Um Pipeline Rastreável para Segmentação Renal, Curadoria de Máscaras e Quantificação Exploratória da Ecogenicidade em Ultrassonografia

Jefferson S. dos Anjos[1], Amaro A. de Lima[1], Gabriel M. Araújo[1], Jorge Luiz de C. Henriques Junior[2], Norderval C. Araújo[2], José Hermógenes R. Suassuna[2], Felipe da R. Henriques[1]

[1] [1] CEFET/RJ – Rio de Janeiro – RJ – Brasil
[2] HUPE – UERJ – Rio de Janeiro – RJ – Brasil

jefferson.anjos.1@aluno.cefet-rj.br

{amaro.lima,gabriel.araujo,felipe.henriques}@cefet-rj.br

{jorge.henriques,norderval.norderval}@uerj.br

Abstract. *Renal ultrasound is widely available, but computational analysis is affected by acquisition variability, ambiguous anatomical boundaries and scarce expert annotations. This study develops and evaluates a traceable pipeline for capsule and intrarenal structure segmentation, human curation and exploratory echogenicity quantification. The kidneyUS dataset supplies manually annotated references, whereas external MONAI images are used only to generate candidate pseudomasks. In the deduplicated capsule test of 70 images, U-Net achieved Dice 0.9290 and IoU 0.8722. On 4,479 external images, the distilled student selected for operational use produced 3,707 non-empty candidates, compared with 3,534 for the previous operational checkpoint; this coverage was not interpreted as anatomical accuracy. On a separate manually annotated test of 50 images, multiclass U-Net achieved mean Dice 0.7594 for cortex, medulla and central echo complex (CEC). In a grouped cascade re-evaluation with no shared examination identifiers across splits, the intrarenal student achieved foreground Dice 0.7210 with the predicted capsule ROI and 0.7395 with the reference ROI. Expanding medulla training from 236 to 578 images did not improve test Dice (0.7528 versus 0.7523). Echogenicity measures are computed from original B-mode images and remain exploratory because repeatability and clinical associations were not validated. The contribution is an auditable workflow separating predictions, pseudolabels, human review and quantitative measurements; it does not claim automatic diagnosis of fibrosis or chronic kidney disease.*

Keywords: *renal ultrasound; semantic segmentation; knowledge distillation; human-in-the-loop; echogenicity.*

Resumo. *A ultrassonografia renal é amplamente disponível, mas sua análise computacional é afetada por variações de aquisição, fronteiras anatômicas ambíguas e escassez de anotações especializadas. Este estudo desenvolve e avalia um pipeline rastreável para segmentação da cápsula e de estruturas*

intrarrenais, curadoria humana e quantificação exploratória da ecogenicidade. O conjunto `kidneyUS` *fornece referências manuais, enquanto imagens externas do MONAI são usadas apenas para gerar pseudomáscaras candidatas. No teste deduplicado da cápsula, com 70 imagens, a U-Net alcançou Dice de 0,9290 e IoU de 0,8722. Em 4.479 imagens externas, a estudante destilada selecionada para operação produziu 3.707 candidatas não vazias, contra 3.534 do checkpoint operacional anterior; essa cobertura não foi interpretada como acurácia anatômica. Em outro teste manual, com 50 imagens, a U-Net multiclasse obteve Dice médio de 0,7594 para córtex, medula e complexo ecogênico central (CEC). Na reavaliação agrupada da cascata, sem identificadores de exame compartilhados entre as divisões, a estudante intrarrenal atingiu Dice foreground de 0,7210 quando recebeu a ROI produzida pela estudante da cápsula, contra 0,7395 com ROI de referência. A expansão do treinamento da medula de 236 para 578 imagens não aumentou o Dice de teste (0,7528 contra 0,7523). As medidas de ecogenicidade são calculadas na imagem B-mode original e permanecem exploratórias, pois sua repetibilidade e suas associações clínicas não foram validadas. A contribuição é um fluxo auditável que separa predições, pseudorrótulos, revisão humana e medidas quantitativas, sem alegar diagnóstico automático de fibrose ou doença renal crônica.*

Palavras-chave: *ultrassonografia renal; segmentação semântica; destilação de conhecimento; curadoria humana; ecogenicidade.*

Lista de Figuras

1 Arquitetura U-Net utilizada na segmentação renal 11
2 Arquitetura U-Net++ utilizada na segmentação renal 12
3 Arquitetura DeepLabV3 com backbone ResNet-50 e ASPP 12
4 Arquitetura SegFormer-B0 13
5 Evolução metodológica da pesquisa em três fases 16
6 Fluxo de treinamento da destilação multi-professor 20
7 Arquiteturas das estudantes da cápsula e intrarrenal 21
8 Visão geral da interface de Curadoria Web 23
9 Visualização ampliada de um exame na Curadoria Web 23
10 Ferramenta de correção manual de máscaras 24
11 Comparador de ROIs para mensuração da ecogenicidade 25
12 Exemplo de segmentação renal em condição favorável 27
13 Divergência entre U-Net e DeepLabV3 28
14 Máscaras anatômicas utilizadas no piloto multimodal 33
15 Imagem renal de exemplo com sobreposição de máscaras 44
16 Interface do assistente multimodal 45

Lista de Tabelas

1 Conjuntos supervisionados por tarefa e protocolo 17
2 Fontes de dados e alcance das avaliações 17
3 Benchmark de segmentação da cápsula renal 26
4 Cobertura de pseudomáscaras no MONAI 27
5 Piloto inicial de destilação da cápsula 28
6 Custo controlado de inferência na RTX 3050 29
7 Combinações de professores na destilação 29
8 Desempenho de segmentação por estrutura intrarrenal 30
9 Revalidação agrupada da cascata destilada 30
10 Concordância Dice entre anotadores humanos 31
11 Pseudo-expansão do conjunto de medula 31
12 Comparação qualitativa do piloto multimodal 33
13 Síntese das evidências e limitações 34
14 Comparação descritiva com MAT-UNet 37
15 Plano experimental para continuidade da dissertação 38
16 Exemplo de uso do assistente multimodal 45

Lista de Abreviaturas e Siglas

ASPP	*Atrous Spatial Pyramid Pooling* (agrupamento espacial piramidal com convolucoes dilatadas).
BCE	*Binary Cross-Entropy* (entropia cruzada binária).
CEC	Complexo Ecogênico Central.
CLAHE	*Contrast Limited Adaptive Histogram Equalization* (equalização adaptativa de histograma limitada por contraste).
CUDA	*Compute Unified Device Architecture*.
DICOM	*Digital Imaging and Communications in Medicine*.
eGFR	*Estimated Glomerular Filtration Rate* (taxa de filtração glomerular estimada).
FPS	*Frames per Second* (quadros por segundo).
GPU	*Graphics Processing Unit* (unidade de processamento gráfico).
IFTA	*Interstitial Fibrosis and Tubular Atrophy* (fibrose intersticial e atrofia tubular).
IoU	*Intersection over Union* (interseção sobre união).
IQR	*Interquartile Range* (intervalo interquartil).
KD	*Knowledge Distillation* (destilação de conhecimento).
MONAI	*Medical Open Network for AI*, ecossistema para aplicações de IA em saúde.
RGB	*Red, Green, Blue* (vermelho, verde e azul).
ROI	*Region of Interest* (região de interesse).
SBBD	Simpósio Brasileiro de Bancos de Dados.

Lista de Símbolos

P	Máscara prevista pelo modelo.
G	Máscara de referência.
p_i	Probabilidade predita para o pixel i.
M	Conjunto dos pixels da máscara candidata.
$C(M)$	Confiança operacional média da máscara.
$S(M_U, M_D)$	Concordância espacial entre as máscaras de U-Net e DeepLabV3.
p_T	Probabilidade-alvo média dos professores.
K	Número de modelos professores combinados.
T	Temperatura da destilação de conhecimento.
$\mathcal{L}_{sup}$	Termo supervisionado da função de perda.
$\mathcal{L}_{KD}$	Termo de perda da destilação.
μ_C	Intensidade média do córtex renal.
μ_{CEC}	Intensidade média do complexo ecogênico central.
$R_{C/CEC}$	Razão percentual entre intensidades médias de córtex e CEC.
CN_{CEC-C}	Contraste normalizado entre CEC e córtex.
D_{CEC-C}	Diferença de intensidade média entre CEC e córtex.

Sumário

1 Introdução **9**
- 1.1 Contextualização e problema . . . 9
- 1.2 Questão de pesquisa e hipótese . . . 9
- 1.3 Objetivos e escopo . . . 9
- 1.4 Contribuições e organização do texto . . . 9

2 Fundamentação Teórica e Trabalhos Relacionados **10**
- 2.1 Ultrassonografia renal, dados anotados e variabilidade de referência . . . 10
- 2.2 Segmentação semântica e arquiteturas comparadas . . . 10
- 2.3 Máscaras, métricas e unidades de avaliação . . . 11
- 2.4 Pseudorrotulação, consenso e destilação de conhecimento . . . 13
- 2.5 Curadoria humana, proveniência e ferramentas existentes . . . 14
- 2.6 Ecogenicidade quantitativa e limites clínicos . . . 14
- 2.7 Modelos multimodais no apoio à revisão . . . 15
- 2.8 Trabalhos diretamente relacionados e lacuna científica . . . 15

3 Metodologia **15**
- 3.1 Visão geral e evolução do protocolo . . . 15
- 3.2 Desenho experimental, fontes e unidades de avaliação . . . 17
- 3.3 Critérios de comparação e validade da avaliação . . . 17
- 3.4 Pré-processamento e benchmark da cápsula . . . 18
- 3.5 Fonte externa, pseudomáscaras e consenso . . . 18
- 3.6 Destilação multi-professor e comparação controlada . . . 19
- 3.7 Segmentação intrarrenal e propagação de erro . . . 21
- 3.8 Pseudo-expansão controlada da medula . . . 22
- 3.9 Curadoria Web: implementação e fluxo de revisão humana . . . 22
- 3.10 Mensuração quantitativa de ecogenicidade . . . 24
- 3.11 Assistente multimodal: desenho do estudo piloto . . . 26

4 Resultados **26**
- 4.1 Segmentação da cápsula renal . . . 26
- 4.2 Consenso entre modelos e imagens externas . . . 27
- 4.3 Destilação da cápsula e custo computacional . . . 28
- 4.4 Segmentação e destilação das estruturas intrarrenais . . . 30
- 4.5 Reavaliação da cascata e propagação de erro . . . 30
- 4.6 Variabilidade da referência humana . . . 31
- 4.7 Medula: estabilidade e pseudo-expansão . . . 31
- 4.8 Plataforma Web de Curadoria . . . 32
- 4.9 Estudo exploratório do assistente multimodal . . . 32
- 4.10 Síntese das evidências disponíveis . . . 34

5 Discussão **35**
- 5.1 O que a cascata demonstra sobre segmentação renal . . . 35
- 5.2 Destilação: economia computacional e limites da seleção . . . 35
- 5.3 Pseudorrótulos, curadoria e qualidade dos dados . . . 35
- 5.4 Ecogenicidade e evidência clínica . . . 36

5.5 Posicionamento diante de trabalhos diretamente relacionados 36
5.6 Síntese interpretativa 37

6 Limitações e Ameaças à Validade **37**
6.1 Validade interna e seleção de modelos 37
6.2 Validade de construção e referência anatômica 37
6.3 Validade externa e deslocamento de domínio 37
6.4 Validade operacional, clínica e multimodal 38

7 Continuidade da Dissertação **38**
7.1 Congelamento e reavaliação independente 38
7.2 Curadoria *human-in-the-loop* e estudo de impacto 38
7.3 Estabilidade da cascata e de ecogenicidade 39
7.4 Posição do assistente multimodal 39

8 Conclusão **39**

Referências Bibliográficas **39**

A Exemplo complementar de uso do assistente **44**

1. Introdução

1.1. Contextualização e problema

A ultrassonografia é amplamente empregada na avaliação morfológica renal por ser não invasiva e oferecer imagens em tempo real. Sua interpretação, contudo, depende do operador, do equipamento e das condições de aquisição: ruído *speckle*, sombras acústicas, ganho, profundidade e enquadramento modificam o contraste entre estruturas. Essas variações dificultam tanto a delimitação do órgão quanto a extração reprodutível de medidas de intensidade. Uma região de interesse mal localizada pode incluir tecido adjacente, fundo e artefatos, comprometendo qualquer descritor calculado a partir dela.

Este trabalho considera duas tarefas anatômicas encadeadas: segmentar o contorno externo do rim, aqui referido operacionalmente como máscara da cápsula, e identificar córtex, medula e complexo ecogênico central (CEC) no interior da região delimitada. Os erros da primeira etapa podem propagar-se à segunda; por isso, uma boa métrica isolada de segmentação não assegura a confiabilidade das medidas intrarrenais. A escassez de anotações especializadas e a divergência entre observadores ampliam esse desafio [Singla et al. 2023, Taha and Hanbury 2015].

1.2. Questão de pesquisa e hipótese

A pergunta central é: *como integrar segmentação hierárquica, destilação de conhecimento, triagem de pseudorrótulos e revisão humana em um fluxo rastreável que permita avaliar a confiabilidade de máscaras e de descritores de ecogenicidade renal?* A hipótese metodológica é que a procedência e a qualidade das máscaras, especialmente nas interfaces intrarrenais, influenciam as medidas de imagem mais do que a simples ampliação do número de exemplos pseudorrotulados. Trata-se de uma hipótese a testar, e não de um efeito já demonstrado pela plataforma.

1.3. Objetivos e escopo

O objetivo geral é desenvolver e avaliar um *pipeline* de visão computacional para delimitação anatômica e caracterização quantitativa exploratória de ultrassonografias renais, mantendo a proveniência de dados, modelos, predições e revisões. Os objetivos específicos são: (i) estabelecer um *benchmark* supervisionado e deduplicado da cápsula; (ii) avaliar consenso e destilação entre arquiteturas distintas; (iii) segmentar estruturas intrarrenais e medir a propagação de erros entre estágios; (iv) investigar os limites da pseudo-expansão; (v) implementar uma plataforma de curadoria auditável; e (vi) especificar medidas de ecogenicidade extraídas da imagem B-mode original. Os objetivos (i)–(iv) contam com avaliações experimentais nesta versão; para (v) e (vi), estão demonstradas a implementação e a viabilidade do fluxo, mas ainda faltam estudos controlados de benefício da revisão e repetibilidade das medidas.

A ecogenicidade cortical e as relações entre regiões anatômicas motivam o último estágio [Manley and O'Neill 2001, Moghazi et al. 2005, Beutler et al. 2024, Zhao et al. 2025]. Entretanto, brilho em B-mode não é um indicador específico de fibrose, e não se dispõe aqui de referência clínica ou histopatológica pareada suficiente para classificá-la. O assistente multimodal integrado à aplicação é tratado como recurso exploratório de apoio à revisão, não como método validado de diagnóstico.

1.4. Contribuições e organização do texto

A contribuição reivindicada é de **integração metodológica e avaliação operacional**, não a invenção de uma nova arquitetura neural. O trabalho articula segmentadores externos e

intrarrenais, professores heterogêneos e estudantes compactas, consenso para triagem, registro de revisões humanas e medidas de intensidade calculadas sobre a imagem original. A distinção entre referência manual, predição, pseudomáscara, máscara revisada e resultado clínico é uma exigência explícita do desenho. A fundamentação apresenta os conceitos e a lacuna; a metodologia descreve os protocolos; os resultados separam evidência experimental de demonstração de software; e a discussão, as ameaças à validade e o plano de continuidade delimitam o que ainda precisa ser testado.

2. Fundamentação Teórica e Trabalhos Relacionados

2.1. Ultrassonografia renal, dados anotados e variabilidade de referência

A delimitação de estruturas renais em ultrassonografia é dificultada por contrastes heterogêneos, sombras acústicas e transições anatômicas nem sempre nítidas. O `Open Kidney Ultrasound Data Set` (`kidneyUS`) disponibiliza imagens e anotações de estruturas como a cápsula, o córtex, a medula e o CEC, com referências independentes que permitem estudar a variabilidade de anotação [Singla et al. 2023]. A presença de mais de um observador é metodologicamente relevante: a comparação entre modelo e anotador mede concordância com aquela referência, não uma verdade anatômica incontestável. Esse aspecto é particularmente importante na interface córtico-medular, onde pequenas diferenças de traçado podem produzir quedas expressivas de Dice.

A literatura de ultrassonografia renal confirma a importância de controlar a fonte dos dados, a preparação da imagem e a definição das estruturas-alvo [Khan et al. 2024, Zuo et al. 2025, Zhang et al. 2026]. Neste estudo, a referência manual é reservada à avaliação supervisionada, enquanto imagens externas sem anotação servem inicialmente à geração de propostas para revisão. A origem de cada máscara é preservada para evitar que uma predição de modelo seja interpretada como anotação especializada.

2.2. Segmentação semântica e arquiteturas comparadas

A segmentação semântica atribui um rótulo a cada pixel da imagem. Na tarefa binária, distingue-se rim de fundo; na tarefa intrarrenal, o modelo prediz fundo, córtex, medula e CEC. As quatro famílias do comparador representam escolhas distintas de extração de contexto e reconstrução espacial: U-Net, U-Net++, DeepLabV3 e SegFormer [Ronneberger et al. 2015, Zhou et al. 2018, Chen et al. 2017, Xie et al. 2021]. Elas foram empregadas como referências experimentais, sem pressupor que maior complexidade arquitetural implique melhor segmentação do rim.

U-Net e U-Net++. A U-Net combina um codificador convolucional com um decodificador que recupera resolução por conexões de salto (*skip connections*); a U-Net++ adiciona caminhos aninhados de fusão entre níveis [Ronneberger et al. 2015, Zhou et al. 2018]. No comparador binário, a U-Net tem quatro níveis com 64, 128, 256 e 512 canais e uma convolução final de um canal; a implementação de U-Net++ produz uma única saída, sem *deep supervision*. Ambas recuperam contexto e localização, mas não eliminam a ambiguidade de limites anatômicos pouco contrastados.

DeepLabV3. O DeepLabV3 utiliza o *Atrous Spatial Pyramid Pooling* (ASPP) e convoluções dilatadas para representar contexto em múltiplas escalas [Chen et al. 2017]. O comparador utiliza a variante com *backbone* ResNet-50 e saída binária. Essa

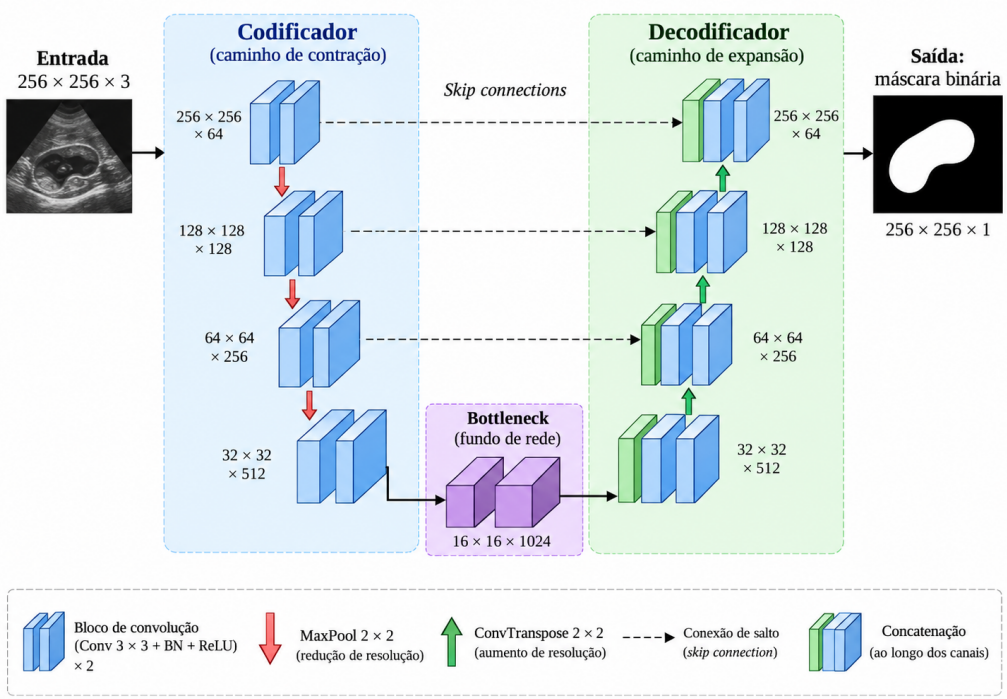


Figura 1. Representação esquemática da arquitetura U-Net utilizada como referência para o comparador de segmentação renal. Fonte: elaboração própria, com base na arquitetura original e na implementação estudada. A arquitetura original é descrita por [Ronneberger et al. 2015].

implementação não corresponde ao DeepLabV3+, que acrescenta um decodificador para refinamento de bordas [Chen et al. 2018]; a distinção evita atribuir propriedades de outra arquitetura ao experimento realizado.

SegFormer. O SegFormer combina codificador hierárquico baseado em Transformers (*Mix Transformer*) e decodificação leve por fusão de características multiescala [Xie et al. 2021]. Sua inclusão permite confrontar redes convolucionais com uma estratégia alternativa de representação; parâmetros, taxa de quadros e Dice precisam ser reportados em condições de benchmark explicitadas.

As arquiteturas acima descrevem os comparadores da cápsula. Os modelos intrarrenais e as estudantes destiladas possuem objetivos, entradas e checkpoints específicos, descritos na metodologia. Assim, desempenho obtido em uma tarefa não é automaticamente transferido para outra.

2.3. Máscaras, métricas e unidades de avaliação

Sejam P a máscara prevista e G a máscara de referência. Dice e interseção sobre união (IoU) medem sobreposição espacial:

$$\mathrm{Dice}(P,G) = \frac{2|P \cap G|}{|P| + |G|}, \qquad \mathrm{IoU}(P,G) = \frac{|P \cap G|}{|P \cup G|}. \tag{1}$$

Essas métricas dependem do método de agregação (por imagem ou global), das regras para máscaras vazias e da referência adotada [Taha and Hanbury 2015]. Precisão e *recall*

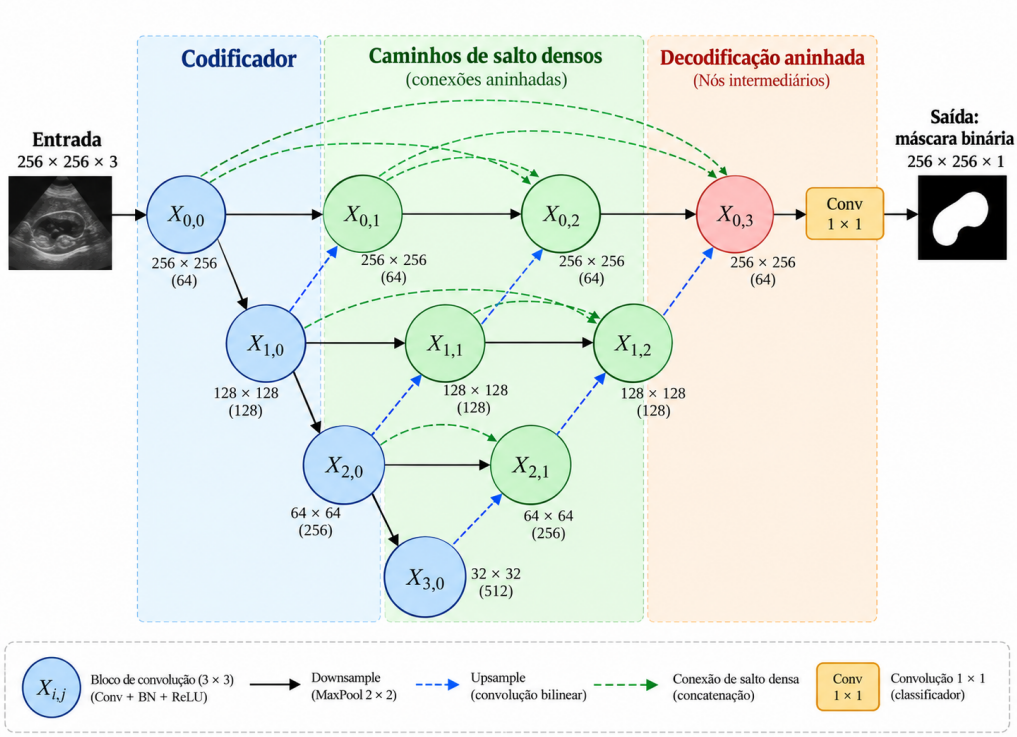


Figura 2. Representação esquemática da arquitetura U-Net++ utilizada como referência para o comparador de segmentação renal. Fonte: elaboração própria, com base na arquitetura original e na implementação estudada. A arquitetura original é descrita por [Zhou et al. 2018].

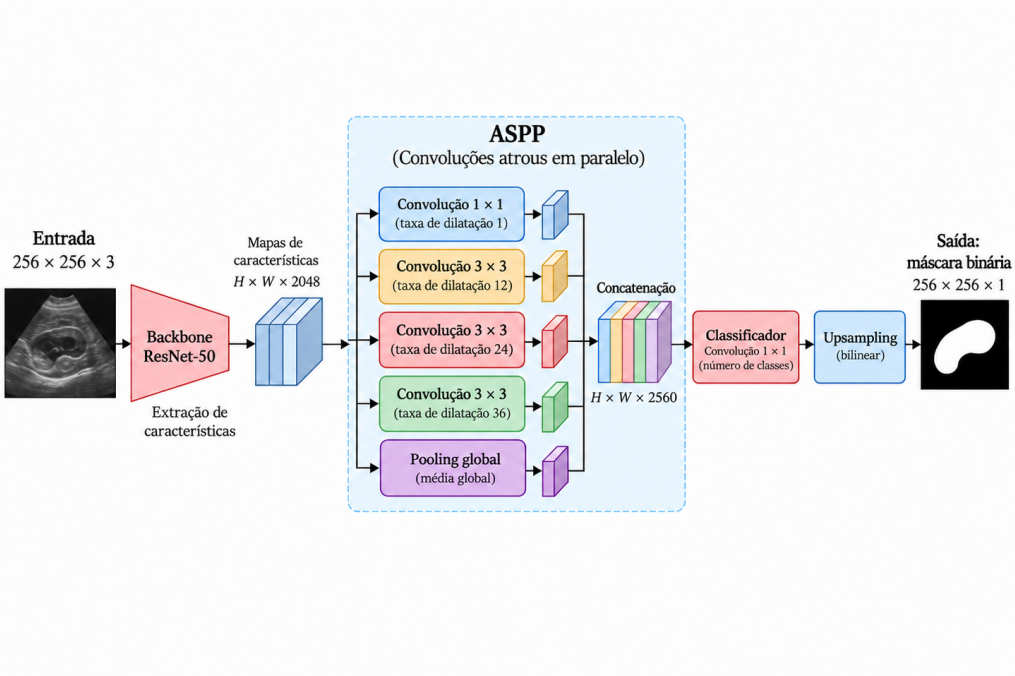


Figura 3. Arquitetura DeepLabV3 empregada na segmentação renal. O backbone ResNet-50 fornece mapas de características ao ASPP, cujas ramificações utilizam taxas 12, 24 e 36, além das ramificações 1×1 e de pooling global. Fonte: elaboração própria, com base em [Chen et al. 2017] e na implementação estudada.

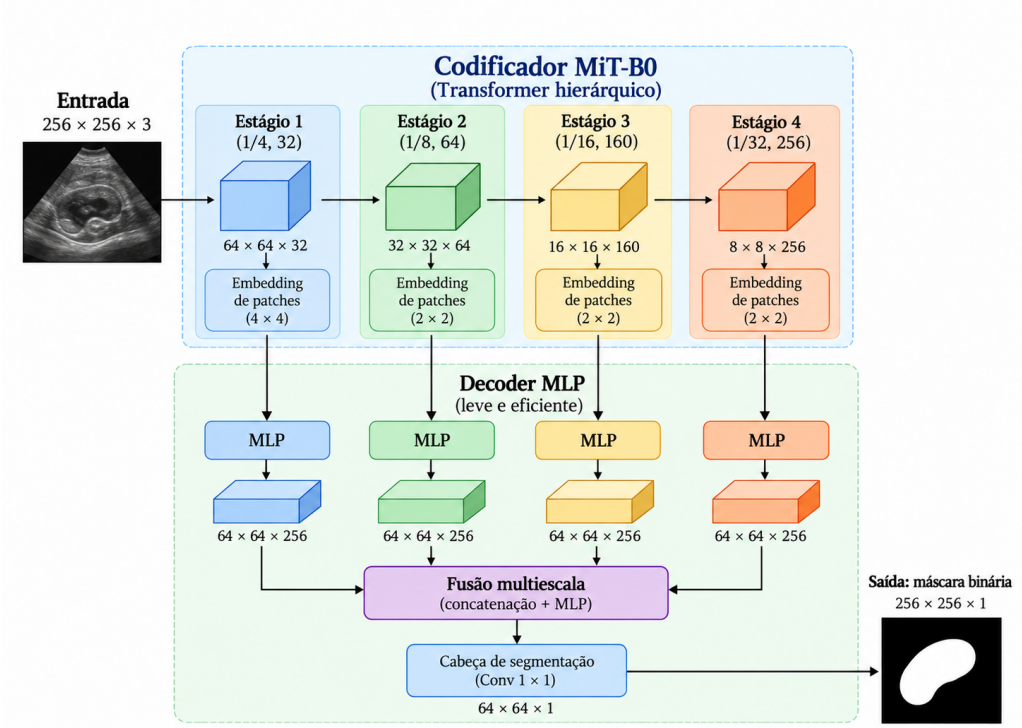


Figura 4. Representação esquemática da arquitetura SegFormer-B0 utilizada como referência para o comparador de segmentação renal. Fonte: elaboração própria, com base na arquitetura original e na implementação estudada. A arquitetura original é descrita por [Xie et al. 2021].

ajudam a identificar, respectivamente, inclusão excessiva e omissão de pixels; a distância de contorno e a análise por classe complementam a sobreposição. Em especial, métricas de cápsula e de estruturas internas, obtidas em amostras diferentes, não constituem um único comparador de dificuldade.

Convém distinguir três grandezas: *probabilidade predita*, *concordância entre modelos* e *acurácia frente à referência*. Uma probabilidade elevada pode estar mal calibrada; duas redes podem concordar num erro comum; e a métrica contra um único anotador não elimina a variabilidade humana. Essas diferenças fundamentam o uso do consenso como sinal de triagem, e não como selo de correção anatômica [Lee 2013, Tajbakhsh et al. 2020].

2.4. Pseudorrotulação, consenso e destilação de conhecimento

Pseudorrotulação reutiliza previsões de modelos como supervisão candidata em imagens sem rótulos, ampliando a cobertura com o risco de reproduzir erros sistemáticos. Estudos de aprendizado semi-supervisionado e rótulos imperfeitos recomendam explicitar regras de seleção e validação [Lee 2013, Jiao et al. 2024, Su et al. 2024, Huang et al. 2025]. No protocolo aqui estudado, o acordo U-Net–DeepLabV3 orienta prioridades de revisão humana; ele não converte uma pseudomáscara em referência independente.

A destilação de conhecimento (*knowledge distillation*, KD) transfere informações das predições de redes professoras para uma estudante potencialmente menor [Hinton et al. 2015]. Para K professores, um alvo suave binário pode ser definido

pela média das probabilidades por pixel:

$$p_T(i) = \frac{1}{K} \sum_{k=1}^{K} p_k(i), \tag{2}$$

A estudante combina supervisão de máscaras manuais e alinhamento aos alvos suaves:

$$\mathcal{L}_{total} = \lambda_{sup}\mathcal{L}_{sup} + \lambda_{KD}\mathcal{L}_{KD}, \tag{3}$$

A destilação é distinta do consenso: o primeiro é um procedimento de treinamento; o segundo é um indicador de concordância usado para triagem. Trabalhos de destilação de canais, regiões e relações espaciais mostram alternativas à simples média de saídas [Shu et al. 2021, Qin et al. 2021, Zhao et al. 2023, Qi et al. 2024]. No `kidneyUS`, o MK-Net de Chen et al. [Chen et al. 2026] também emprega destilação e estruturas intrarrenais; logo, não há alegação de pioneirismo no uso de KD nesse conjunto. A contribuição a avaliar é sua inserção numa cascata rastreável, com estudantes independentes por tarefa e medição explícita do custo de inferência.

2.5. Curadoria humana, proveniência e ferramentas existentes

Num fluxo *human-in-the-loop*, a saída do modelo é uma proposta de anotação. O revisor pode aceitar, corrigir, rejeitar ou declarar uma máscara indisponível, mantendo a versão automática e a versão revisada como objetos distintos [Budd et al. 2021]. Para auditoria, devem ser registrados identificador de imagem e exame, origem dos dados, classe anatômica, modelo e checkpoint, decisão do revisor e versão resultante. Esses metadados permitem investigar se uma eventual melhora vem do volume de imagens, do filtro automático ou da intervenção humana.

A Curadoria Web deve ser comparada com soluções existentes, e não apresentada como inovação do conceito de anotação assistida. MONAI Label integra inferência e revisão em aplicações médicas; CVAT oferece edição visual de máscaras; OHIF fornece visualização de imagens; e MedSAM é uma referência de segmentação médica de propósito amplo [Diaz-Pinto et al. 2024, Aljabri et al. 2022, CVAT.ai 2026, OHIF 2026, Ma et al. 2024]. O diferencial operacional pretendido é reunir, num fluxo renal específico, máscaras de cápsula/córtex/medula/CEC, revisões versionadas e medidas de ecogenicidade. A existência da ferramenta não demonstra, por si só, redução de tempo de anotação, ganho de Dice ou concordância entre especialistas; esses são desfechos ainda a medir.

2.6. Ecogenicidade quantitativa e limites clínicos

A ecogenicidade em B-mode depende da resposta do tecido e de fatores de aquisição, incluindo ganho, compensação temporal, profundidade e processamento do aparelho. Por isso, intensidade em tons de cinza não é uma medida absoluta de fibrose. Estudos sobre ecogenicidade cortical e comparações relativas com órgãos ou regiões de referência motivam descritores quantitativos, mas empregam definições e desfechos que não são intercambiáveis [Manley and O'Neill 2001, Moghazi et al. 2005, Beutler et al. 2024, Zhao et al. 2025].

Se C e E representam os pixels válidos de córtex e CEC, as intensidades médias na imagem original I são:

$$\mu_C = \frac{1}{|C|} \sum_{(x,y)\in C} I(x,y), \qquad \mu_{CEC} = \frac{1}{|E|} \sum_{(x,y)\in E} I(x,y). \tag{4}$$

A razão μ_C/μ_{CEC}, sua versão percentual e o contraste normalizado são descritores distintos, com orientação matemática definida. A comparação córtex–CEC usada neste trabalho ainda precisa de avaliação de sensibilidade à máscara, posição das ROIs e profundidade. Realces como CLAHE podem auxiliar o segmentador, mas não devem ser confundidos com a imagem B-mode original empregada para quantificação. Estudos sobre doença renal e fibrose com referência histológica [Athavale et al. 2021, Qin et al. 2024] estabelecem um patamar de validação clínica não alcançado pelo presente conjunto experimental.

2.7. Modelos multimodais no apoio à revisão

Modelos de linguagem podem estruturar laudos e recuperar entidades, negações e incertezas; modelos de visão e linguagem também podem receber imagens e perguntas. Essas tarefas não equivalem à detecção clínica validada de alterações renais [Wang et al. 2025, Reichenpfader et al. 2024, Busch et al. 2025]. Propostas como LLaVA-Med, BioMed-VITAL, MedGemma e Qwen2.5-VL oferecem fundamentos de adaptação multimodal, mas seus resultados em outros domínios não são evidência de desempenho no `kidneyUS` [Li et al. 2023, Cui et al. 2024, Sellergren et al. 2026, Bai et al. 2025]. Revisões metodológicas ressaltam riscos de afirmações não sustentadas e necessidade de avaliação humana com prompts e versões documentados [Artsi et al. 2025, Bluethgen et al. 2025].

O assistente da Curadoria Web utiliza as máscaras e medidas como evidências auxiliares. Nesta versão, sua avaliação é um estudo de viabilidade com amostra muito pequena, sem referência independente dos achados; por isso, ocupa posição secundária perante a validação anatômica da cascata e não fundamenta conclusões de superioridade entre modelos.

2.8. Trabalhos diretamente relacionados e lacuna científica

O `kidneyUS` de Singla et al. [Singla et al. 2023] fornece a base de referência, enquanto Khan et al. [Khan et al. 2024] e Zuo et al. [Zuo et al. 2025] aproximam-se da segmentação renal, esta última incluindo estruturas intrarrenais. Athavale et al. [Athavale et al. 2021] estudaram desfechos histopatológicos associados à fibrose, diferentemente do presente protocolo exploratório de intensidade. MONAI Label [Diaz-Pinto et al. 2024] já explora o ciclo de predição e revisão. Essas pesquisas delimitam o que não pode ser reivindicado como inédito: arquiteturas, pseudorrotulação, destilação, anotação assistida ou associação clínica de ecogenicidade, tomadas isoladamente.

A lacuna operacional e metodológica examinada é a avaliação encadeada das dependências entre segmentação externa, segmentação interna, proveniência da máscara, intervenção de revisão e medidas extraídas da imagem original. A pesquisa investiga essa integração por meio de comparadores supervisionados, experimentos de destilação, análise de propagação de erro e um artefato de curadoria. O efeito quantitativo da revisão humana sobre a qualidade final das máscaras e a repetibilidade de ecogenicidade permanece hipótese experimental para a continuidade da dissertação.

3. Metodologia

3.1. Visão geral e evolução do protocolo

O fluxo de pesquisa foi desenvolvido em três fases que correspondem a níveis progressivos de análise, e não a três bases de teste diretamente comparáveis. A primeira

organizou dados, comparou segmentadores da cápsula e explorou pseudorrótulos. A segunda acrescentou consenso, destilação e segmentação intrarrenal, com avaliação do efeito do erro da cápsula. A terceira integrou inferência e revisão humana à Curadoria Web, permitindo calcular descritores de ecogenicidade na imagem original e estudar um assistente multimodal em caráter exploratório. A Figura 5 sintetiza a dependência entre as etapas.

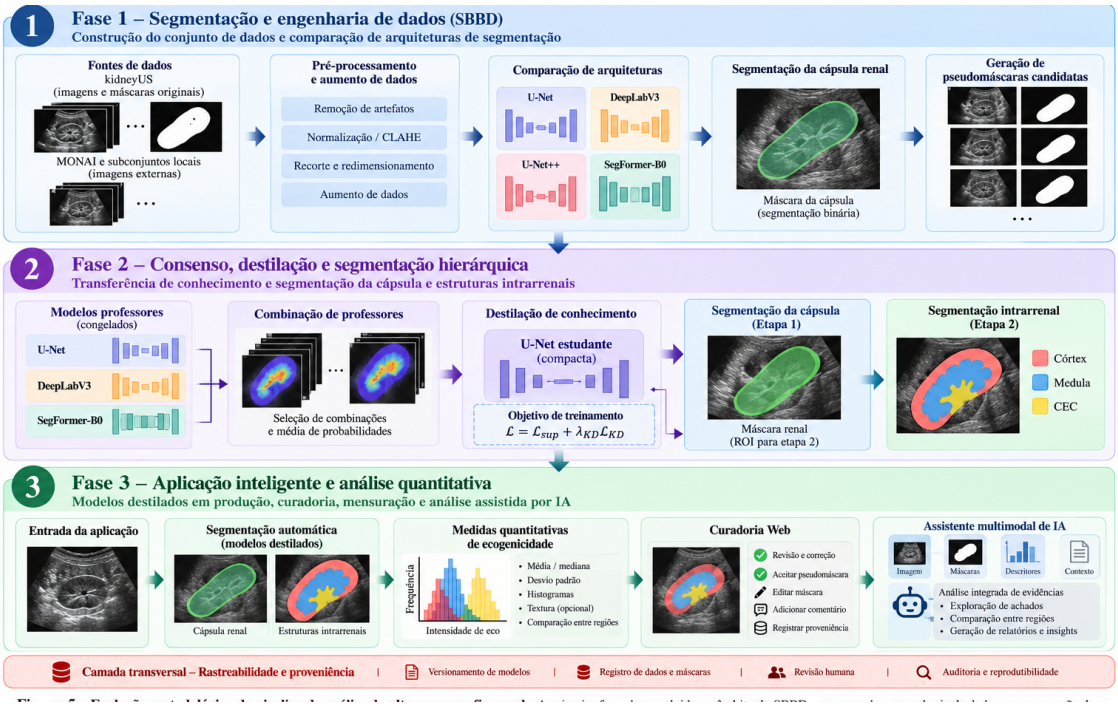


Figura 5. Visão geral da evolução metodológica da pesquisa: engenharia de dados e segmentação renal (Fase 1), consenso e destilação hierárquica com estudantes distintas para cápsula e estruturas intrarrenais (Fase 2), e integração à Curadoria Web, mensuração exploratória e assistente multimodal (Fase 3). Proveniência e revisão humana são transversais às fases. Fonte: elaboração própria.

O ponto de partida histórico, documentado no trabalho do SBBD, utilizou 513 pares imagem–máscara do `kidneyUS` e um acervo que chegou a 5.994 imagens após incluir 1.002 registros locais e 4.479 imagens externas selecionadas do MONAI [Singla et al. 2023, MONAI Development Team 2026]. Naquele protocolo, 2.961 pseudomáscaras e 1.001 máscaras preexistentes foram utilizadas no conjunto expandido. O DeepLabV3-ResNet50 obteve Dice de 0,9235 em teste fixo desse experimento anterior, mas sua amostra e seu protocolo não equivalem aos testes manuais deduplicados posteriores. Esses números contextualizam a evolução; os resultados centrais da presente qualificação usam avaliações supervisionadas identificadas por tarefa.

A observação de erros visualmente plausíveis em previsões de alta confiança motivou a mudança de aceitação automática de pseudomáscaras para *triagem e revisão*. Assim, a máscara automática, a referência manual do `kidneyUS` e a versão corrigida na plataforma permanecem objetos distintos. A destilação busca reduzir o custo de inferência sem assumir que compactação melhore o Dice; a mensuração de ecogenicidade exige ainda validação de repetibilidade e referência clínica. Essas distinções determinam o desenho experimental a seguir.

3.2. Desenho experimental, fontes e unidades de avaliação

Os experimentos são organizados por tarefa anatômica e unidade de divisão, sem combinar suas amostras em uma estimativa única. As referências supervisionadas provêm das anotações do `kidneyUS` [Singla et al. 2023]; as máscaras adicionais produzidas neste projeto têm identificação de modelo, checkpoint e, quando aplicável, estado de revisão. A Tabela 1 reúne as divisões manuais e identifica a reavaliação agrupada da cascata, cuja partição não é intercambiável com o benchmark intrarrenal anterior.

Tabela 1. Conjuntos supervisionados utilizados por tarefa. Tamanhos e divisões diferentes não representam o mesmo experimento.

Tarefa/protocolo	Total	Treino	Val.	Teste
Cápsula deduplicada	468	328	70	70
Intrarrenal multiclasse (original)	335	235	50	50
Medula binária	336	236	50	50
Cascata reavaliada por exame	335	234	50	51

A cápsula parte de 486 registros do primeiro anotador, correspondentes a 468 imagens únicas após deduplicação por conteúdo. O benchmark utiliza 328 imagens para treino, 70 para validação e 70 para teste. O experimento intrarrenal original utiliza 335 imagens (235/50/50), e o estudo específico de medula utiliza 336 (236/50/50). A reavaliação da cascata conserva 335 imagens elegíveis, mas define 234/50/51 por identificador de exame, sem chaves `IM-*` compartilhadas entre divisões. A separação agrupada por paciente ou exame é mais apropriada do que divisão aleatória de quadros correlacionados; as regras e manifestos de cada experimento precisam acompanhar os checkpoints para reprodução.

Tabela 2. Papel das fontes de dados e alcance das avaliações realizadas.

Fonte	Tipo de referência	Uso permitido no estudo
`kidneyUS`	Anotações humanas de estruturas renais	Treino, validação e testes supervisionados separados por tarefa
MONAI renal curado (4.479)	Imagens sem máscara manual externa consolidada	Gerar e contar propostas; não estimar Dice externo
Acervo histórico expandido	Máscaras preexistentes e pseudomáscaras de diferentes origens	Contextualização, sem substituir teste manual deduplicado

3.3. Critérios de comparação e validade da avaliação

Dice, IoU, precisão e *recall* são interpretados em relação à referência manual pertinente a cada protocolo; as médias intrarrenais consideram classes de primeiro plano, ao passo que a métrica binária refere-se à cápsula ou à medula. O experimento da cascata compara, sobre seus mesmos casos de teste, uma ROI de cápsula de referência com a ROI efetivamente prevista pela estudante. Essa comparação pareada é mais informativa para propagação de erros do que confrontar Dice de conjuntos distintos. Concordância entre professores, confiança média de pixels e porcentagem de propostas não vazias no MONAI são indicadores operacionais, não medidas de acurácia anatômica.

A seleção de limiar e checkpoint deve utilizar exclusivamente a validação. A matriz de combinações de professores teve uma limitação documentada: a combinação operacional foi escolhida após a observação dos resultados de teste, o que impede interpretá-los como confirmação independente da opção selecionada. Para a conclusão da dissertação, uma configuração congelada precisará ser examinada em teste não utilizado na escolha, com estimativas de incerteza por exame/paciente e sensibilidade a inicializações. FPS é reportado separando o benchmark fim a fim do benchmark restrito ao *forward* da rede, pois esses números não são equivalentes.

3.4. Pré-processamento e benchmark da cápsula

Os segmentadores são treinados com imagens normalizadas e redimensionadas; na configuração deduplicada de referência da U-Net, a entrada possui 256 por 256 pixels, CLAHE é aplicado ao ramo de segmentação e o aumento de dados é restrito ao treinamento. O treinamento registrado utiliza AdamW, taxa inicial de aprendizado de 10^{-4} e perda combinada de entropia cruzada binária e Dice. A seleção do checkpoint e do limiar de decisão ocorre com base na validação; para a U-Net de cápsula consolidada de referência, o limiar documentado é $0{,}35$, enquanto a estudante destilada operacional utiliza $0{,}60$. A inferência de pseudomáscaras externas utiliza também a imagem espelhada horizontalmente, agregando as previsões antes da binarização.

U-Net, UNet++, DeepLabV3-ResNet50 e SegFormer-B0 são comparados no mesmo teste deduplicado. A qualidade de sobreposição é reportada por Dice e IoU [Taha and Hanbury 2015]; precisão e *recall* identificam tendências de supersegmentação ou omissão, enquanto quadros por segundo (FPS) informam o custo de inferência nas condições do benchmark. A U-Net foi a referência inicial da cascata; após a matriz de destilação, a aplicação passou a utilizar, como decisão operacional exploratória, a U-Net estudante da combinação U-Net + DeepLabV3 para inferência e geração de pseudomáscaras. A escolha da combinação foi feita após a observação da matriz completa, incluindo o teste, e não deve ser apresentada como seleção independente desse conjunto.

3.5. Fonte externa, pseudomáscaras e consenso

Para estudar expansão de dados, metadados do repositório clínico MONAI/NVIDIA [MONAI Development Team 2026] foram filtrados por exames renais ou retroperitoneais. DICOMs candidatos foram processados em lotes; foram mantidos quadros adequados ao estudo em escala de cinza, reduzidas sequências temporais e descartados, por padrão, quadros RGB ou coloridos. O conjunto externo consolidado contém 4.479 imagens. Essas imagens não são parte do teste supervisionado da cápsula e não dispõem, nesse fluxo, de referência manual suficiente para estimar Dice externo.

A U-Net gera propostas de máscara renal. Para uma máscara candidata não vazia M, a confiança operacional média é definida por

$$C(M) = \frac{1}{|M|} \sum_{i \in M} p_i, \tag{5}$$

em que p_i é a probabilidade atribuída ao primeiro plano no pixel i. Essa estatística resume a confiança dos pixels selecionados, mas não estima diretamente a probabilidade de toda a máscara estar correta. Componentes conectados, plausibilidade geométrica

e características da predição são usados para preparação e priorização, sem converter automaticamente a proposta em *ground truth*.

A mesma imagem é processada por uma DeepLabV3 independente. A concordância espacial entre as duas predições é

$$S(M_U, M_D) = \frac{2|M_U \cap M_D|}{|M_U| + |M_D|}, \tag{6}$$

calculada para máscaras não vazias com denominador válido. O indicador foi calibrado por validação cruzada *out-of-fold* em cinco folds agrupados por exame, para que cada amostra manual fosse avaliada por modelos que não a haviam utilizado naquele fold. Limiares operacionais de $0{,}89$ e $0{,}94$, derivados da distribuição de calibração documentada, organizam a fila de revisão; eles não certificam a qualidade anatômica. O manifesto preserva fonte, modelo, checkpoint, estado e indicadores associados a cada predição.

3.6. Destilação multi-professor e comparação controlada

O consenso U-Net–DeepLabV3 foi introduzido inicialmente como medida de concordância para organizar a revisão de pseudomáscaras. Entretanto, manter duas redes ativas para cada inferência aumenta o consumo operacional. A destilação foi incorporada como uma estratégia adicional: o consenso permanece como mecanismo de auditoria e triagem, enquanto uma U-Net estudante pode concentrar, em seus parâmetros, parte do comportamento dos professores.

A implementação considera as combinações de professores U-Net–DeepLabV3, U-Net–SegFormer-B0, DeepLabV3–SegFormer-B0 e U-Net–DeepLabV3–SegFormer-B0. Também foi preparado um controle com a mesma U-Net estudante treinada apenas pelas máscaras manuais, sem termo de destilação. Para cada combinação, as probabilidades são produzidas por professores congelados e agregadas conforme a Equação 2. As previsões são armazenadas em cache e cada professor é carregado individualmente, evitando mantê-los simultaneamente na GPU durante a preparação dos alvos.

A estudante possui três canais de entrada, uma saída binária e 32 canais de base. A perda supervisionada é a soma de entropia cruzada binária e perda Dice:

$$\mathcal{L}_{sup} = \mathcal{L}_{BCE} + \mathcal{L}_{Dice}. \tag{7}$$

Para probabilidade média p_T dos professores, limitada numericamente ao intervalo $[10^{-4}, 1 - 10^{-4}]$, e logits z_S da estudante, o termo de destilação implementado é

$$\mathcal{L}_{KD} = T^2 \ \mathrm{BCEWithLogits}\left(\frac{z_S}{T}, \sigma\left[\frac{\mathrm{logit}(p_T)}{T}\right]\right), \tag{8}$$

com $T = 2$, $\lambda_{sup} = 1$ e $\lambda_{KD} = 0{,}5$. No controle sem professores, o termo $\mathcal{L}_{KD}$ é removido. A configuração piloto emprega imagens de 256×256 pixels, CLAHE, aumento de dados apenas no treinamento, AdamW, taxa inicial de 10^{-4}, lote 16, semente 42, até 12 épocas e parada antecipada com paciência de quatro épocas.

Os experimentos utilizam os mesmos conjuntos manuais deduplicados de 328 imagens para treino, 70 para validação e 70 para teste. O limiar e o checkpoint

de cada estudante devem ser escolhidos na validação e mantidos fixos durante a avaliação independente. Para comparações entre configurações, registram-se Dice, IoU, parâmetros, tamanho dos pesos e tempo de inferência em um protocolo comum. Precisão, *recall*, análise por exame e intervalos de confiança constituem extensões importantes da avaliação. O filtro opcional de concordância mínima entre professores é tratado como uma ablação separada, pois altera a composição do conjunto de treinamento. A escolha da combinação de professores para a implantação foi feita após a matriz completa, incluindo os resultados do teste; portanto, o teste não permaneceu completamente isolado da seleção da configuração operacional, e essa escolha deve ser interpretada como exploratória.

O piloto U-Net–DeepLabV3 e as demais combinações de professores já foram executados e são reportados na Seção de Resultados. A escolha operacional de uma estudante é uma decisão de implantação que deverá ser reavaliada à luz da qualidade anatômica e não apenas da velocidade, especialmente porque a seleção da combinação operacional observou o desempenho no teste.

A Figura 6 resume o desenho metodológico da destilação. Os professores permanecem congelados durante a formação dos alvos; as combinações são avaliadas separadamente, e a estudante recebe tanto a máscara manual quanto a média das probabilidades dos professores. A figura representa o fluxo de treinamento, não uma execução simultânea dos professores na inferência da aplicação.

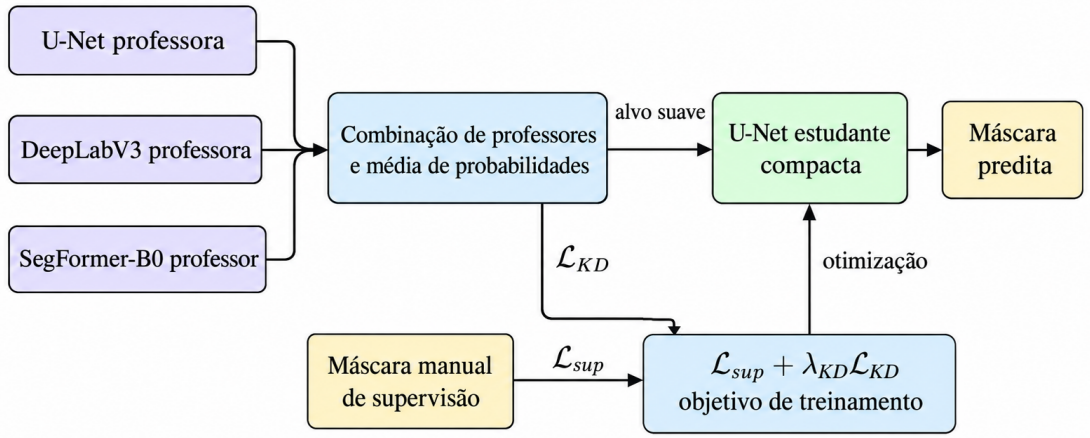


Figura 6. Fluxo metodológico da destilação multi-professor. As combinações de U-Net, DeepLabV3 e SegFormer-B0 geram alvos suaves; a estudante é treinada combinando essa informação com a máscara manual.

A Figura 6 distingue os professores, empregados exclusivamente na preparação dos alvos suaves, da U-Net estudante, utilizada na inferência. As combinações representam experimentos alternativos de treinamento, e não a execução obrigatória dos três professores ao mesmo tempo. A supervisão manual permanece presente em todas as configurações destiladas; a destilação da cápsula e a destilação intrarrenal são realizadas em treinamentos distintos, com máscaras e saídas anatômicas específicas.

3.6.1. Topologia das estudantes operacionais

As duas estudantes operacionais compartilham a topologia U-Net, mas atendem a saídas anatômicas diferentes. A Figura 7 representa essa distinção: a estudante da cápsula recebe três canais e produz uma máscara binária, enquanto a estudante intrarrenal recebe a imagem da ROI, a ROI mascarada e a máscara renal, produzindo quatro classes. Os professores são utilizados somente durante o treinamento; na inferência da aplicação, apenas as estudantes são carregadas.

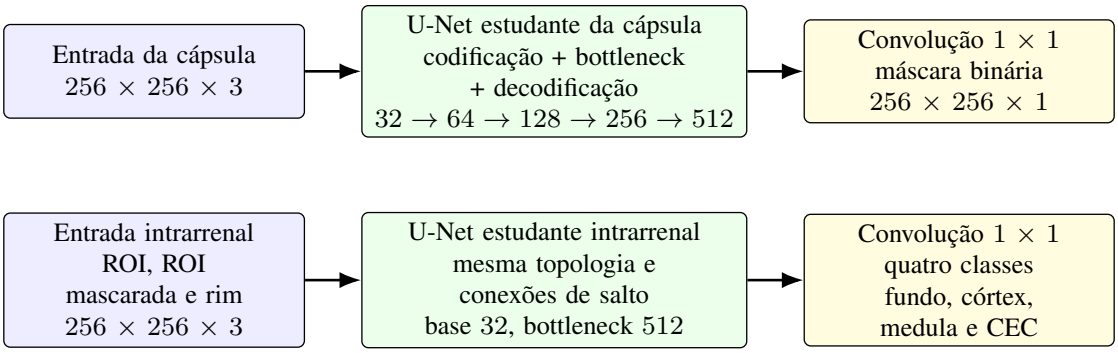


Figura 7. Arquiteturas das estudantes destiladas utilizadas na cascata. As duas redes têm a mesma topologia U-Net compacta, mas diferem na semântica dos canais de entrada e no número de classes de saída. Fonte: elaboração própria com base na implementação do projeto e em [Ronneberger et al. 2015].

A estudante da cápsula é uma U-Net convolucional binária com três canais de entrada e um canal de saída. Sua arquitetura utiliza quatro blocos de codificação com 32, 64, 128 e 256 canais, um *bottleneck* com 512 canais e quatro blocos de decodificação com convoluções transpostas e conexões de salto. Cada bloco `DoubleConv` contém duas convoluções 3×3, normalização em lote e ReLU; a saída é produzida por uma convolução 1×1. Em comparação, a U-Net professora utiliza a mesma topologia com 64 canais de base, enquanto a DeepLabV3 professora utiliza backbone ResNet-50 e ASPP com convoluções atrous. A estudante intrarrenal reutiliza os mesmos blocos e canais de base, mas termina com quatro logits para fundo, córtex, medula e CEC. Assim, a destilação não combina as arquiteturas em uma rede híbrida: transfere para a U-Net menor as probabilidades médias produzidas pelos dois professores.

3.7. Segmentação intrarrenal e propagação de erro

A análise interna prediz quatro classes: fundo, córtex, medula e CEC. A U-Net multiclasse e a DeepLabV3 multiclasse recebem, no fluxo consolidado, três canais correspondentes à ROI em tons de cinza, à ROI com o exterior do rim mascarado e à máscara de cápsula. O treinamento da U-Net documentado utiliza imagens de 256 por 256 pixels, AdamW, taxa inicial de 10^{-4} e perda de entropia cruzada multiclasse combinada com Dice. Na reavaliação corrigida, o conjunto foi agrupado por identificador de exame e o recorte da ROI foi aplicado antes do redimensionamento, reproduzindo o fluxo de produção. A avaliação reporta Dice e IoU por estrutura, além das médias sobre as classes de primeiro plano.

Para a implantação, foi treinada uma segunda estudante destilada, agora multiclasse e específica da etapa intrarrenal, com 234 imagens para treino, 50 para validação e 51 para teste independente no split agrupado. Ela utiliza 32 canais de base e combina a supervisão manual com a média das probabilidades produzidas pela U-Net

e pela DeepLabV3 intrarrenais, com temperatura $T = 2$ e peso de destilação $0{,}5$. Os professores são necessários apenas para formar os alvos suaves durante o treinamento; na inferência da cascata, somente a estudante é carregada.

Duas séries independentes de anotações do `kidneyUS` permitem calcular concordância interobservador por estrutura. Esse resultado serve para contextualizar ambiguidades da referência, sem estabelecer que a rede superou um humano: as comparações humano–humano e modelo–anotador possuem pares e desenhos distintos.

A dependência entre estágios é investigada em um experimento de estabilidade: o segmentador especializado de medula é aplicado inicialmente com ROI definida pela cápsula manual e depois com ROI produzida pelo modelo renal. A mudança na máscara e em medidas de intensidade permite observar a sensibilidade da etapa interna a erros da primeira. Trata-se de um experimento específico de medula e não substitui a avaliação completa da cascata multiclasse em novos dados.

3.8. Pseudo-expansão controlada da medula

DeepLabV3 e MedullaROIUNet produzem candidatos independentes de máscara de medula. A seleção automática combina concordância e restrições geométricas; um experimento acrescentou 342 pseudomáscaras às 236 imagens de treino manual, totalizando 578 exemplos. As 50 imagens de validação e as 50 de teste permaneceram manuais. A comparação resultante examina o efeito desse conjunto específico de pseudorrótulos; não mede o efeito de uma curadoria humana completa nem garante equivalência entre conjuntos de tamanhos diferentes.

3.9. Curadoria Web: implementação e fluxo de revisão humana

Como artefato computacional desta pesquisa, foi desenvolvida a plataforma *Curadoria Web*, implementada no diretório `curadoria_web/` do repositório. Seu objetivo é integrar a inspeção de imagens ultrassonográficas, a conferência das predições anatômicas e a revisão humana em um mesmo ambiente. A arquitetura separa o servidor de aplicação em Python, responsável pelas operações sobre casos, máscaras e persistência, da interface desenvolvida com HTML, CSS e JavaScript. O sistema utiliza um manifesto de casos para carregar as imagens e suas versões de máscaras e mantém em banco SQLite os registros da curadoria.

O fluxo de trabalho começa com a identificação do revisor e a seleção de um caso na fila. A tela permite filtrar a origem das anotações e o estado da revisão, consultar as informações do modelo e sobrepor ou ocultar individualmente as camadas de rim, córtex, medula e complexo ecogênico central. O revisor pode classificar cada estrutura como aceita, a corrigir, rejeitada ou indisponível. Quando necessária, a correção pode ser realizada por polígono, pincel ou borracha; as operações permitem substituir, adicionar ou remover áreas da máscara. As edições são registradas sem sobrescrever a predição original, de modo que a máscara revisada possa ser distinguida da máscara proposta pelo modelo.

A Figura 8 apresenta a organização do ambiente. As Figuras 9 e 10 apresentam, respectivamente, a inspeção ampliada de um exame e a ferramenta utilizada para preparar uma correção manual.

A Figura 8 documenta a disposição da fila de curadoria, a identificação do revisor e os controles disponíveis na interface.

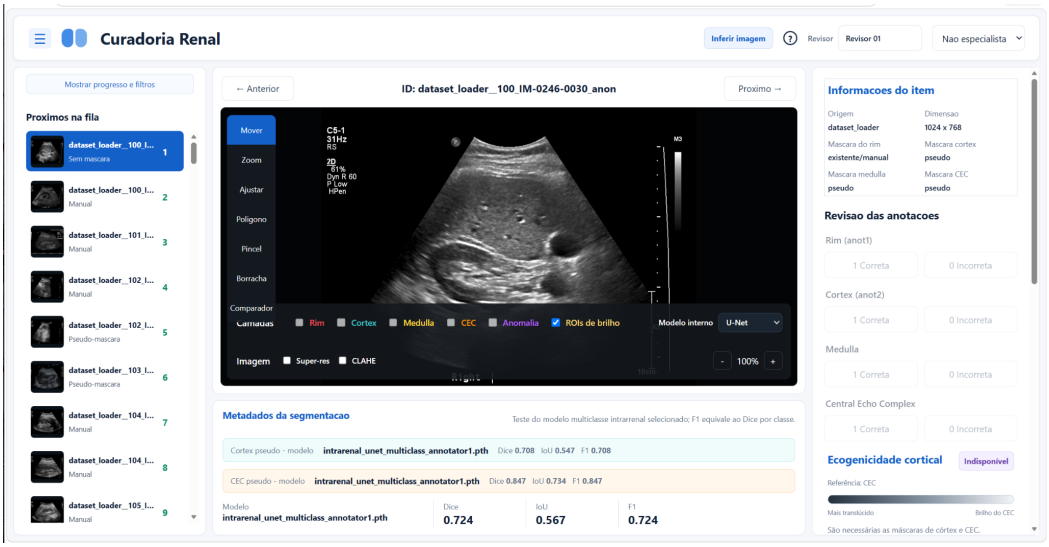


Figura 8. Visão geral da interface de Curadoria Web: fila de imagens à esquerda, visualizador de ultrassonografia renal ao centro e, à direita, metadados dos modelos e controles de revisão das anotações. O painel de progresso e filtros está recolhido.
Fonte: elaboração própria (captura de tela do sistema desenvolvido).

A visão geral reúne a fila de casos, o visualizador e os controles de revisão em uma única tela. Os metadados do modelo e o estado da curadoria ficam associados ao caso selecionado, enquanto o painel de progresso e os filtros podem permanecer recolhidos durante a inspeção.

A Figura 9 apresenta a visualização ampliada do mesmo caso, destinada ao exame da imagem renal sem distrações dos painéis laterais.

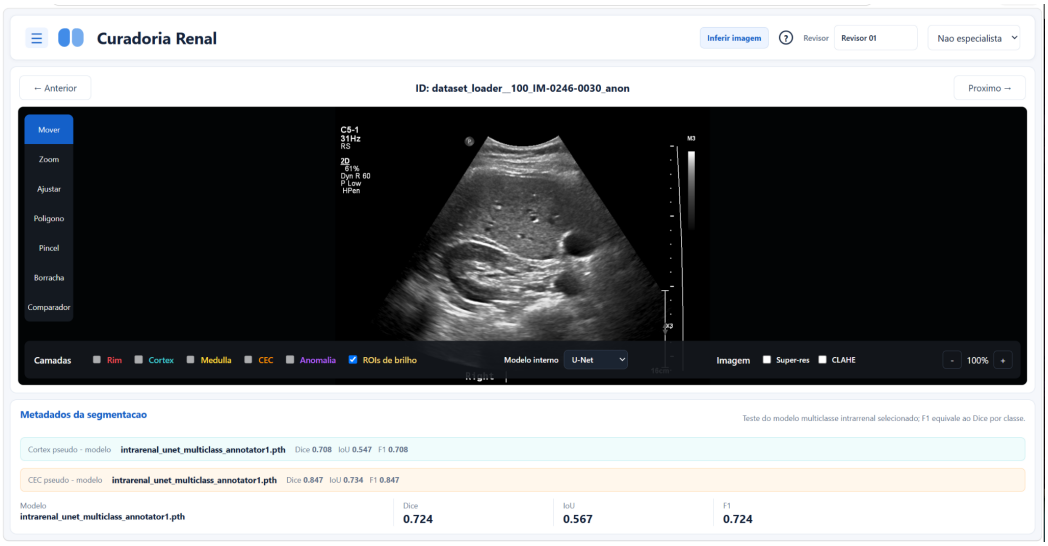


Figura 9. Visualização ampliada de uma ultrassonografia renal na Curadoria Web: área de inspeção do exame, ferramentas de navegação e controles das camadas anatômicas. As sobreposições das máscaras estão desativadas nesta captura.
Fonte: elaboração própria (captura de tela do sistema desenvolvido).

Na captura ampliada, as máscaras estão desativadas; na aplicação, elas podem ser habilitadas individualmente para comparar rim, córtex, medula e CEC com a imagem

original.

A Figura 10 apresenta a tela de configuração de uma edição manual com a ferramenta de pincel.

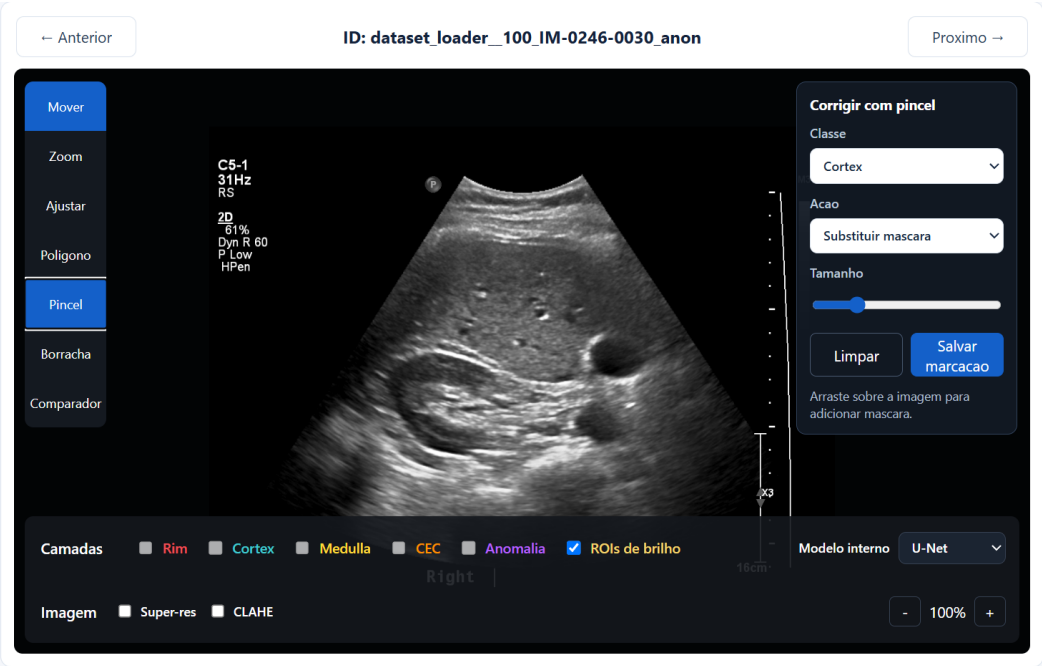


Figura 10. Tela de correção manual de máscaras na Curadoria Web: ferramenta pincel selecionada para substituir a máscara da classe córtex. A imagem documenta a configuração da edição, não uma correção concluída.
Fonte: elaboração própria (captura de tela do sistema desenvolvido).

A tela mostra a seleção da classe e da operação, mas não demonstra, isoladamente, uma máscara já alterada ou uma operação de salvamento concluída. A persistência e o histórico são propriedades verificáveis na implementação.

O módulo de inferência recebe uma nova imagem, executa a U-Net estudante de cápsula alinhada ao domínio (`capsule_from_regions_grouped_student_unet_deeplab.pth`), recorta a ROI renal, aplica a U-Net estudante intrarrenal destilada (`intrarenal_grouped_roi_student_unet_deeplab.pth`) e reconstrói máscaras no espaço da imagem. O mesmo checkpoint de cápsula é utilizado pelo construtor de pseudomáscaras do MONAI. Em seguida, calcula descritores de ecogenicidade quando as regiões necessárias estão disponíveis. As saídas são armazenadas separadamente e não ingressam automaticamente na base de treino, prevenindo incorporação silenciosa de previsões não revisadas.

3.10. Mensuração quantitativa de ecogenicidade

As previsões podem utilizar CLAHE, mas as estatísticas de brilho são calculadas na imagem B-mode original preservada pelo fluxo, antes desse realce. Seja μ_C a intensidade média cortical e μ_{CEC} a intensidade média do CEC. Para denominadores estritamente positivos, definem-se a razão e o contraste normalizado:

$$R_{C/CEC} = 100\frac{\mu_C}{\mu_{CEC}}, \qquad CN_{CEC-C} = 100\frac{\mu_{CEC} - \mu_C}{\mu_{CEC} + \mu_C}. \tag{9}$$

A diferença absoluta de intensidade é $D_{CEC-C} = \mu_{CEC} - \mu_C$. Também são registrados mediana, intervalo interquartil (IQR), tamanho das regiões e indicadores de saturação. Quando uma máscara é inexistente ou uma medida é matematicamente indefinida, o sistema deve registrar indisponibilidade, em vez de criar uma estimativa.

Como médias de regiões extensas podem ser sensíveis a bordas, heterogeneidade e profundidade, emprega-se adicionalmente um protocolo de ROIs pareadas. As máscaras de córtex e CEC são erodidas por um elemento estruturante de 5×5 pixels; a área é organizada em três estratos verticais e o algoritmo procura até um par de discos válidos por estrato. Os discos têm áreas iguais e profundidades verticais aproximadas. Para cada par i, calculam-se

$$R_i = 100\frac{\mu_{C,i}}{\mu_{CEC,i}}, \qquad D_i = \mu_{CEC,i} - \mu_{C,i}. \tag{10}$$

A mediana dos R_i é a medida exploratória principal e o IQR descreve sua dispersão. O revisor pode ajustar as posições e conservar a versão revisada. A coordenada vertical funciona apenas como aproximação operacional de profundidade; não corrige completamente ganho temporal, atenuação, compressão ou diferenças entre equipamentos. O protocolo ainda requer análise de sensibilidade e repetibilidade, não sendo interpretado como biomarcador clínico validado.

A Figura 11 apresenta o comparador interativo de duas ROIs circulares posicionadas manualmente sobre as máscaras anatômicas.



Figura 11. Comparador de ecogenicidade da Curadoria Web: seleção manual de ROIs sobre máscaras anatômicas e cálculo da razão de brilho CEC (A)/córtex (B) para o par selecionado, usando a imagem original sem CLAHE. Essa razão local não corresponde ao indicador global córtex/CEC nem constitui diagnóstico.
Fonte: elaboração própria (captura de tela do sistema desenvolvido).

No exemplo, o CEC é selecionado como região A e o córtex como região B; por isso, a razão exibida é $100\,\mu_{CEC}/\mu_C$, inversa à razão global $R_{C/CEC}$ definida na Equação 9. Os indicadores não devem ser comparados sem considerar a ordem das regiões, e o exemplo interativo de um par não substitui a mediana do protocolo automático de até três pares.

3.11. Assistente multimodal: desenho do estudo piloto

O assistente recebe uma imagem B-mode, sobreposições de máscaras e descritores já produzidos pelo *pipeline*. A avaliação realizada é demonstrativa: um caso principal foi submetido ao Qwen2.5-VL-3B-Instruct-AWQ local e a um assistente multimodal externo, com a mesma pergunta e as mesmas evidências declaradas; outro caso ilustra o uso da interface. O objetivo foi inspecionar se as respostas fazem referência às regiões e aos valores apresentados e se registram corretamente a incerteza, não estabelecer sensibilidade ou especificidade clínica.

Os registros precisam conservar o prompt integral, a imagem efetivamente enviada, as versões das máscaras, a identificação técnica verificável do modelo externo, os parâmetros de inferência e a resposta sem edição. A identificação comercial anotada originalmente para o modelo externo não comprova, por si só, o identificador de checkpoint ou versão. Além disso, as máscaras do exemplo principal foram geradas por checkpoints anteriores indicados na legenda correspondente, de modo que esse piloto não serve de validação independente da cascata destilada operacional. Sem referência especializada dos achados e com amostra tão pequena, a comparação limita-se a observações qualitativas.

4. Resultados

Os resultados são apresentados por tarefa e pela ordem de dependência da cascata: delimitação externa, triagem de imagens, destilação, estruturas internas e avaliação integrada. Comparações entre protocolos independentes são indicadas como descritivas, não como medições pareadas.

4.1. Segmentação da cápsula renal

A Tabela 3 apresenta os resultados da segmentação da cápsula no teste manual deduplicado, comum às quatro arquiteturas comparadas.

As taxas de FPS dessa tabela pertencem ao benchmark original, que inclui carregamento dos lotes, transferência para a GPU, pós-processamento e cálculo das métricas. Para separar o custo da rede desses componentes, a subseção posterior apresenta um benchmark controlado de *forward* com protocolo comum à estudante e ao SegFormer.

Tabela 3. Segmentação da cápsula em 70 imagens de teste manual deduplicado do `kidneyUS`.

Modelo	Dice	IoU	Precisão	Recall	FPS
U-Net	**0,9290**	**0,8722**	**0,9236**	**0,9440**	18,11
SegFormer-B0	0,9223	0,8598	0,9117	0,9426	**31,34**
DeepLabV3 R50	0,9203	0,8606	0,9219	0,9338	22,26
UNet++	0,9099	0,8419	0,8910	0,9419	16,57

A U-Net obteve o maior Dice ($0{,}9290$), IoU ($0{,}8722$), precisão ($0{,}9236$) e *recall* ($0{,}9440$) entre as configurações comparadas. O SegFormer-B0 alcançou a maior taxa de inferência ($31{,}34$ FPS), em contraste com $18{,}11$ FPS da U-Net. O ganho de sobreposição da U-Net em relação ao SegFormer foi de $0{,}0067$ em Dice nesse teste; sem intervalo de confiança por exame ou comparação pareada de diferenças, não se deve converter essa distância numérica em alegação de superioridade estatística.

A escolha inicial da U-Net para localizar a ROI renal baseou-se no desempenho observado e no papel crítico da máscara externa. Após a destilação, a aplicação utiliza a

U-Net estudante descrita na subseção seguinte; essa mudança não implica que o modelo apresente a mesma qualidade em imagens externas. A diversidade de qualidade visual exige análise de erros e validação específica para novas fontes.

A Figura 12 apresenta um exemplo qualitativo em que as condições de aquisição favorecem a delimitação; a imagem não substitui a avaliação agregada da Tabela 3.

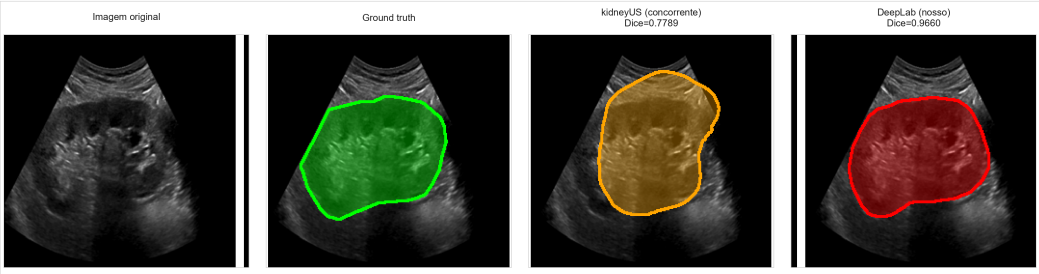


Figura 12. Exemplo qualitativo de segmentação em imagem com condições favoráveis de delimitação renal. A inspeção visual complementa, mas não substitui, as métricas agregadas.

Na imagem apresentada, o contorno previsto acompanha visualmente a região renal em condições de contraste favoráveis. Esse exemplo não permite inferir o comportamento do modelo em imagens com sombras, baixo contraste ou limites ambíguos.

4.2. Consenso entre modelos e imagens externas

Na calibração com referência manual, o consenso U-Net–DeepLabV3 apresentou média de $0{,}9416$, mediana de $0{,}9627$ e correlação documentada de $0{,}840$ com o menor Dice frente à anotação manual. A direção dessa associação sugere utilidade para triagem, mas concordância entre modelos não pode ser tomada como probabilidade de correção. Para avaliar a implantação da estudante, a Tabela 4 compara a cobertura operacional no mesmo lote de 4.479 imagens externas do MONAI. Como não há máscaras manuais externas consolidadas para esse lote, esses números expressam a capacidade de produzir uma proposta não vazia, e não a acurácia anatômica.

Tabela 4. Cobertura operacional de pseudomáscaras no lote externo do MONAI.

Situação	Pseudomáscaras MONAI não vazias	Imagens sem máscara
Antes	3.534 de 4.479	945
Modelo destilado	3.707 de 4.479	772
Diferença	**+173 imagens**	**-173 imagens**

O modelo destilado aumentou a cobertura de propostas não vazias de 78,9% para 82,8%, correspondendo a 173 imagens adicionais processadas com uma máscara candidata. Esse resultado demonstra o funcionamento operacional da estudante no fluxo de geração de pseudomáscaras e sua integração ao pipeline. Entretanto, não demonstra, isoladamente, melhora da qualidade anatômica: essa questão exige comparação com referências manuais, análise por imagem e revisão especializada.

A Figura 13 ilustra um caso em que a discordância entre modelos justifica a inspeção humana.

O caso ilustra a função do consenso como mecanismo de triagem: a diferença entre as máscaras indica a necessidade de inspeção, mas a concordância entre modelos

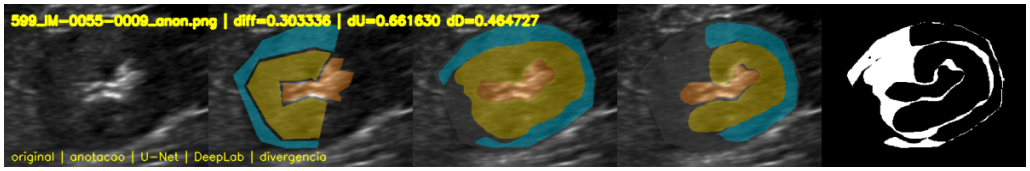


Figura 13. Exemplo de divergência entre predições de U-Net e DeepLabV3. Discordância orienta inspeção humana, mas concordância também não certifica o contorno renal.

também não constitui prova de correção anatômica.

4.3. Destilação da cápsula e custo computacional

Como experimento piloto inicial do caminho de destilação, foi treinada uma U-Net estudante com 32 canais de base, usando 328 imagens manuais para treino, 70 para validação e 70 para teste independente. A estudante combinou a perda supervisionada da máscara manual com a perda de destilação das probabilidades médias da U-Net e da DeepLabV3, com temperatura $T = 2$ e peso de destilação $0{,}5$. A seleção do checkpoint ocorreu na validação; o teste foi consultado somente ao final.

Tabela 5. Piloto inicial da destilação de conhecimento no teste manual independente; a seleção operacional posterior é apresentada na matriz de combinações de professores.

Modelo	Dice	IoU
U-Net professora	0,9302	0,8738
DeepLabV3 professora	0,9182	0,8587
U-Net estudante destilada	0,8847	0,7932

Os valores de $0{,}8847$ e $0{,}9078$ não correspondem à mesma execução. O primeiro pertence ao piloto inicial, executado pelo script `train_distilled_unet.py`, com limiar selecionado de $0{,}45$ e tempo registrado de 175,1 s. O segundo pertence à matriz posterior de combinações, executada pelo script `train_distillation_combinations.py`, com limiar $0{,}60$ e tempo de 168,2 s. Embora os dois experimentos usem a divisão nominal de 328/70/70 imagens, são execuções distintas e não devem ser tratados como replicações diretas.

O resultado confirma a execução do protocolo, mas não demonstra superioridade da estudante: nesta primeira configuração, seu desempenho ficou abaixo dos dois professores. Esse checkpoint do piloto não foi adotado como modelo operacional final; o piloto foi sucedido pela matriz posterior de combinações, que orientou a seleção operacional exploratória da estudante U-Net–DeepLabV3. A motivação de implantação foi concentrar o conhecimento dos professores em uma única rede e reduzir o custo de memória em relação a mantê-los simultaneamente na inferência. Essa é uma decisão operacional, não uma alegação de superioridade estatística; a qualidade da estudante deve continuar sendo monitorada e comparada com os professores em avaliações futuras.

4.3.1. Parâmetros, velocidade e matriz de professores

O treinamento foi realizado com imagens de 256×256 pixels, lote 16, AdamW, taxa de aprendizagem 10^{-4}, decaimento 10^{-5}, aumento de dados e CLAHE no treino. A função objetivo combinou BCE+Dice supervisionada pela máscara manual, com peso 1,0, e a

perda de destilação, com peso 0,5 e temperatura $T = 2$. Foram executadas 12 épocas, com seleção pela validação e semente 42; o treinamento levou 168,2 s na RTX 3050 de 8 GB. O limiar salvo para a aplicação é 0,60. A estudante possui 7.765.985 parâmetros e seu checkpoint ocupa 29,69 MiB; os checkpoints da U-Net e da DeepLabV3 professoras ocupam, respectivamente, 118,51 MiB e 160,56 MiB.

A Tabela 6 compara o custo de uma passagem direta pela rede. O protocolo utilizou a mesma RTX 3050, imagens de 256×256, lote 8, sincronização CUDA e medição somente do *forward*, sem incluir carregamento do modelo, leitura do disco ou cálculo das métricas. Foram processadas 73 imagens porque o benchmark de velocidade utilizou o diretório de teste legado 'capsule_annotator_1', não deduplicado; a avaliação de acurácia da Tabela 3 utiliza o diretório deduplicado com 70 imagens. Assim, as 73 imagens caracterizam apenas o protocolo de latência e não devem ser confundidas com o conjunto independente usado para Dice e IoU. O SegFormer-B0 foi mantido como referência porque havia apresentado a maior velocidade entre os comparadores.

Tabela 6. Custo controlado de inferência na RTX 3050; uma única passagem direta, sem pré-processamento e sem métricas.

Modelo	Parâmetros	Pesos (MiB)	ms/imagem	FPS
U-Net professora	31.043.521	118,51	18,19	54,97
DeepLabV3 professora	41.998.934	160,56	15,23	65,65
U-Net estudante	7.765.985	29,69	6,51	153,51
SegFormer-B0	3.714.401	14,25	2,74	365,61

O resultado mostra que a estudante reduz substancialmente o custo em relação aos professores: seu tempo por imagem é aproximadamente 64% menor que o da U-Net professora e 57% menor que o da DeepLabV3. O SegFormer-B0 continua sendo o mais rápido no protocolo controlado, com 2,74 ms por imagem; portanto, a adoção da estudante não é justificada por velocidade máxima, mas pelo compromisso entre uma única arquitetura convolucional, menor custo que os professores e a transferência do consenso usado no treinamento. O modelo escolhido permanece dependente de revisão humana e não produz diagnóstico clínico.

As cinco configurações da matriz produzem a mesma arquitetura de estudante, com 32 canais de base; portanto, o número de professores utilizados durante o treino não aumenta o custo de inferência da aplicação. A diferença entre elas está no alvo suave usado durante a destilação. A Tabela 7 apresenta a comparação realizada com o mesmo particionamento manual. Os *checkpoints* e limiares de cada execução foram selecionados pela validação. O conjunto de teste independente foi apresentado para comparação final e não foi usado para ajustar os pesos ou hiperparâmetros de cada execução; entretanto, foi observado posteriormente na escolha exploratória da combinação operacional.

Tabela 7. Comparação das combinações de professores na destilação da U-Net estudante.

Professores	Dice val.	IoU val.	Dice teste	IoU teste
Nenhum (baseline)	0,9108	0,8363	0,8978	0,8145
U-Net + DeepLabV3	0,9093	0,8337	**0,9078**	**0,8312**
U-Net + SegFormer-B0	0,9027	0,8226	0,8965	0,8125
DeepLabV3 + SegFormer-B0	**0,9109**	**0,8363**	0,8847	0,7933
U-Net + DeepLabV3 + SegFormer-B0	0,9101	0,8351	0,9078	0,8311

Na validação, a combinação DeepLabV3–SegFormer-B0 apresentou o maior Dice ($0{,}9109$), enquanto U-Net–DeepLabV3 obteve $0{,}9093$. A combinação

U-Net–DeepLabV3 foi escolhida operacionalmente porque apresentou o maior Dice (0,9078) e IoU (0,8312) no teste observado na matriz. Essa decisão utiliza o teste para selecionar a combinação e, portanto, não permite tratar esse teste como uma estimativa completamente independente de desempenho da configuração escolhida. Em relação ao baseline sem destilação, a estudante U-Net–DeepLabV3 aumentou o Dice de 0,8978 para 0,9078 e o IoU de 0,8145 para 0,8312 nesse protocolo, diferenças descritivas que ainda precisam de repetição e intervalos de confiança. O trio de professores ficou praticamente empatado (0,9078 de Dice), mostrando que adicionar um terceiro professor não produziu ganho mensurável. A média de probabilidades pode diluir informação complementar ou introduzir alvos suaves conflitantes; assim, mais professores não implicam necessariamente melhor transferência. O SegFormer-B0 continua sendo o modelo mais rápido, com 2,74 ms por imagem; entre as estudantes, o tempo permanece aproximadamente igual porque todas executam a mesma U-Net e os professores não são carregados durante a inferência.

4.4. Segmentação e destilação das estruturas intrarrenais

A Tabela 8 apresenta o desempenho dos modelos no teste manual de 50 imagens, discriminado por estrutura intrarrenal.

Tabela 8. Desempenho intrarrenal no teste manual de 50 imagens; Dice por estrutura e médias sobre classes de primeiro plano.

Modelo	Córtex	Medula	CEC	Dice médio	IoU médio
U-Net	**0,7075**	**0,7237**	0,8469	**0,7594**	**0,6163**
DeepLabV3 R50	0,6822	0,7156	**0,8497**	0,7492	0,6045
U-Net estudante destilada	0,6959	0,7076	0,8467	0,7501	0,6051

A U-Net multiclasse obteve Dice médio 0,7594 e os maiores Dice de córtex (0,7075) e medula (0,7237); a DeepLabV3 foi ligeiramente superior no CEC (0,8497 contra 0,8469). A estudante destilada alcançou Dice médio 0,7501 e IoU médio 0,6051, com desempenho próximo aos professores neste teste. Em todos os modelos, o CEC apresentou sobreposição mais alta do que córtex e medula. O resultado reforça que a tarefa interna deve ser analisada por estrutura e não apenas por uma média geral.

4.5. Reavaliação da cascata e propagação de erro

Após a auditoria do protocolo, a cápsula e as estruturas intrarrenais foram retreinadas no mesmo domínio das imagens anotadas intrarrenais. O split foi agrupado por identificador de exame e a estudante da cápsula foi avaliada antes de fornecer sua ROI à estudante multiclasse. Essa avaliação não reutiliza a ROI manual no caminho principal e, portanto, mede a propagação de erro entre os estágios.

Tabela 9. Revalidação da cascata destilada no teste agrupado por exame.

Configuração	Dice	IoU
Estudante da cápsula	0,9584	—
Estudante intrarrenal com ROI de referência	0,7395	0,6081
Estudante intrarrenal com ROI prevista	0,7210	0,5847

A estudante da cápsula obteve Dice médio de 0,9584 no conjunto de 51 imagens. Na etapa intrarrenal, a substituição da ROI manual pela ROI prevista reduziu o Dice médio foreground de 0,7395 para 0,7210, uma diferença absoluta de 0,0185. O resultado confirma que a estudante intrarrenal não deve ser avaliada somente com ROI de referência

quando o objetivo é descrever a aplicação. Ao mesmo tempo, a avaliação permanece exploratória: a combinação U-Net–DeepLabV3 foi mantida por decisão operacional derivada de experimentos anteriores, e não por uma seleção independente deste novo teste.

4.6. Variabilidade da referência humana

A Tabela 10 apresenta a concordância Dice entre os dois anotadores, organizada por estrutura e pelo número de imagens comuns disponíveis.

Tabela 10. Concordância Dice entre os dois anotadores do `kidneyUS`, nos conjuntos disponíveis por estrutura.

Estrutura	Imagens comuns	Dice
Cápsula	486	0,9461
Córtex	323	0,5961
Medula	325	0,6936
CEC	468	0,8688

A cápsula apresentou concordância mais elevada ($0{,}9461$), ao passo que córtex ($0{,}5961$) e medula ($0{,}6936$) concentraram divergências maiores. As quantidades de imagens comuns também diferem por classe; por isso, a tabela não representa uma avaliação pareada única de quatro estruturas em exatamente os mesmos casos. A menor concordância humana ajuda a interpretar a dificuldade de obter referências internas estáveis, sem constituir prova de que os modelos alcançaram desempenho equivalente ao de especialistas.

4.7. Medula: estabilidade e pseudo-expansão

Uma heurística inicial para localizar regiões escuras apresentou Dice médio $0{,}3291$ frente à referência do primeiro anotador. No experimento supervisionado específico de medula, a DeepLabV3 atingiu Dice de teste $0{,}7528$ e a MedullaROIUNet, $0{,}7326$. Em avaliação específica da estabilidade da cascata, a troca da ROI de cápsula manual pela cápsula prevista alterou o Dice global da DeepLabV3 de $0{,}7626$ para $0{,}7610$, uma diferença absoluta de $0{,}0016$. Nesse protocolo, a intensidade média estimada na medula teve correlação de $0{,}9508$ entre os dois cenários. Essa correlação descreve o conjunto avaliado; não descarta erros individuais nem certifica estabilidade de outras medidas.

A Tabela 11 apresenta a comparação da pseudo-expansão com validação e teste manuais preservados.

Tabela 11. Experimento de pseudo-expansão do treino da medula, com validação e teste manuais preservados.

Configuração	Treino	Val. Dice	Teste Dice	IoU teste
Manual	236	0,7235	**0,7528**	**0,6035**
Manual + 342 pseudo	578	**0,7424**	0,7523	0,6030

A expansão elevou numericamente o Dice de validação de $0{,}7235$ para $0{,}7424$, enquanto o Dice de teste passou de $0{,}7528$ para $0{,}7523$. Essa diferença de $-0{,}0005$ no teste não demonstra benefício de generalização; tampouco permite afirmar equivalência estatística ou inutilidade da pseudo-expansão. O achado sinaliza a necessidade de estudar qualidade do rótulo, composição dos casos e variabilidade entre execuções antes de incorporar automaticamente novas máscaras ao treino.

4.8. Plataforma Web de Curadoria

Além dos experimentos de segmentação, a pesquisa produziu uma aplicação Web funcional para inspeção, edição e documentação de máscaras de ultrassonografia renal. As Figuras 8–10 apresentam a interface de triagem de casos, a visualização ampliada e os controles de correção de estruturas anatômicas. A Figura 11 registra a integração entre máscaras intrarrenais e a comparação visual de duas regiões de interesse de ecogenicidade. A aplicação também disponibiliza um fluxo de inferência para novas imagens, separado da inclusão automática de dados na base de treinamento.

O produto implementado demonstra a viabilidade técnica de reunir predição automática, conferência individual por estrutura, edição das máscaras e registro de decisões em uma infraestrutura local auditável. O histórico de alterações e a separação entre máscaras originais e corrigidas são propriedades da implementação; não constituem, isoladamente, evidência de melhora na acurácia, de concordância interobservador ou de utilidade clínica. A mensuração desses aspectos integra o planejamento experimental subsequente.

4.9. Estudo exploratório do assistente multimodal

Para avaliar o comportamento do assistente como apoio à interpretação da imagem, e verificar sua integração com a Curadoria Web e as máscaras anatômicas, foi executado um estudo piloto com a imagem `kidneyus_capsule_test__122_IM-0144-0001_anon.png`. A inferência da cascata foi executada na RTX 3050 de 8 GB, com dispositivo CUDA, imagem de 1024×768 pixels e máscaras de rim, córtex, medula e CEC. O mesmo conjunto de evidências e a mesma sobreposição visual foram enviados ao Qwen2.5-VL-3B-Instruct-AWQ local e ao assistente multimodal externo. O recorte da cápsula foi delimitado por $\texttt{capsule_bbox} = (120, 159, 805, 742)$.

O piloto não foi desenhado para estabelecer um diagnóstico, mas para observar se os modelos conseguem utilizar as evidências fornecidas, localizar regiões anatômicas relevantes, relacionar métricas de ecogenicidade e expressar limitações. Esses comportamentos são tratados como apoio à triagem e à revisão especializada, não como decisão clínica autônoma.

A Figura 14 documenta visualmente o conjunto de evidências utilizado no piloto: a imagem B-mode original, cada máscara anatômica individual e a sobreposição conjunta das regiões segmentadas.

A composição mostra que as quatro máscaras estão no mesmo espaço da imagem original e correspondem às evidências disponibilizadas ao assistente. A máscara externa do rim foi produzida pela U-Net de cápsula; córtex, medula e CEC foram produzidos pela U-Net multiclasse intrarrenal. Portanto, as quatro camadas são predições automáticas do pipeline, e não anotações humanas independentes ou máscaras corrigidas pela Curadoria Web. A visualização facilita a inspeção da localização anatômica, mas não constitui anotação clínica independente nem confirma, por si só, a presença de artefatos ecogênicos.

A Tabela 12 resume a comparação descritiva. Como o estudo possui um único caso e não utiliza um gabarito independente para os achados multimodais, os critérios de resposta devem ser lidos como observações qualitativas dos pesquisadores, e não como métricas de desempenho.

Desfecho do piloto. Considerando os comportamentos observados, o desfecho operacional foi favorável à utilização do assistente como apoio à triagem baseada em

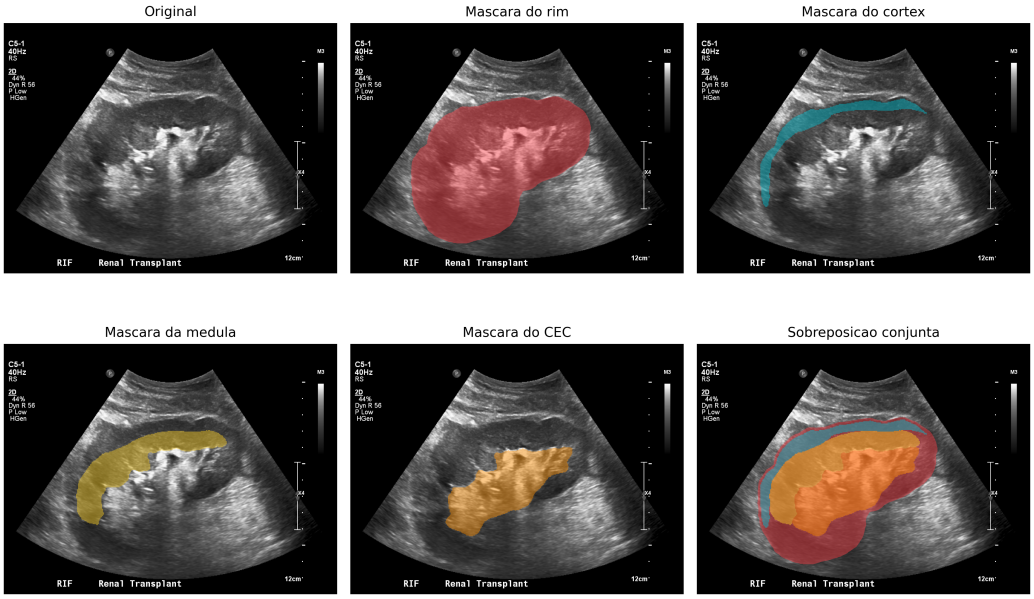


Figura 14. Evidências visuais do estudo piloto multimodal: imagem B-mode original, máscaras individuais de rim, córtex, medula e CEC e sobreposição conjunta. As máscaras individuais são apresentadas sobre a imagem para facilitar a localização de cada estrutura; as cores representam rim em vermelho, córtex em ciano, medula em amarelo e CEC em laranja. As máscaras foram geradas automaticamente pela cascata da Curadoria Web, com U-Net da cápsula (`models/kidneyus_capsule_unet.pth`) e U-Net multiclasse intrarrenal (`models/intrarenal_unet_multiclass_annotator1.pth`). Fonte: elaboração própria a partir da inferência registrada em `inferencias/infer_0141d6c60b3a`.

Tabela 12. Comparação qualitativa do estudo piloto multimodal ($N = 1$).

Critério	Qwen local	assistente multimodal externo
Evidências recebidas	Imagem, quatro máscaras e métricas	Mesma entrada
Região prioritária	Não delimitada claramente	Região central/CEC, faixa média
Separação CEC–foco	Parcial e genérica	Explicitamente cautelosa
Uso da ecogenicidade	Parcial; saída limitada pelo contexto	CEC 130,4; córtex 71,6; diferença 58,7
Resultado qualitativo	Localização menos explícita; rastreabilidade parcial	Localização mais explícita; rastreabilidade maior
Acurácia estatística	Não estimável ($N = 1$)	Não estimável ($N = 1$)

evidências: os dois modelos receberam a mesma imagem, as quatro máscaras e as métricas, mas o assistente multimodal externo produziu, neste caso, uma resposta mais explicitamente vinculada às regiões e aos valores fornecidos, enquanto a resposta do Qwen local exigiu maior mediação interpretativa. Essa diferença é uma observação qualitativa de um único caso, e não uma demonstração de superioridade geral.

O resultado não deve ser interpretado como acurácia clínica, pois o piloto possui apenas um caso e não dispõe de uma referência humana independente para presença, localização e natureza de um foco ecogênico. Portanto, a conclusão adequada é que a integração é tecnicamente viável e pode apoiar a organização da análise pelo especialista, mas ainda não demonstra detecção confiável de artefatos ecogênicos nem diagnóstico. A avaliação quantitativa requer uma amostra anotada por especialistas, com sensibilidade, especificidade, precisão, F1, concordância por região e taxa de afirmações não sustentadas.

A demonstração adicional com a interface é documentada no Apêndice A.

4.10. Síntese das evidências disponíveis

A Tabela 13 separa resultados em referência supervisionada de indicadores operacionais e componentes implementados ainda não avaliados experimentalmente. Essa separação é necessária porque o projeto reúne fases e bases com diferentes possibilidades de inferência.

Tabela 13. Situação dos principais componentes na qualificação e próximo requisito de validação.

Componente	Evidência apresentada	Limite ou teste pendente
Cápsula	Dice $0{,}9290$ em 70 imagens manuais deduplicadas	Incerteza por exame e teste externo anotado
Destilação da cápsula	Matriz de estudantes, parâmetros e latência; Dice observado $0{,}9078$	Reavaliar seleção em teste não consultado
Intrarrenal e cascata	Dice $0{,}7594$ (teste original) e $0{,}7210$ com ROI prevista (teste agrupado)	Erros por estrutura, exame e qualidade visual
Pseudomáscaras MONAI	3.707 propostas não vazias de 4.479 imagens	Correção anatômica por revisão especializada
Curadoria e ecogenicidade	Fluxos de edição e mensuração implementados	Estudo de revisão, repetibilidade e sensibilidade das ROIs
Assistente multimodal	Demonstração qualitativa em caso isolado	Gabarito dos achados e avaliação de amostra independente

Um checkpoint histórico de DeepLabV3 no `dataset_geral` registrou Dice de $0{,}9366$, mas esse resultado pertence a outro protocolo, não é uma replicação dos testes manuais deduplicados e não foi utilizado para selecionar uma estimativa consolidada de desempenho.

5. Discussão

5.1. O que a cascata demonstra sobre segmentação renal

A questão científica deste trabalho não se limita a identificar qual arquitetura produz o maior Dice isolado. A tarefa central é avaliar como uma delimitação externa condiciona a segmentação de córtex, medula e CEC e, subsequentemente, as medidas extraídas da imagem original. O benchmark da cápsula obteve Dice de $0{,}9290$ com U-Net em 70 imagens deduplicadas; o experimento intrarrenal original obteve Dice médio de $0{,}7594$ em outras 50 imagens. Esses valores são resultados de tarefas e amostras diferentes, não uma comparação pareada de dificuldade. Ainda assim, a discriminação das estruturas internas aparece como um problema que exige atenção própria, sobretudo nas interfaces córtico-medulares.

O experimento agrupado da cascata é mais diretamente informativo para o uso pretendido. Mantendo o mesmo teste de 51 imagens e a mesma estudante intrarrenal, substituir a ROI manual por uma ROI prevista reduziu o Dice de primeiro plano de $0{,}7395$ para $0{,}7210$. A diferença absoluta de $0{,}0185$ caracteriza propagação de erro entre estágios; ela não deve ser disfarçada por um bom resultado isolado da cápsula. Uma média modesta pode ainda concentrar falhas relevantes em imagens com sombras, baixo contraste ou recortes incompletos. Na etapa seguinte, é necessário medir o deslocamento das ROIs de córtex e CEC e o efeito correspondente sobre cada razão de ecogenicidade, em vez de supor que o Dice da cápsula seja um substituto da estabilidade dos descritores.

A concordância interobservador de $0{,}5961$ no córtex e $0{,}6936$ na medula oferece contexto adicional: fronteiras internas são discutíveis até entre anotações independentes. Contudo, o experimento humano–humano não utiliza necessariamente os mesmos casos dos testes dos modelos e não estabelece uma referência humana máxima universal. O caminho mais defensável envolve analisar erros por estrutura e exame, reportar discrepâncias para ambos os observadores quando houver pares elegíveis e registrar decisões de adjudicação.

5.2. Destilação: economia computacional e limites da seleção

A estudante da cápsula reduziu o arquivo de pesos e o tempo de *forward* em comparação com a U-Net professora; no ensaio controlado, foram registrados $6{,}51$ ms por imagem e $153{,}51$ FPS. Isso é evidência de redução de custo num protocolo específico, não garantia de igual ganho de latência no fluxo completo da aplicação. O SegFormer-B0 permaneceu mais rápido no mesmo ensaio, e sua inclusão impede concluir que a estudante seja o menor custo computacional possível entre as arquiteturas avaliadas.

A matriz de professores sugere benefício potencial da destilação frente ao controle sem KD: Dice de teste $0{,}9078$ para U-Net–DeepLabV3 contra $0{,}8978$ sem professores. Entretanto, a combinação operacional foi escolhida depois de observado o teste, enquanto outra combinação apresentou o maior Dice de validação. Essa sequência introduz viés de seleção e exige novo teste independente para qualquer alegação confirmatória. O primeiro piloto da mesma dupla nominal, com Dice $0{,}8847$, também reforça a importância de não tratar execuções com códigos, limiares e checkpoints distintos como uma trajetória de melhoria contínua. A proposta acadêmica mais forte não é anunciar um vencedor, mas explicitar o compromisso observado entre custo, fidelidade anatômica e reprodutibilidade.

5.3. Pseudorrótulos, curadoria e qualidade dos dados

No MONAI externo, a estudante operacional produziu 173 propostas não vazias adicionais sobre 4.479 imagens. É um aumento de cobertura de aproximadamente 3,9

pontos percentuais, porém sem referência manual externa não se conhece a proporção de máscaras anatomicamente corretas. De modo semelhante, a correlação entre consenso e menor Dice contra anotação manual sugere uma variável útil de priorização, não um certificado de aprovação. Esses indicadores só adquirem utilidade científica para seleção de dados quando associados a erros verificados por anotadores independentes.

O experimento de medula oferece um contraponto importante ao argumento de que ampliar a base automaticamente melhora a segmentação: adicionar 342 pseudomáscaras elevou o Dice de validação, mas o Dice de teste foi de $0{,}7528$ para $0{,}7523$. A diferença não identifica sua causa; pode refletir rótulos imperfeitos, redundância das imagens, mudança de distribuição ou variação do treinamento [Tajbakhsh et al. 2020, Su et al. 2024]. Sua contribuição é justificar a comparação futura entre três regimes controlados: treino apenas manual, treino manual com pseudorrótulos automáticos e treino manual com pseudorrótulos revisados.

Nesse cenário, a Curadoria Web transforma a procedência e as decisões de revisão em dados auditáveis. O sistema implementa aceitação, correção e rejeição, mas o benefício ainda é uma hipótese. Um experimento de revisão deve registrar por estrato de consenso a proporção de máscaras aceitas, o tipo de correção, a concordância entre revisores e o tempo de trabalho, mantendo um teste manual independente. Só assim será possível atribuir eventual ganho ao processo de curadoria, e não apenas ao maior número de exemplos de treinamento.

5.4. Ecogenicidade e evidência clínica

O cálculo de medidas na imagem B-mode original, separado do CLAHE empregado na inferência, evita que um realce destinado à rede seja confundido com variação física do tecido. A razão córtex–CEC, os pares de ROIs e as estatísticas robustas definem um procedimento explícito e auditável, mas escolhas como erosão, tamanho de disco, profundidade aproximada e posição do par podem alterar o valor obtido. Faltam medidas de repetibilidade intra/interobservador e uma análise de sensibilidade dessas escolhas. O próximo passo é verificar se a medida muda mais quando a máscara é corrigida ou quando o mesmo revisor reposiciona a ROI.

A literatura estabelece que ecogenicidade relativa pode ser estudada em contextos renais, mas a razão córtex–CEC aqui proposta não é automaticamente equivalente a comparações rim–fígado, rim–baço ou a exames com desfechos histopatológicos [Manley and O'Neill 2001, Moghazi et al. 2005, Beutler et al. 2024, Zhao et al. 2025, Athavale et al. 2021]. Sem uma coorte clínica pareada e controle de parâmetros de aquisição, não se pode interpretar o descritor como marcador validado de fibrose, IFTA ou doença renal crônica. O valor presente é produzir uma variável de imagem definida e rastreável, cuja validade poderá ser investigada em etapa posterior.

5.5. Posicionamento diante de trabalhos diretamente relacionados

A Tabela 14 apresenta uma comparação descritiva com a MAT-UNet de Zuo et al. [Zuo et al. 2025], que também aborda estruturas do `kidneyUS`. Ela não constitui experimento competitivo sob um mesmo protocolo de teste.

O resultado publicado da MAT-UNet é numericamente maior na cápsula, enquanto valores deste trabalho são maiores em algumas regiões internas. Essa diferença não define um ranking, pois divisões, anotadores, critérios de inclusão e agregação das métricas podem variar. De modo semelhante, MONAI Label já oferece

Tabela 14. Comparação descritiva do Dice com a MAT-UNet de Zuo et al. [Zuo et al. 2025]. Os resultados provêm de protocolos independentes e não constituem um ranking experimental.

Estrutura	MAT-UNet (2025)	U-Net deste trabalho
Cápsula	0,9383	0,9290
Córtex	0,5893	0,7075
Medula	0,6634	0,7237
CEC	0,8434	0,8469

anotação assistida por IA [Diaz-Pinto et al. 2024], e MK-Net já investiga destilação no `kidneyUS` [Chen et al. 2026]. Portanto, a originalidade reivindicada restringe-se à *integração examinável* de modelos, consenso para triagem, estudantes específicas, revisão versionada e medidas de ecogenicidade, não à invenção isolada desses componentes.

5.6. Síntese interpretativa

Os experimentos demonstram que a cascata pode ser executada e avaliada com referência manual, que a propagação de erro é mensurável e que uma estudante pode reduzir custo computacional. Ainda não demonstram que a revisão humana melhora o desempenho, que as pseudomáscaras externas são anatomicamente corretas ou que as medidas de ecogenicidade antecipam doença. Essa fronteira entre resultados medidos e hipóteses testáveis é central para a validade da contribuição.

6. Limitações e Ameaças à Validade

6.1. Validade interna e seleção de modelos

A separação entre treino, validação e teste foi aprimorada com deduplicação e agrupamento por exame/paciente, mas há protocolos históricos com conjuntos e pré-processamentos diferentes. Na matriz de destilação, a decisão sobre a combinação operacional consultou o desempenho do teste; mesmo sem ajuste dos pesos nesse conjunto, essa decisão compromete sua independência para comparar estratégias. Também faltam repetições sistemáticas com diferentes sementes e intervalos de confiança por unidade independente. O plano de mitigação é congelar manifestos, checkpoints, versões dos scripts e limiares antes de uma reavaliação cega por exame, usando o teste somente após a seleção final.

6.2. Validade de construção e referência anatômica

Dice e IoU medem sobreposição com máscaras de referência, não adequação para produzir medidas de intensidade ou localizar alterações clínicas. A discordância entre anotadores, sobretudo nas fronteiras de córtex e medula, pode modificar o valor de uma métrica sem mudança correspondente na anatomia subjacente. Confiança dos pixels, concordância entre modelos e número de máscaras não vazias possuem interpretações distintas da acurácia. É necessário avaliar erros por estrutura, dimensões e qualidade visual, além de registrar regras de tratamento de regiões ausentes e de versões corrigidas.

6.3. Validade externa e deslocamento de domínio

Os principais testes supervisionados usam o `kidneyUS`; as 4.479 imagens MONAI constituem um conjunto externo não anotado adequadamente para aferir Dice. Equipamento, operador, ganho, profundidade, compressão, qualidade de imagem e prevalência de dificuldades anatômicas podem deslocar a distribuição. Uma amostra

externa selecionada para anotação especializada, incluindo casos difíceis e uma seleção aleatória dos diferentes estratos de consenso, é necessária para estimar erro anatômico fora do domínio de treino. Casos escolhidos apenas por confiança alta superestimariam a qualidade do fluxo.

6.4. Validade operacional, clínica e multimodal

A Curadoria Web implementa o ciclo de revisão, mas ainda não existem medições controladas de tempo, taxa de correção, concordância ou benefício no retreinamento. As razões de ecogenicidade dependem de máscaras, ROIs e parâmetros de aquisição; faltam estudo de sensibilidade, repetibilidade e associação com dados clínicos pareados. Os exemplos do assistente multimodal têm caráter ilustrativo e não incluem gabarito independente dos achados; a versão exata do serviço externo também precisa de documentação para reprodução. Nenhum desses componentes é avaliado como diagnóstico de fibrose, IFTA ou doença renal crônica.

7. Continuidade da Dissertação

A continuidade deve converter os componentes implementados em hipóteses avaliáveis, priorizando a correção das fontes de viés identificadas na presente qualificação. A Tabela 15 relaciona cada eixo a uma comparação controlada e ao desfecho esperado. Os procedimentos descritos são **propostas de experimentos**, não resultados adicionais.

Tabela 15. Plano de validação proposto para a continuidade da dissertação.

Prioridade	Procedimento proposto	Desfecho principal
1. Protocolo final	Congelar dados, modelo e limiares por validação; teste independente agrupado por exame	Dice/IoU por classe e incerteza pareada
2. Revisão humana	Amostra estratificada por consenso e qualidade, com revisores independentes	Aceitação, correção, tempo e concordância
3. Efeito no treinamento	Comparar manual, manual + pseudo e manual + pseudo revisado sob mesmo teste	Ganho de segmentação atribuível à curadoria
4. Ecogenicidade	Perturbar máscaras/ROIs e repetir medidas por revisor na imagem original	Repetibilidade, erro e sensibilidade do descritor

7.1. Congelamento e reavaliação independente

Primeiro, serão unificados os manifestos por identificador de exame, com rastreabilidade de imagem, origem, versão da máscara, configuração do checkpoint e papel de cada amostra. A seleção de arquiteturas e limiares deverá ocorrer sem consulta ao teste final; múltiplas inicializações e intervalos de confiança agrupados por exame ou paciente serão usados para caracterizar a incerteza, conforme a disponibilidade de dados. Resultados históricos permanecerão identificados, sem mistura com o protocolo congelado.

7.2. Curadoria *human-in-the-loop* e estudo de impacto

A etapa seguinte propõe uma amostra para revisão estratificada por alto, médio e baixo consenso, origem e qualidade visual, incluindo também seleção aleatória para detectar erros nos casos aparentemente confiáveis. As máscaras automáticas e corrigidas serão versionadas; revisores independentes documentarão aceitação, correção, rejeição,

tempo e discordância. Para isolar o efeito da revisão, os três regimes de treinamento deverão manter arquitetura, testes, orçamento de amostras e critérios de seleção comparáveis. A hipótese será examinada pela diferença de desempenho, não presumida pela implementação da interface.

7.3. Estabilidade da cascata e de ecogenicidade

Em seguida, a avaliação ponta a ponta deverá quantificar o deslocamento das ROIs após variações na cápsula e nas máscaras internas. Serão comparadas imagens originais com máscaras manuais, automáticas e revisadas, alterando sistematicamente raio dos discos, erosão, profundidade aproximada e número de pares. O desfecho será a variabilidade dos descritores, mediante repetição de medições, diferenças pareadas e medidas de concordância apropriadas. Uma eventual investigação com eGFR, creatinina ou histopatologia dependerá de dados clínicos pareados, governança institucional e desenho específico; não integra a evidência atual.

7.4. Posição do assistente multimodal

O assistente permanecerá auxiliar à revisão, com prioridade inferior à validação anatômica e à estabilidade da ecogenicidade. Caso seja ampliado, o piloto exigirá gabarito de especialistas, perguntas e entradas padronizadas, identificação técnica dos modelos, registro de afirmações não sustentadas e avaliação por caso. Sem esse protocolo, novas demonstrações não serão tratadas como prova de acurácia clínica.

8. Conclusão

Este trabalho desenvolveu um pipeline rastreável para ultrassonografia renal que articula delimitação da cápsula, segmentação intrarrenal, consenso, destilação, curadoria humana e mensuração exploratória da ecogenicidade. Na avaliação supervisionada deduplicada, a U-Net da cápsula alcançou Dice $0{,}9290$ e IoU $0{,}8722$ em 70 imagens, enquanto a U-Net intrarrenal atingiu Dice médio $0{,}7594$ em outro teste manual de 50 imagens. A revalidação da cascata no teste agrupado quantificou queda de Dice de $0{,}7395$ para $0{,}7210$ ao substituir a ROI de referência pela prevista, demonstrando a importância de avaliar o encadeamento dos modelos.

A destilação permitiu executar uma estudante compacta com menor custo que as professoras no ensaio de *forward*, embora a escolha da combinação operacional exija revalidação independente. No MONAI, o aumento de 3.534 para 3.707 candidatas não vazias representa maior cobertura, não acurácia externa. A pseudo-expansão da medula não elevou o Dice de teste, reforçando que quantidade de pseudorrótulos e qualidade anatômica são questões distintas.

A contribuição consolidada está na integração auditável das etapas e na distinção entre o que foi medido, o que está implementado e o que permanece hipótese. Os experimentos futuros deverão demonstrar o efeito da revisão humana, a estabilidade das ROIs e a repetibilidade das medidas de ecogenicidade. Até que exista validação clínica pareada, o sistema deve ser interpretado como infraestrutura de análise e pesquisa, não como método de diagnóstico automático de fibrose ou doença renal crônica.

Referências

[Aljabri et al. 2022] Aljabri, M., AlAmir, M., AlGhamdi, M., Abdel-Mottaleb, M., and Collado-Mesa, F. (2022). Towards a better understanding of annotation tools for medical imaging: A survey. *Multimedia Tools and Applications*, 81(18):25877–25911.

[Artsi et al. 2025] Artsi, Y., Klang, E., Collins, J. D., Glicksberg, B. S., Nadkarni, G. N., Korfiatis, P., and Sorin, V. (2025). Large language models in radiology reporting - a systematic review of performance, limitations, and clinical implications. *Intelligence-Based Medicine*, 12:100287.

[Athavale et al. 2021] Athavale, A. M., Hart, P. D., Itteera, M., Cimbaluk, D., Patel, T., Alabkaa, A., Arruda, J., Singh, A., Rosenberg, A., and Kulkarni, H. (2021). Development and validation of a deep learning model to quantify interstitial fibrosis and tubular atrophy from kidney ultrasonography images. *JAMA Network Open*, 4(5):e2111176.

[Bai et al. 2025] Bai, S., Chen, K., Liu, X., Wang, J., Ge, W., Song, S., Dang, K., Wang, P., et al. (2025). Qwen2.5-vl technical report.

[Beutler et al. 2024] Beutler, B. D., El-Sabawi, B., Walker, D. K., Cen, S., and Tchelepi, H. (2024). An objective computer-assisted measurement of sonographic renal cortical echogenicity: The splenorenal index. *Ultrasound Quarterly*, 40(1).

[Bluethgen et al. 2025] Bluethgen, C., Van Veen, D., Zakka, C., Link, K. E., Fanous, A. H., Daneshjou, R., Frauenfelder, T., Langlotz, C. P., Gatidis, S., and Chaudhari, A. (2025). Best practices for large language models in radiology. *Radiology*, 315(1).

[Budd et al. 2021] Budd, S., Robinson, E. C., and Kainz, B. (2021). A survey on active learning and human-in-the-loop deep learning for medical image analysis. *Medical Image Analysis*, 71:102062.

[Busch et al. 2025] Busch, F., Hoffmann, L., Pinto dos Santos, D., Makowski, M. R., Saba, L., Prucker, P., Hadamitzky, M., Navab, N., Kather, J. N., Truhn, D., Cuocolo, R., Adams, L. C., and Bressem, K. K. (2025). Large language models for structured reporting in radiology: past, present, and future. *European Radiology*, 35(5):2589–2602.

[Chen et al. 2026] Chen, B., Liu, C., Qi, W., and Chan, S.-C. (2026). MK-Net: A multi-scale semantic propagation and base-channel distillation network for multi-class kidney ultrasound segmentation. In *2026 IEEE International Symposium on Circuits and Systems*, pages 155–159. IEEE.

[Chen et al. 2017] Chen, L.-C., Papandreou, G., Schroff, F., and Adam, H. (2017). Rethinking atrous convolution for semantic image segmentation.

[Chen et al. 2018] Chen, L.-C., Zhu, Y., Papandreou, G., Schroff, F., and Adam, H. (2018). Encoder-decoder with atrous separable convolution for semantic image segmentation. In *Proceedings of the European Conference on Computer Vision (ECCV)*, pages 801–818.

[Cui et al. 2024] Cui, H., Mao, L., Liang, X., Zhang, J., Ren, H., Li, Q., Li, X., and Yang, C. (2024). Biomedical visual instruction tuning with clinician preference alignment.

[CVAT.ai 2026] CVAT.ai (2026). CVAT: Computer vision annotation tool documentation. `https://docs.cvat.ai/`. Documentacao tecnica consultada em outubro de 2026.

[Diaz-Pinto et al. 2024] Diaz-Pinto, A., Alle, S., Nath, V., Tang, Y., Ihsani, A., et al. (2024). MONAI Label: A framework for AI-assisted interactive labeling of 3D medical images. *Medical Image Analysis*, 95:103207.

[Hinton et al. 2015] Hinton, G., Vinyals, O., and Dean, J. (2015). Distilling the knowledge in a neural network.

[Huang et al. 2025] Huang, S., Wang, S., Qiao, S., Liu, Y., and Liu, T. (2025). Semi-plc: A framework for semi-supervised medical images segmentation with pseudo label correction. *Computer Methods and Programs in Biomedicine*, 271:109027.

[Jiao et al. 2024] Jiao, R., Zhang, Y., Ding, L., Xue, B., Zhang, J., Cai, R., and Jin, C. (2024). Learning with limited annotations: A survey on deep semi-supervised learning for medical image segmentation. *Computers in Biology and Medicine*, 169:107840.

[Khan et al. 2024] Khan, R., Xiao, C., Liu, Y., Tian, J., Chen, Z., Su, L., Li, D., Hassan, H., Li, H., Xie, W., Zhong, W., and Huang, B. (2024). Transformative deep neural network approaches in kidney ultrasound segmentation: Empirical validation with an annotated dataset. *Interdisciplinary Sciences: Computational Life Sciences*, 16(2):439–454.

[Lee 2013] Lee, D.-H. (2013). Pseudo-label: The simple and efficient semi-supervised learning method for deep neural networks. In *Workshop on Challenges in Representation Learning, ICML*, volume 3.

[Li et al. 2023] Li, C., Wong, C., Zhang, S., Usuyama, N., Liu, H., Yang, J., Naumann, T., Poon, H., and Gao, J. (2023). Llava-med: Training a large language-and-vision assistant for biomedicine in one day.

[Ma et al. 2024] Ma, J., He, Y., Li, F., Han, L., You, C., and Wang, B. (2024). Segment anything in medical images. *Nature Communications*, 15:654.

[Manley and O'Neill 2001] Manley, J. A. and O'Neill, W. C. (2001). How echogenic is echogenic? quantitative acoustics of the renal cortex. *American Journal of Kidney Diseases*, 37(4):706–711.

[Moghazi et al. 2005] Moghazi, S., Jones, E., Schroepple, J., et al. (2005). Correlation of renal histopathology with sonographic findings. *Kidney International*, 67(4):1515–1520.

[MONAI Development Team 2026] MONAI Development Team (2026). Clinical ultrasound image repository. AWS Open Data Registry. Accessed May 2026.

[OHIF 2026] OHIF (2026). OHIF medical imaging viewer documentation. `https://docs.ohif.org/`. Documentacao tecnica consultada em outubro de 2026.

[Qi et al. 2024] Qi, X., Wu, Z., Zou, W., Ren, M., Gao, Y., Sun, M., Zhang, S., Shan, C., and Sun, Z. (2024). Exploring generalizable distillation for efficient medical image segmentation. *IEEE Journal of Biomedical and Health Informatics*, 28(7):4170–4183.

[Qin et al. 2021] Qin, D., Bu, J.-J., Liu, Z., Shen, X., Zhou, S., Gu, J.-J., Wang, Z.-H., Wu, L., and Dai, H.-F. (2021). Efficient medical image segmentation based on knowledge distillation. *IEEE Transactions on Medical Imaging*, 40(12):3820–3831.

[Qin et al. 2024] Qin, X., Liu, X., Xia, L., Luo, Q., and Zhang, C. (2024). Multimodal ultrasound deep learning to detect fibrosis in early chronic kidney disease. *Renal Failure*, 46(2):2417740.

[Reichenpfader et al. 2024] Reichenpfader, D., Müller, H., and Denecke, K. (2024). A scoping review of large language model based approaches for information extraction from radiology reports. *npj Digital Medicine*, 7(1).

[Ronneberger et al. 2015] Ronneberger, O., Fischer, P., and Brox, T. (2015). U-net: Convolutional networks for biomedical image segmentation. In *Medical Image Computing and Computer-Assisted Intervention (MICCAI)*, pages 234–241.

[Sellergren et al. 2026] Sellergren, A., Kazemzadeh, S., Mahvar, F., et al. (2026). An open vision-language model for diverse medical applications. *Nature Medicine*, 32(10):3695–3704.

[Shu et al. 2021] Shu, C., Liu, Y., Gao, J., Yan, Z., and Shen, C. (2021). Channel-wise knowledge distillation for dense prediction. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 5311–5320.

[Singla et al. 2023] Singla, R., Ringstrom, C., Hu, G., Lessoway, V., Reid, J., Nguan, C., and Rohling, R. (2023). The open kidney ultrasound data set. In *Simplifying Medical Ultrasound*, volume 14337 of *Lecture Notes in Computer Science*, pages 155–164. Springer Nature Switzerland.

[Su et al. 2024] Su, J., Luo, Z., Lian, S., Lin, D., and Li, S. (2024). Mutual learning with reliable pseudo label for semi-supervised medical image segmentation. *Medical Image Analysis*, 94:103111.

[Taha and Hanbury 2015] Taha, A. A. and Hanbury, A. (2015). Metrics for evaluating 3d medical image segmentation: Analysis, selection, and tool. *BMC Medical Imaging*, 15(29).

[Tajbakhsh et al. 2020] Tajbakhsh, N., Jeyaseelan, L., Li, Q., Chiang, J. N., Wu, Z., and Ding, X. (2020). Embracing imperfect datasets: A review of deep learning solutions for medical image segmentation. *Medical Image Analysis*, 63:101693.

[Wang et al. 2025] Wang, C., Banerjee, R., Kuperstein, H., Malick, H., Bano, R., Cunningham, R. L., Tahir, H., Sakhuja, P., Hajagos, J., and Koraishy, F. M. (2025). Natural language processing for kidney ultrasound analysis: correlating imaging reports with chronic kidney disease diagnosis. *Renal Failure*, 47(1).

[Xie et al. 2021] Xie, E., Wang, W., Yu, Z., Anandkumar, A., Alvarez, J. M., and Luo, P. (2021). Segformer: Simple and efficient design for semantic segmentation with transformers. *Advances in Neural Information Processing Systems*, 34:12077–12090.

[Zhang et al. 2026] Zhang, Y., Hou, Y., Qiu, T., Zhuang, Y., Chen, K., Ling, W., Luo, Y., and Lin, J. (2026). Deep learning in renal ultrasound: applications, challenges, and future outlook. *Frontiers in Oncology*, 15:1730628.

[Zhao et al. 2023] Zhao, L., Qian, X., Guo, Y., Song, J., Hou, J., and Gong, J. (2023). MSKD: Structured knowledge distillation for efficient medical image segmentation. *Computers in Biology and Medicine*, 164:107284.

[Zhao et al. 2025] Zhao, L., Shang, J., Shi, Y., Yan, Y., Li, P., Niu, W., Zhang, G., Ding, Z., Chu, X., Wang, T., and Zheng, S. (2025). Quantifying ultrasound echogenicity difference for accurate chronic kidney disease diagnosis. *Journal of Nephrology*, 38(8):2353–2362.

[Zhou et al. 2018] Zhou, Z., Siddiquee, M. M. R., Tajbakhsh, N., and Liang, J. (2018). Unet++: A nested u-net architecture for medical image segmentation. In *Deep Learning in Medical Image Analysis and Multimodal Learning for Clinical Decision Support*, volume 11045 of *Lecture Notes in Computer Science*, pages 3–11. Springer.

[Zuo et al. 2025] Zuo, Y., Li, J., and Tian, J. (2025). A segmentation network with two distinct attention modules for the segmentation of multiple renal structures in ultrasound images. *Diagnostics*, 15(15):1978.

A. Exemplo complementar de uso do assistente

Como exemplo ilustrativo do uso assistencial, foi selecionada a imagem `dataset_loader__10_IM-0415-0078_anon`, pertencente ao conjunto com referência manual de rim, córtex, medula e CEC. A apresentação inicial do caso é feita pela imagem B-mode e pela sobreposição das regiões anatômicas, conforme a Figura 15. Essa etapa delimita o objeto da revisão antes da formulação da pergunta ao assistente.

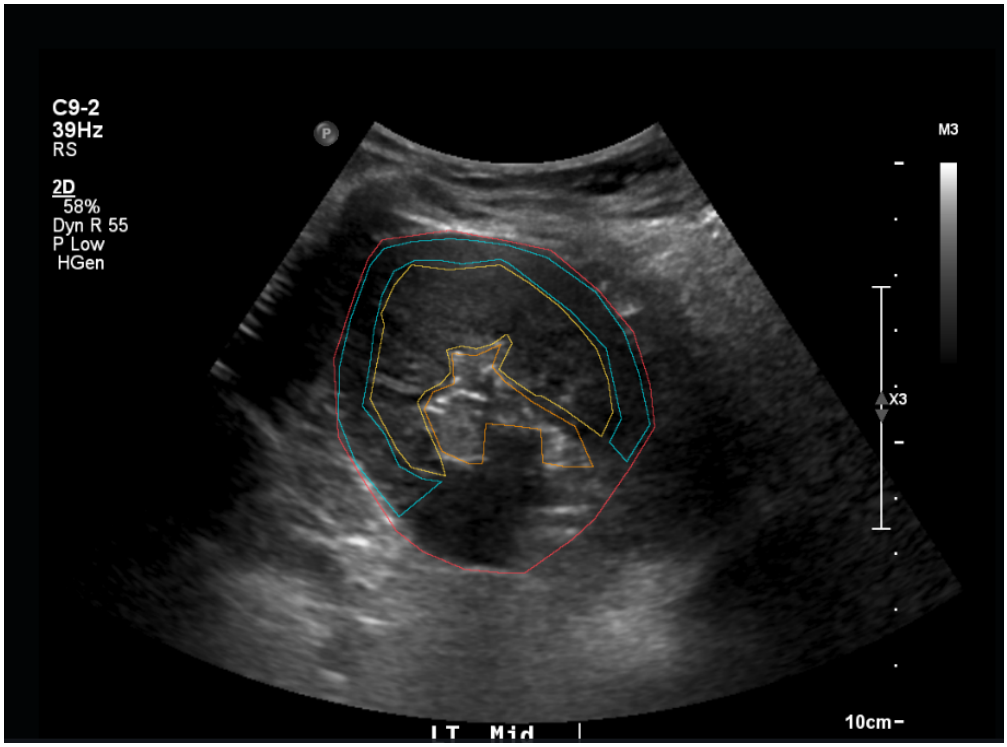


Figura 15. Exemplo de imagem renal apresentada para apoio assistencial, com a sobreposição visual das máscaras de rim, córtex, medula e CEC. A imagem e as máscaras foram recuperadas do manifesto de curadoria; a visualização não constitui, isoladamente, uma conclusão diagnóstica.

Após a apresentação do objeto, a pergunta foi normalizada para: "comparando as máscaras do córtex com o CEC, há indícios de fibrose?". O contexto visual selecionado foi o recorte da cápsula renal, acompanhado das máscaras, do medidor de brilho e das métricas disponíveis. A Figura 16 mostra a interface assistencial no momento da consulta, incluindo a pergunta, o consentimento explícito para o provedor externo e os comandos de análise local ou comparação.

A Tabela 16 organiza o resultado em uma sequência assistencial, sem transformar a saída do modelo em diagnóstico. O modelo local Qwen2.5-VL-3B-Instruct-AWQ produziu uma resposta mais genérica e incluiu uma afirmação sobre fibrose que exige mediação. O assistente multimodal externo descreveu ecos brilhantes dispersos, relacionou os valores de córtex $(32{,}7)$ e CEC $(79{,}2)$ à diferença de $46{,}5$ e ressaltou que esses dados não permitem afirmar nem excluir fibrose. Essa diferença é útil para a revisão humana, mas não representa acurácia comparativa, pois se trata de um único caso sem referência independente para o achado assistencial.

Esse exemplo mostra a função assistencial pretendida: organizar evidências, indicar regiões que merecem atenção e explicitar limitações para apoiar o especialista.

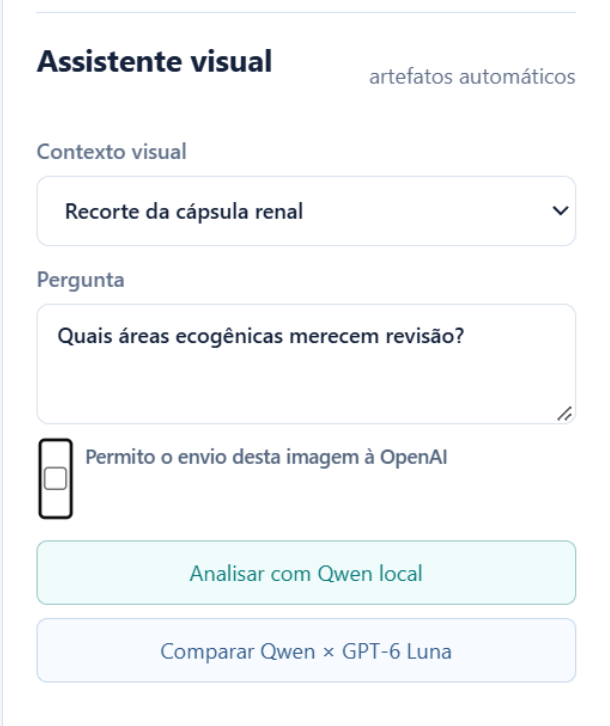


Figura 16. Interface do assistente visual durante o exemplo de uso assistencial. A Curadoria Web apresenta o contexto visual, a pergunta, as opções de execução e as evidências recuperadas da imagem selecionada.

Tabela 16. Exemplo de uso assistencial do assistente multimodal.

Etapa	Resultado apresentado	Uso e limite
Entrada	Imagem B-mode, recorte da cápsula, máscaras anatômicas e métricas de ecogenicidade.	Define o objeto e as evidências da revisão.
Resposta local	Saída genérica sobre a relação CEC–córtex, com afirmação não sustentada sobre fibrose.	Serve como proposta inicial; requer checagem especializada.
Resposta externa	Ecos brilhantes dispersos, sem foco cortical delimitado; córtex 32,7, CEC 79,2 e diferença 46,5.	Prioriza a revisão do contraste, sem caracterizar lesão.
Desfecho assistencial	Encaminhar a imagem e as regiões indicadas para revisão humana.	Não confirma nem exclui fibrose e não substitui laudo.

A decisão final permanece humana, e a saída conversacional não é incorporada automaticamente como anotação clínica.