Segmentação Renal, Curadoria *Human-in-the-Loop* e Quantificação da Ecogenicidade em Ultrassonografia: um Pipeline Rastreável para Caracterização Intrarrenal

Jefferson S. dos Anjos[1], Amaro A. de Lima[1], Gabriel M. Araújo[1], Jorge Luiz de C. Henriques Junior[2], Norderval C. Araújo[2], José Hermógenes R. Suassuna[2], Felipe da R. Henriques[1]

[1 1] CEFET/RJ – Rio de Janeiro – RJ – Brasil
[2] HUPE – UERJ – Rio de Janeiro – RJ – Brasil

jefferson.anjos.1@aluno.cefet-rj.br

{amaro.lima,gabriel.araujo,felipe.henriques}@cefet-rj.br

{jorge.henriques,norderval.norderval}@uerj.br

Abstract. *Renal ultrasound is widely available, but computational analysis is affected by acquisition variability, ambiguous anatomical boundaries and scarce expert annotations. This study develops and evaluates a traceable pipeline for capsule and intrarenal structure segmentation, human curation and exploratory echogenicity quantification. The kidneyUS dataset supplies manually annotated references, whereas external MONAI images are used only to generate candidate pseudomasks. In the deduplicated capsule test of 70 images, U-Net achieved Dice 0.9290 and IoU 0.8722. On 4,479 external images, the distilled student selected for operational use produced 3,707 non-empty candidates, compared with 3,534 for the previous operational checkpoint; this coverage was not interpreted as anatomical accuracy. On a separate manually annotated test of 50 images, multiclass U-Net achieved mean Dice 0.7594 for cortex, medulla and central echo complex (CEC). Expanding medulla training from 236 to 578 images did not improve test Dice (0.7528 versus 0.7523). Echogenicity measures are computed from original B-mode images and remain exploratory because repeatability and clinical associations were not validated. The contribution is an auditable workflow separating predictions, pseudolabels, human review and quantitative measurements; it does not claim automatic diagnosis of fibrosis or chronic kidney disease.*

Resumo. *A ultrassonografia renal é amplamente disponível, mas sua análise computacional é afetada por variações de aquisição, fronteiras anatômicas ambíguas e escassez de anotações especializadas. Este estudo desenvolve e avalia um pipeline rastreável para segmentação da cápsula e de estruturas intrarrenais, curadoria humana e quantificação exploratória da ecogenicidade. O conjunto* `kidneyUS` *fornece referências manuais, enquanto imagens externas do MONAI são usadas apenas para gerar pseudomáscaras candidatas. No teste deduplicado da cápsula, com 70 imagens, a U-Net alcançou Dice de 0,9290 e IoU de 0,8722. Em 4.479 imagens externas, a estudante destilada*

selecionada para operação produziu 3.707 candidatas não vazias, contra 3.534 do checkpoint operacional anterior; essa cobertura não foi interpretada como acurácia anatômica. Em outro teste manual, com 50 imagens, a U-Net multiclasse obteve Dice médio de 0,7594 para córtex, medula e complexo ecogênico central (CEC). A expansão do treinamento da medula de 236 para 578 imagens não aumentou o Dice de teste (0,7528 contra 0,7523). As medidas de ecogenicidade são calculadas na imagem B-mode original e permanecem exploratórias, pois sua repetibilidade e suas associações clínicas não foram validadas. A contribuição é um fluxo auditável que separa predições, pseudorrótulos, revisão humana e medidas quantitativas, sem alegar diagnóstico automático de fibrose ou doença renal crônica.

1. Introdução

A ultrassonografia é utilizada na avaliação morfológica renal por oferecer aquisição não invasiva, disponibilidade clínica e visualização em tempo real. Entretanto, a interpretação de suas imagens permanece dependente do operador e das condições de aquisição. Ruído *speckle*, sombras acústicas, variações de ganho, profundidade, enquadramento e pós-processamento alteram a aparência dos tecidos, dificultando tanto a delimitação do órgão quanto a comparação de intensidades. Esse problema torna-se especialmente relevante quando se pretende quantificar regiões internas: uma estimativa de brilho pode incorporar pixels de tecido adjacente, fundo ou artefatos se a região anatômica não estiver corretamente identificada.

A tarefa computacional pode ser decomposta em dois níveis relacionados. O primeiro consiste em localizar a cápsula renal e produzir uma máscara externa confiável. O segundo consiste em identificar estruturas de interesse no interior dessa máscara, particularmente córtex, medula e complexo ecogênico central (CEC). A segmentação externa reduz a área de busca, mas também introduz dependência entre etapas: um contorno incompleto pode eliminar tecido relevante, enquanto uma máscara excessiva pode contaminar a caracterização intrarrenal. Portanto, o desempenho de cada segmentador, considerado isoladamente, não descreve toda a confiabilidade de uma cadeia de análise.

Outro obstáculo é a disponibilidade de anotações. A marcação pixel a pixel requer conhecimento anatômico e pode variar entre observadores, principalmente nas interfaces córtico-medulares. O uso de pseudorrótulos para imagens não anotadas é uma alternativa estudada em aprendizado semi-supervisionado, mas previsões de elevada confiança podem permanecer anatomicamente incorretas [Lee 2013, Jiao et al. 2024, Su et al. 2024]. Isso exige distinguir três objetos diferentes: a proposta automática, a anotação humana e a máscara corrigida após revisão. O consenso entre arquiteturas pode ajudar a ordenar casos para inspeção, mas não deve ser confundido com acurácia individual nem convertido diretamente em referência clínica.

No domínio da imagem renal, a ecogenicidade cortical e a relação entre regiões anatômicas têm sido investigadas como descritores quantitativos associados a características funcionais ou histológicas [Manley and O'Neill 2001, Moghazi et al. 2005, Beutler et al. 2024, Zhao et al. 2025]. Entretanto, a ecogenicidade não é específica para fibrose; além disso, seus valores são afetados por parâmetros de aquisição. Dessa maneira, a passagem de uma máscara segmentada para uma medida

de intensidade exige um protocolo explícito de seleção de regiões de interesse (ROIs), controle de artefatos e análise de repetibilidade, antes de qualquer inferência clínica.

Diante desse cenário, a questão que orienta esta pesquisa é: *como integrar segmentação anatômica, estimativas de estabilidade e revisão humana em um fluxo rastreável capaz de produzir descritores quantitativos de ultrassonografia renal cuja confiabilidade possa ser avaliada?* A hipótese metodológica a ser examinada é que a qualidade e a procedência das máscaras influenciam a estabilidade das medidas intrarrenais, de modo que a curadoria humana pode ser mais relevante do que a simples inclusão de um maior número de pseudorrótulos. Essa hipótese ainda não corresponde a um efeito comprovado pelos experimentos atuais.

O objetivo geral é desenvolver e avaliar um pipeline de visão computacional para delimitação anatômica e caracterização quantitativa de ultrassonografias renais, preservando a proveniência de imagens, máscaras, modelos e revisões. Os objetivos específicos são estabelecer um benchmark supervisionado e deduplicado da cápsula; avaliar a concordância entre segmentadores na triagem de imagens externas; comparar segmentadores intrarrenais e sua relação com a variabilidade entre anotadores; investigar o efeito preliminar da pseudo-expansão; implementar curadoria auditável; e especificar medidas de ecogenicidade calculadas na imagem original. A validação da influência da revisão humana e a associação com desfechos clínicos constituem etapas posteriores.

A contribuição apresentada não consiste em propor uma nova arquitetura neural, mas em articular problemas normalmente avaliados separadamente. O `kidneyUS`, com anotações independentes, sustenta os testes supervisionados [Singla et al. 2023]; imagens externas são destinadas à geração de candidatos para revisão; e o mesmo encadeamento anatômico alimenta um protocolo quantitativo exploratório. O texto distingue resultados efetivamente medidos, componentes implementados e estudos planejados, prevenindo que uma boa métrica de segmentação seja interpretada como evidência de identificação de doença renal.

O restante do artigo está organizado da seguinte forma: a próxima seção apresenta a fundamentação teórica e os trabalhos relacionados; em seguida, descreve-se a evolução do protocolo e os materiais e métodos; depois são apresentados os resultados, a discussão, as limitações e as ameaças à validade; por fim, a conclusão sintetiza as contribuições e os experimentos ainda necessários.

2. Fundamentação Teórica e Trabalhos Relacionados

Esta seção distingue os conceitos necessários para compreender o pipeline dos estudos que delimitam seu posicionamento. As subseções sobre arquiteturas, representação das máscaras e medidas de ecogenicidade apresentam a fundamentação técnica; as subseções sobre dados, anotação assistida, modelos multimodais e plataformas de curadoria sintetizam trabalhos relacionados e explicitam a lacuna abordada. Essa separação evita que resultados publicados em outros protocolos sejam apresentados como validação do sistema proposto.

2.1. Dados anotados e desafios da segmentação renal

A segmentação de ultrassonografias renais é dificultada pela variabilidade do formato do órgão, pelo contraste heterogêneo e pela presença de artefatos que compartilham intensidade com o parênquima. O `Open Kidney Ultrasound Data Set` (`kidneyUS`) foi disponibilizado com imagens e anotações de estruturas renais, incluindo

marcações independentes que possibilitam estudar tanto o desempenho computacional quanto a variabilidade de referência [Singla et al. 2023]. A existência de dois observadores é particularmente importante: uma métrica obtida contra um único anotador não representa, por si só, um limite universal de precisão anatômica.

No comparador de cápsula renal, foram consideradas quatro famílias de arquiteturas: U-Net e U-Net++, baseadas em redes convolucionais com conexões de salto; DeepLabV3, que explora contexto multiescala por convoluções dilatadas; e SegFormer, cujo codificador hierárquico utiliza Transformers [Ronneberger et al. 2015, Zhou et al. 2018, Chen et al. 2017, Xie et al. 2021]. O `kidneyUS` é utilizado aqui como referência de imagens e anotações, não como fonte de uma arquitetura específica do comparador [Singla et al. 2023]. Características de borda, custo de inferência, estabilidade em casos difíceis e sensibilidade aos dados de treinamento influenciam a escolha dos modelos. Estudos específicos de ultrassom renal reforçam a relevância da qualidade de imagem, preparação da entrada e contexto anatômico [Khan et al. 2024, Zuo et al. 2025].

A segmentação intrarrenal apresenta um grau adicional de dificuldade. Córtex, medula e CEC não têm necessariamente fronteiras visualmente inequívocas em todo exame; pequenas variações de anotação podem produzir diferenças substanciais de sobreposição, especialmente em estruturas menores. Por isso, este trabalho utiliza resultados por classe e concordância entre anotadores, evitando que uma média agregada esconda falhas localizadas.

2.2. Estudos diretamente relacionados e diferenciação da proposta

Singla et al. [Singla et al. 2023] apresentaram o `Open Kidney Ultrasound Data Set`, disponibilizando ultrassonografias renais e anotações anatômicas independentes. Esse conjunto sustenta a referência supervisionada utilizada neste trabalho, mas a disponibilização de imagens e máscaras não equivale ao desenvolvimento do pipeline aqui investigado. No domínio da segmentação, Khan et al. [Khan et al. 2024] avaliaram abordagens de redes neurais profundas para ultrassonografia renal, reforçando a importância de comparar modelos sob condições experimentais explícitas.

A pesquisa de Zuo, Li e Tian [Zuo et al. 2025] aproxima-se particularmente da tarefa intrarrenal: os autores propõem uma rede com dois módulos de atenção para segmentar múltiplas estruturas renais, incluindo cápsula, córtex, medula e complexo ecogênico central. Trata-se de uma referência mais específica do que os artigos gerais das arquiteturas U-Net, DeepLabV3 ou SegFormer. Diferentemente desse estudo, a presente pesquisa não propõe um novo módulo de atenção; seu foco está na relação entre segmentação externa e intrarrenal, na produção e proveniência de máscaras fora do conjunto original, na revisão por meio da Curadoria Web e na preparação de descritores quantitativos. Resultados numéricos de trabalhos externos não são tomados como comparações diretas sem correspondência de divisões, anotações e protocolo.

Quanto à motivação clínica, Athavale et al. [Athavale et al. 2021] desenvolveram e validaram um modelo de aprendizado profundo para quantificar fibrose intersticial e atrofia tubular a partir de ultrassonografias, utilizando desfechos histopatológicos. A proximidade temática é relevante, mas não autoriza inferir que medidas de intensidade extraídas pelo nosso sistema predigam fibrose: o presente trabalho não dispõe de validação equivalente por biópsia. Em outra frente, Zhao et al. [Zhao et al. 2025] investigaram diferenças de ecogenicidade entre estruturas renais para avaliação de doença

renal crônica. Seu protocolo mostra a importância de referências anatômicas internas, embora as ROIs, as definições de região de comparação e os desfechos clínicos não sejam automaticamente equivalentes à razão córtex–CEC aqui estudada.

A dimensão de anotação assistida tem paralelo no MONAI Label, descrito por Diaz-Pinto et al. [Diaz-Pinto et al. 2024], que integra modelos de inferência, interfaces médicas e interação humana durante a rotulação. Assim, a Curadoria Web desenvolvida neste projeto não é apresentada como invenção do conceito de anotação assistida, mas como implementação especializada para estruturas renais, com persistência de propostas e correções, revisão rastreável e vínculo com análises de ecogenicidade. A contribuição científica a ser examinada resulta da integração dessas etapas e da avaliação de seus efeitos, não de uma alegação de superioridade sobre cada trabalho relacionado.

2.3. NLP, LLMs e modelos de visão e linguagem em ultrassonografia

O uso de processamento de linguagem natural em ultrassonografia renal oferece uma ponte entre os achados descritos pelo especialista e as medidas produzidas pelo pipeline de imagem. Wang et al. [Wang et al. 2025] analisaram laudos de ultrassonografia renal para reconhecer indicadores como ecogenicidade aumentada e redução do comprimento renal, relacionando-os a diagnóstico de doença renal crônica. Esse tipo de abordagem atua sobre o texto já produzido e não substitui a análise da imagem; sua relevância para esta pesquisa está na definição de entidades, negações, incertezas e lateralidades que podem ser confrontadas com as máscaras e os descritores quantitativos. Revisões recentes da aprendizagem profunda em ultrassonografia renal também destacam a necessidade de integrar segmentação, mensuração, dados clínicos e validação externa [Zhang et al. 2026b].

Uma revisão sistemática e metanálise sobre IA aplicada à ultrassonografia renal reuniu estudos de acurácia, mas ressaltou a heterogeneidade dos protocolos e a escassez de validação externa [Elhaie et al. 2026]. Essa evidência não pode ser transferida diretamente para o Kidney Assistant, pois os desfechos publicados incluem classificação e predição clínica que não fazem parte do teste conversacional atual. Ainda assim, ela reforça a necessidade de separar o desempenho anatômico das máscaras, a qualidade dos descritores e a fidelidade da resposta gerada. No mesmo sentido, a correlação entre parâmetros ultrassonográficos assistidos por computador e achados histológicos pode motivar a seleção de razões de ecogenicidade, mas não autoriza converter uma medida isolada em diagnóstico individual [Araújo et al. 2026].

Na tarefa de estruturação textual em documentação médica por imagem, Busch et al. [Busch et al. 2025] revisaram o emprego de LLMs para transformar informação livre em formatos estruturados. A revisão mostra que estruturação, resumo e extração de entidades são tarefas diferentes da interpretação diagnóstica direta da imagem. A scoping review de Reichenpfader, Müller e Denecke [Reichenpfader et al. 2024] complementa essa distinção ao apontar variação na granularidade das anotações, pouca validação externa e dificuldade de comparação entre conjuntos e tarefas. Essas evidências metodológicas adjacentes sustentam a utilidade de vocabulários controlados e variantes lexicais, mas não substituem as regras explícitas usadas no projeto para preservar negações, incertezas e lateralidade por achado.

As recomendações metodológicas para LLMs aplicados à documentação por imagem enfatizam que respostas plausíveis podem conter omissões, confabulações e afirmações não sustentadas. Por isso, devem ser avaliadas por especialistas, com prompts

e parâmetros registrados, além de comparação com métodos mais simples quando estes forem suficientes [Artsi et al. 2025, Bluethgen et al. 2025]. Essa orientação fundamenta a decisão de tratar a resposta do assistente como proposta de pesquisa, vinculada às evidências recuperadas pela Curadoria Web, e não como laudo ou decisão clínica autônoma.

Modelos de visão e linguagem ampliam a estruturação textual ao receberem uma imagem juntamente com uma instrução. O LLaVA-Med demonstrou uma estratégia de adaptação de um modelo conversacional para imagens biomédicas [Li et al. 2023], enquanto o BioMed-VITAL investigou a seleção de dados de instrução alinhada a preferências de especialistas [Cui et al. 2024]. O MedGemma representa uma alternativa especializada em tarefas médicas de imagem e texto [Sellergren et al. 2026]. Essas referências fundamentam a arquitetura conceitual do assistente, mas seus resultados não são tratados como evidência de desempenho em ultrassonografia renal.

O Qwen2.5-VL foi escolhido como modelo local porque seu relatório técnico descreve processamento de resolução dinâmica, localização espacial e extração estruturada de informações visuais [Bai et al. 2025]. No entanto, as capacidades gerais descritas no relatório não validam automaticamente o checkpoint 3B quantizado usado na RTX 3050. O experimento deste artigo mede esse checkpoint específico, com a mesma imagem, máscaras, métricas e prompt registrados para cada condição.

Na geração de respostas fundamentadas, a associação entre cada afirmação e a região anatômica ou evidência utilizada é relevante para o desenho da Curadoria Web. Estudos recentes de estruturação de relatórios de ultrassonografia, incluindo UltraReporter, modelos para tireoide e processamento de relatórios mamários, mostram a relevância do domínio, mas também utilizam tarefas, idiomas, dados e referências clínicas diferentes [Hao et al. 2026, Zhang et al. 2026a, Cheng et al. 2026, Chen et al. 2026b]. Portanto, esses trabalhos são utilizados como fundamentação e trabalhos relacionados, não como resultados replicados neste estudo.

O escopo experimental multimodal fica restrito a dois modelos. O Qwen2.5-VL-3B-Instruct-AWQ é executado localmente, permitindo registrar latência, uso de memória e reprodutibilidade na GPU disponível. O GPT-6 Luna é utilizado como referência externa, recebendo o mesmo conjunto de evidências e a mesma pergunta. Os demais modelos citados nesta seção não são incluídos na comparação quantitativa, seja por exigirem infraestrutura adicional, por dependerem de acesso ou treinamento específico, ou por terem sido desenvolvidos para outra modalidade. Essa delimitação evita que resultados publicados em protocolos incomparáveis sejam apresentados como uma validação do Kidney Assistant.

2.4. Redes neurais convolucionais e segmentação semântica

Redes neurais convolucionais (*Convolutional Neural Networks*, CNNs) aprendem representações espaciais de uma imagem por meio de filtros aplicados localmente, com compartilhamento de parâmetros. Uma convolução bidimensional pode ser expressa, de forma simplificada, como

$$F_k^{(l)}(x,y) = \sigma\left(b_k + \sum_c \sum_{u,v} W_{k,c}^{(l)}(u,v)\, F_c^{(l-1)}(x+u, y+v) \right), \tag{1}$$

em que $F_k^{(l)}$ é o mapa de características do filtro k na camada l, W representa os pesos, b_k o viés e σ uma não linearidade. Camadas sucessivas aprendem representações desde bordas e padrões de textura até relações espaciais de maior alcance. Operações de *pooling* reduzem resolução e ampliam o campo receptivo, mas podem suprimir detalhes que são relevantes para contornos anatômicos finos. Em segmentação semântica, o resultado não é apenas uma classe global da imagem: é um mapa de rótulos por pixel, obtido por um decodificador e convertido em máscara segundo a regra de decisão da tarefa.

Uma comparação de segmentadores deve distinguir a arquitetura de base, as estratégias de inicialização dos pesos e as escolhas de treinamento. As CNNs U-Net, U-Net++ e DeepLabV3 apresentam diferentes maneiras de combinar textura local e contexto; o SegFormer constitui uma alternativa hierárquica com atenção baseada em Transformers. No experimento binário do rim, todas as saídas foram adaptadas a um canal, mas isso não torna idênticas as capacidades representacionais ou os custos computacionais das redes.

2.5. U-Net: codificação, expansão e conexões de salto

A Figura 1 apresenta esquematicamente os principais componentes da arquitetura U-Net discutida nesta subseção.

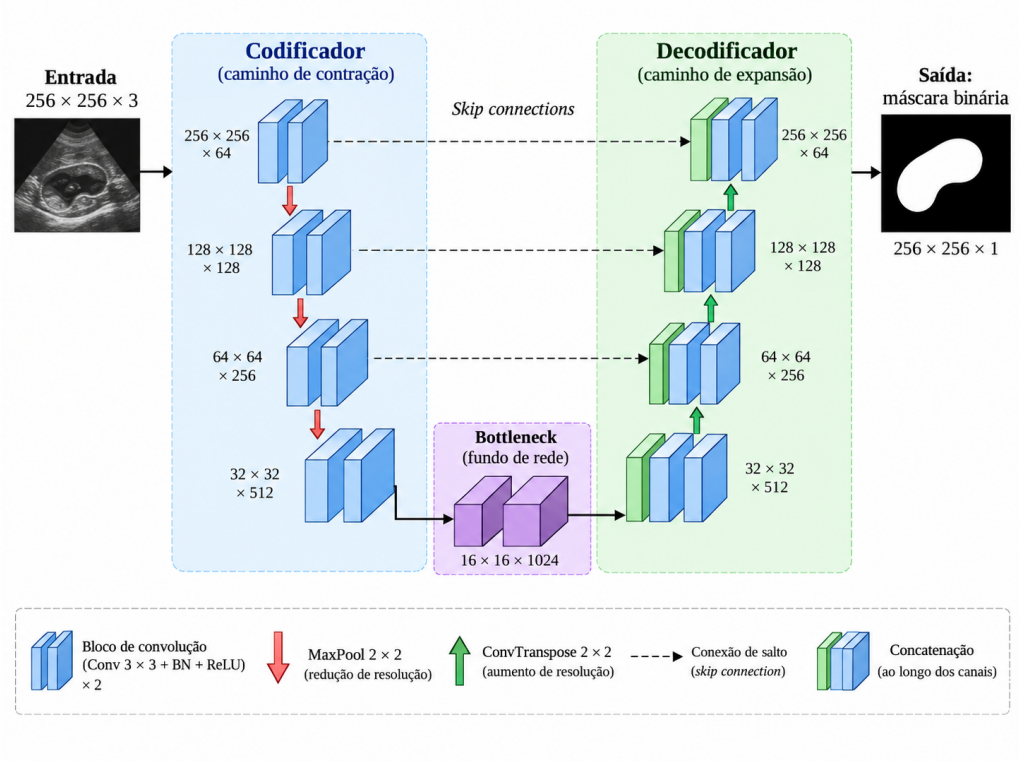


Figura 1. Representação esquemática da arquitetura U-Net utilizada como referência para o comparador de segmentação renal. Fonte: elaboração própria, com base na arquitetura original e na implementação estudada. A arquitetura original é descrita por [Ronneberger et al. 2015].

A U-Net foi concebida para segmentação biomédica e apresenta um caminho contrativo e outro expansivo ligados por *skip connections* [Ronneberger et al. 2015]. O codificador utiliza blocos convolucionais e redução progressiva da resolução para capturar características e contexto; a região central (*bottleneck*) processa representações de maior abstração; o decodificador recupera resolução combinando as características ampliadas

com mapas provenientes do codificador. Essa concatenação ajuda a reconstruir limites espaciais que seriam difíceis de recuperar apenas a partir das representações de baixa resolução.

A implementação do comparador, em `train_unet.py`, recebe três canais e emprega quatro blocos de codificação com 64, 128, 256 e 512 canais, intercalados por *max-pooling* 2×2. O *bottleneck* utiliza 1.024 canais; quatro operações de convolução transposta recompõem a resolução, com concatenação de características de igual escala. Cada bloco `DoubleConv` aplica duas convoluções 3×3 com *Batch Normalization* e ReLU. A convolução final 1×1 produz um *logit* por pixel para a máscara binária. Essa descrição corresponde ao código de treinamento analisado, e não implica que todos os checkpoints intrarrenais reutilizem parâmetros idênticos.

A vantagem conceitual da U-Net está na combinação entre contexto e localização, relevante para distinguir a cápsula renal de tecidos adjacentes com ecogenicidade semelhante. Entretanto, *skip connections* não garantem correção de fronteiras em imagens de baixo contraste, e a perda de detalhes durante o *downsampling* permanece uma limitação a investigar.

2.6. U-Net++: caminhos de salto densos e decodificação aninhada

A Figura 2 apresenta esquematicamente os principais componentes da arquitetura U-Net++ discutida nesta subseção.

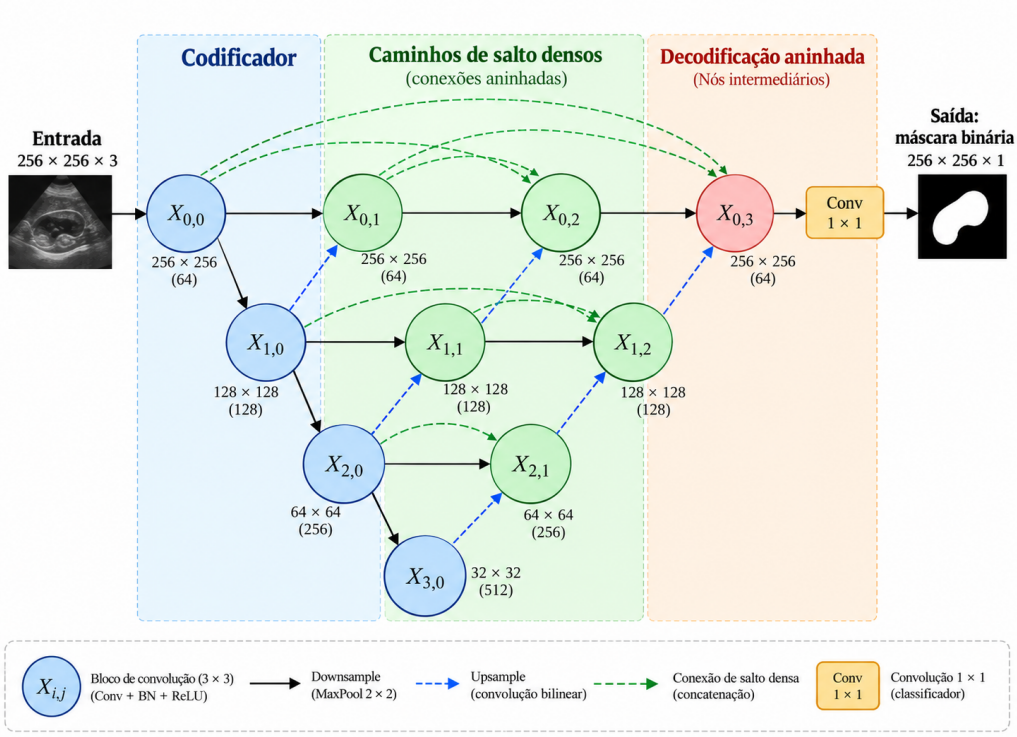


Figura 2. Representação esquemática da arquitetura U-Net++ utilizada como referência para o comparador de segmentação renal. Fonte: elaboração própria, com base na arquitetura original e na implementação estudada. A arquitetura original é descrita por [Zhou et al. 2018].

A U-Net++ modifica a topologia do codificador–decodificador ao introduzir caminhos de salto aninhados, nos quais mapas de características

passam por blocos convolucionais intermediários antes de serem integrados à decodificação [Zhou et al. 2018]. Em lugar de uma conexão direta por nível, cada nó pode combinar características de nós anteriores da mesma resolução e informações ampliadas de um nível mais profundo. O objetivo arquitetural é reduzir a diferença de representação entre as características encaminhadas pelo codificador e aquelas utilizadas pelo decodificador, preservando informações de múltiplas escalas.

A organização dos nós pode ser sintetizada por

$$X^{i,j} = H\left(\left[X^{i,0}, \ldots, X^{i,j-1}, U(X^{i+1,j-1})\right]\right), \quad j > 0, \tag{2}$$

em que H representa o bloco convolucional, U a interpolação para a resolução do nível superior e os colchetes a concatenação por canais. Na implementação disponível em `train_unetplusplus.py`, há quatro níveis de codificação com 64, 128, 256 e 512 canais e nós intermediários `conv0_1`, `conv0_2` e `conv0_3`, além de outros nós associados a resoluções inferiores. O aumento espacial é feito por interpolação bilinear; os blocos contêm duas convoluções 3×3, normalização em lote e ReLU.

Diferentemente de variantes da proposta original que utilizam múltiplas saídas supervisionadas, o código examinado termina em uma única convolução 1×1 aplicada ao nó `conv0_3`; portanto, não implementa *deep supervision*. A estrutura aninhada oferece mais caminhos de fusão, mas também modifica o custo de treinamento e não assegura desempenho superior em um conjunto renal pequeno. Essa possibilidade é avaliada empiricamente pelo comparador.

2.7. DeepLabV3: convoluções dilatadas e contexto multiescala

A Figura 3 apresenta a arquitetura DeepLabV3 empregada e suas taxas de dilatação.

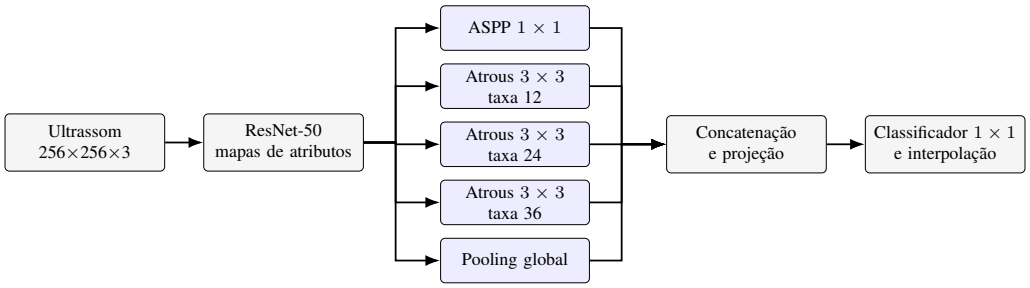


Figura 3. Arquitetura DeepLabV3 empregada na segmentação renal, com ResNet-50 e ASPP com taxas de dilatação 12, 24 e 36. Fonte: elaboração própria, com base em [Chen et al. 2017] e na implementação estudada.

O DeepLabV3 explora convoluções dilatadas (*atrous*) e o módulo *Atrous Spatial Pyramid Pooling* (ASPP) para combinar contexto em diferentes escalas sem depender de um decodificador simétrico como o da U-Net [Chen et al. 2017]. Na convolução dilatada, o deslocamento entre posições amostradas é controlado por uma taxa r:

$$y(p) = \sum_{k} w(k)\, x(p + r\, k). \tag{3}$$

Para $r = 1$, a operação corresponde à convolução comum. Com taxas maiores, o campo receptivo efetivo aumenta sem alterar a quantidade de posições do filtro. No ASPP, diferentes taxas operam em paralelo e são combinadas com informações globais, permitindo representar estruturas em várias escalas.

Em `src/segmentation/experiments/train_deeplab.py`, utiliza-se `torchvision.models.segmentation.deeplabv3_resnet50` por padrão, com opção para ResNet-101. O código inicializa pesos previamente treinados quando a opção `-no-pretrained` não é utilizada e substitui a camada final do classificador por uma convolução 1×1 de saída binária. Na implementação convencional do ASPP do `torchvision`, há uma ramificação 1×1, convoluções atrous com taxas 12, 24 e 36 e uma ramificação de *pooling* global. O modelo retorna *logits* de segmentação, posteriormente processados no fluxo compartilhado de avaliação.

O DeepLabV3 pode aproveitar contexto para diferenciar a região renal de outras estruturas com texturas parecidas; em contrapartida, a reconstrução de contornos pequenos pode ser desafiadora. Deve-se observar que o artigo sobre DeepLabV3+ descreve uma extensão com decodificador para refinamento espacial [Chen et al. 2018]; **essa extensão não é a arquitetura instanciada no comparador** e, por isso, o trabalho original do DeepLabV3 constitui a referência principal deste modelo.

2.8. SegFormer: codificador hierárquico com Transformers

A Figura 4 apresenta esquematicamente os principais componentes da arquitetura SegFormer-B0 discutida nesta subseção.

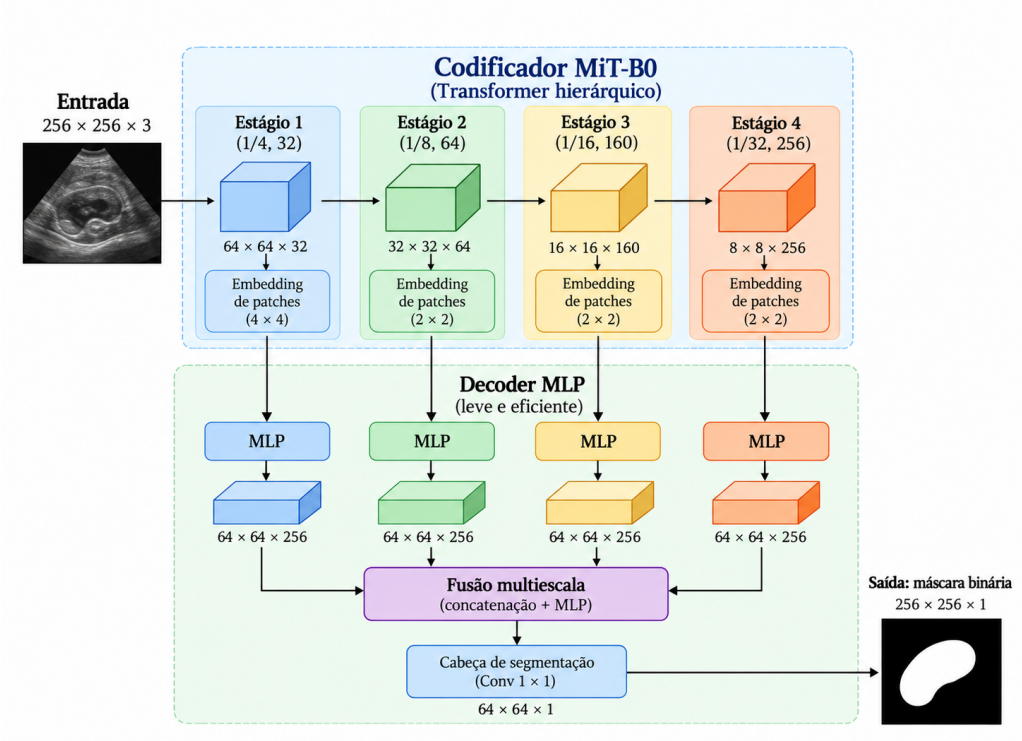


Figura 4. Representação esquemática da arquitetura SegFormer-B0 utilizada como referência para o comparador de segmentação renal. Fonte: elaboração própria, com base na arquitetura original e na implementação estudada. A arquitetura original é descrita por [Xie et al. 2021].

O SegFormer difere das três arquiteturas anteriores por utilizar o *Mix Transformer* (MiT) como codificador hierárquico, seguido de um decodificador leve baseado em projeções e fusão multiescala [Xie et al. 2021]. A imagem é transformada em representações progressivamente mais compactas, enquanto mecanismos de autoatenção permitem integrar relações entre posições do mapa de características. Uma forma geral

da atenção escalada é

$$\mathrm{Attention}(Q, K, V) = \mathrm{softmax}\left(\frac{QK^{\top}}{\sqrt{d_k}}\right) V, \tag{4}$$

em que Q, K e V representam consultas, chaves e valores, e d_k controla o escalonamento dos produtos internos. No MiT, a atenção é empregada em uma estrutura hierárquica com redução espacial, evitando operar apenas sobre uma representação plana de resolução única.

O script `src/segmentation/experiments/train_segformer.py` utiliza a biblioteca `transformers` e, por padrão, carrega `nvidia/segformer-b0-finetuned-ade-512-512`; a variante B2 é uma opção de linha de comando, não o padrão. A configuração B0 organiza características em quatro escalas com 32, 64, 160 e 256 canais. O classificador é adaptado por `num_labels=1`, com `ignore_mismatched_sizes=True` para permitir a reinicialização de componentes cuja dimensionalidade não corresponde à tarefa renal. Na inferência, os *logits* do decodificador precisam ser redimensionados para coincidir com a resolução da máscara de referência.

O uso de pesos provenientes de um conjunto de imagens naturais, como ADE20K, constitui uma condição experimental distinta da inicialização das redes convolucionais sem pré-treinamento. O SegFormer permite examinar o efeito de características hierárquicas baseadas em atenção, mas diferenças de desempenho também podem refletir o pré-treinamento e o protocolo de otimização, não somente a arquitetura.

2.9. Síntese comparativa das arquiteturas

U-Net e U-Net++ recuperam informação espacial por caminhos expansivos e concatenação com características do codificador; a U-Net++ aprofunda essa integração por conexões intermediárias densas. DeepLabV3 privilegia a extração de contexto multiescala por convoluções dilatadas e ASPP, sem o decodificador especializado do DeepLabV3+. SegFormer utiliza um codificador MiT baseado em Transformers e uma fusão multiescala leve. Assim, o comparador reúne diferentes estratégias de representação e reconstrução da região renal, avaliadas por métricas de sobreposição e de contorno, sem pressupor superioridade geral de uma família arquitetural.

A descrição acima refere-se aos scripts de comparação binária da cápsula. Os modelos posteriormente empregados para segmentação intrarrenal e na Curadoria Web constituem experimentos próprios; suas configurações e rótulos devem ser descritos na metodologia correspondente, evitando transferir automaticamente para eles as características ou os resultados dos checkpoints do benchmark.

2.10. Destilação de conhecimento na segmentação semântica

A destilação de conhecimento (*knowledge distillation*, KD) é um procedimento de treinamento no qual uma rede estudante aprende com a supervisão de um ou mais modelos professores. Em vez de utilizar apenas rótulos discretos, a estudante recebe também distribuições de probabilidade produzidas pelos professores, denominadas *soft targets*. Essa estratégia foi sistematizada por Hinton, Vinyals e Dean [Hinton et al. 2015] como alternativa para transferir o comportamento de modelos ou conjuntos de modelos a uma rede mais compacta.

Na segmentação binária, a saída de cada professor é um mapa espacial de probabilidades de primeiro plano, e não uma única classe atribuída à imagem. Desse modo, valores intermediários próximos às fronteiras podem carregar informação adicional à máscara binarizada. A destilação aplicada a predições densas exige preservar essa correspondência espacial; trabalhos como o de Shu et al. [Shu et al. 2021] também exploram a organização das ativações para orientar a transferência.

Quando há K professores, uma forma simples de agregação é a média das probabilidades por pixel:

$$p_T(i) = \frac{1}{K} \sum_{k=1}^{K} p_k(i), \tag{5}$$

em que $p_k(i)$ é a probabilidade prevista pelo professor k no pixel i. Essa média é um alvo de treinamento, não um certificado de correção anatômica. A concordância dos professores pode ser alta mesmo quando todos erram.

Para a estudante binária, a função objetivo pode combinar a perda supervisionada pela máscara manual com uma perda de destilação:

$$\mathcal{L}_{total} = \lambda_{sup}\mathcal{L}_{sup} + \lambda_{KD}\mathcal{L}_{KD}, \tag{6}$$

em que λ_{sup} e λ_{KD} controlam a contribuição de cada termo. A temperatura T suaviza a distribuição usada na transferência de conhecimento [Hinton et al. 2015]. O emprego de professores adicionais não garante aumento de Dice: desempenho, memória, parâmetros e latência precisam ser medidos separadamente. Nesse sentido, KD difere da pseudorrotulação, que produz máscaras candidatas para imagens sem anotação, e do consenso, utilizado neste projeto para triagem de previsões divergentes.

2.11. Trabalhos relacionados à destilação em imagens médicas

Qin et al. [Qin et al. 2021] investigaram a transferência de informações semânticas regionais para segmentadores médicos compactos, com avaliação em tomografias dos conjuntos LiTS17 e KiTS19. Embora o KiTS19 inclua estruturas renais, sua modalidade e seu alvo anatômico diferem da delimitação da cápsula em ultrassonografia; portanto, os resultados numéricos não são diretamente transferíveis para este estudo.

Zhao et al. [Zhao et al. 2023] propuseram destilação estruturada combinando filtragem de características e relações entre regiões para preservar informação anatômica durante o treinamento de redes menores. Shu et al. [Shu et al. 2021] estudaram a transferência de distribuições por canal em tarefas de predição densa. Essas contribuições mostram que destilar saídas não é a única estratégia possível: características internas e relações espaciais também podem ser usadas em trabalhos futuros.

Qi et al. [Qi et al. 2024] estudaram destilação generalizável para segmentação médica entre domínios. A questão é pertinente à presente pesquisa, pois diferenças entre equipamentos, exames e fontes de ultrassonografia podem afetar professores e estudantes. Entretanto, a literatura citada não constitui validação externa do modelo aqui desenvolvido.

Uma referência diretamente próxima é o MK-Net, de Chen et al. [Chen et al. 2026a], que propõe uma arquitetura própria para segmentação multiclasse no `KidneyUS`, com propagação semântica multiescala, destilação de canais-base e aproximadamente 12,9 milhões de parâmetros. A proximidade do conjunto e das

estruturas anatômicas impede afirmar que este trabalho seja o primeiro a aplicar destilação ao `KidneyUS`. A diferença está no objeto investigado: o presente estudo não propõe uma nova arquitetura, mas compara professores heterogêneos, separa a destilação da cápsula da destilação intrarrenal, preserva o consenso como mecanismo de auditoria e integra as previsões à Curadoria Web e à mensuração exploratória da ecogenicidade.

O diferencial investigado neste trabalho está, portanto, na passagem de um consenso já utilizado para priorizar revisão humana para um protocolo de destilação multi-professor integrado a uma cascata renal hierárquica. A contribuição central é o desenvolvimento e a avaliação de um pipeline rastreável que busca reduzir o custo de inferência sem perder a possibilidade de auditar a origem das máscaras e de preservar as delimitações necessárias à análise quantitativa. Essa contribuição se materializa em quatro frentes: (i) comparação de combinações de U-Net, DeepLabV3 e SegFormer-B0 com controle sem destilação; (ii) compactação separada das etapas de cápsula e estruturas intrarrenais; (iii) distinção entre predição, consenso, pseudomáscara, revisão e máscara aceita; e (iv) integração entre segmentação e ecogenicidade na imagem original. A proposta não reivindica uma técnica inédita de KD nem superioridade clínica; avalia sua utilidade e seus limites em um fluxo específico de ultrassonografia renal.

2.12. Representação das máscaras e avaliação técnica

Em segmentação semântica, cada posição (x, y) de uma imagem I recebe um rótulo anatômico. Na tarefa binária, a máscara de referência $M(x, y) \in \{0, 1\}$ distingue rim e fundo; uma rede produz valores contínuos, convertidos em probabilidades e posteriormente em máscaras mediante uma regra de decisão. No problema intrarrenal multiclasse, a predição distingue estruturas como córtex, medula e complexo ecogênico central (CEC). Essa separação implica duas fontes de erro: a delimitação externa incorreta pode deslocar o recorte de interesse e, mesmo dentro de um recorte correto, pode haver confusão entre estruturas de aparência semelhante.

Para uma máscara prevista P e uma referência G, os coeficientes de Dice e de interseção sobre união (IoU) são definidos por

$$\mathrm{Dice}(P, G) = \frac{2|P \cap G|}{|P| + |G|}, \qquad \mathrm{IoU}(P, G) = \frac{|P \cap G|}{|P \cup G|}. \tag{7}$$

Em máscaras binárias não vazias, $\mathrm{Dice} = 2\,\mathrm{IoU}/(1 + \mathrm{IoU})$. Ambas quantificam sobreposição, mas não demonstram por si só a exatidão de limites anatômicos, nem a validade clínica dos descritores extraídos. Sua interpretação pressupõe referência adequada e regras explícitas para regiões vazias, cálculo por imagem ou agregado e seleção do conjunto de teste [Taha and Hanbury 2015]. Métricas por estrutura são particularmente necessárias em classes pequenas: deslocamentos de poucos pixels podem modificar fortemente Dice e IoU.

A comparação entre segmentadores também exige diferenciar *confiança de predição*, *concordância entre modelos* e *acurácia contra referência humana*. Probabilidades de saída podem não estar calibradas; alto Dice entre duas predições indica concordância recíproca, mas não comprova correção anatômica. Por isso, máscaras geradas automaticamente são tratadas como candidatas até passarem por verificação apropriada, e as máscaras de teste manual permanecem separadas dos dados utilizados para treinamento ou seleção [Lee 2013, Tajbakhsh et al. 2020].

2.13. Curadoria assistida, proveniência e controle de qualidade dos dados

Um fluxo de curadoria médica pode ser descrito como uma sequência de estados: caso não revisado, proposta automática disponível, avaliação humana, aceitação/correção/rejeição e eventual exportação para um conjunto elegível a treinamento. É importante armazenar o identificador da imagem, a origem da máscara, a arquitetura e a versão do modelo, a classe anatômica, a ação do revisor, a data e a versão resultante. O registro dessas informações permite reconstruir decisões e impedir que pseudorrótulos sejam confundidos com anotações manuais independentes. Revisões de ferramentas médicas destacam o papel da interface e dos procedimentos de anotação na qualidade dos conjuntos de dados [Aljabri et al. 2022].

Em um ambiente *human-in-the-loop*, a saída da rede é uma sugestão de trabalho, não uma referência definitiva. O revisor pode corrigir componentes, limites e classes; o sistema deve preservar a proposta anterior para permitir auditoria. O efeito científico desse processo precisa ser medido por estudos de tempo de anotação, concordância entre revisores e comparação de desempenho em dados de teste independentes. A disponibilização da interface, isoladamente, não demonstra economia de tempo nem ganho de generalização [Budd et al. 2021, Diaz-Pinto et al. 2024].

2.14. Pseudorrótulos, consenso e confiabilidade das máscaras

Pseudorrotulação é a utilização de saídas de modelos como supervisão candidata para exemplos não rotulados [Lee 2013]. Sua vantagem operacional reside na possibilidade de ampliar a cobertura do conjunto sem repetir integralmente o esforço de anotação. O risco é incorporar erros sistemáticos e reforçar padrões inadequados em sucessivos treinamentos. Revisões e propostas recentes discutem aprendizado semi-supervisionado, consistência, estimativas de incerteza e correção de pseudorrótulos em imagens médicas [Jiao et al. 2024, Tajbakhsh et al. 2020, Su et al. 2024, Huang et al. 2025].

Neste projeto, duas redes de famílias diferentes segmentam a mesma imagem. O Dice entre suas máscaras é utilizado como medida de concordância *entre modelos*, não como Dice frente à anatomia verdadeira. Mesmo duas redes concordantes podem compartilhar um erro; por outro lado, baixa concordância ajuda a identificar casos que merecem inspeção. A calibração *out-of-fold* procura estudar a associação desse indicador com o erro observado em dados manuais não usados pelo modelo avaliado. A passagem desse indicador para regras de seleção de dados requer validação adicional.

2.15. Curadoria *human-in-the-loop*

Em sistemas *human-in-the-loop*, modelos e revisores desempenham funções complementares: a automação fornece propostas e prioriza casos, enquanto humanos inspecionam, corrigem ou rejeitam saídas [Budd et al. 2021]. A distinção não é apenas operacional. Uma máscara revisada deve conservar seus metadados de origem, o modelo que a produziu, a identidade ou código do revisor, a decisão tomada e a versão da correção. Sem essa trilha de auditoria, não é possível atribuir eventuais ganhos de treinamento à quantidade de dados ou à intervenção especializada.

O sistema desenvolvido mantém a predição original e a máscara corrigida como objetos distintos e registra revisões por estrutura anatômica. A hipótese de que essa estratégia produzirá melhores modelos ou medidas mais estáveis exige comparação controlada entre treinamento manual, pseudo-expansão automática e pseudo-expansão revisada, e não pode ser presumida da existência da interface.

2.16. Ecogenicidade quantitativa e limites da interpretação clínica

A ecogenicidade cortical tem sido quantificada por comparação com órgãos ou estruturas de referência. Manley e O'Neill discutem a quantificação cortical; estudos posteriores exploram medidas relativas envolvendo baço ou seio renal e suas associações com indicadores funcionais [Manley and O'Neill 2001, Beutler et al. 2024, Zhao et al. 2025]. Esses trabalhos motivam o uso de razões, diferenças e contrastes normalizados, mas seus protocolos e órgãos de referência não são automaticamente intercambiáveis. A comparação córtex–CEC desta pesquisa é um protocolo intrarrenal específico, cuja equivalência a medidas da literatura não foi demonstrada.

A interpretação de aumento de ecogenicidade também requer cautela. Moghazi et al. investigaram relações entre características ultrassonográficas e biópsia, evidenciando associações que não tornam uma medida isolada específica para fibrose [Moghazi et al. 2005]. Pesquisas voltadas a IFTA ou fibrose utilizam desfechos histopatológicos e, em alguns casos, combinações de modalidades de imagem [Athavale et al. 2021, Qin et al. 2024]. Como o presente projeto não dispõe de uma coorte histopatológica pareada suficiente, sua contribuição limita-se à caracterização quantitativa de padrões de imagem, não à classificação validada de fibrose.

2.17. Plataformas de anotação e trabalhos relacionados à Curadoria Web

A contribuição de uma plataforma de curadoria precisa ser situada diante de ferramentas existentes. A revisão de Aljabri et al. [Aljabri et al. 2022] organiza soluções de anotação médica por recursos de interação, tipos de imagem e suporte ao processo de rotulação. No campo de anotação assistida por IA, o MONAI Label [Diaz-Pinto et al. 2024] combina serviços de inferência com interfaces como 3D Slicer e OHIF, oferece estratégias de aprendizado ativo e apresenta experimentos de redução do tempo de anotação. Assim, inferência associada à revisão humana e integração cliente–servidor não constituem, isoladamente, novidades desta pesquisa.

Entre as ferramentas disponíveis, o CVAT oferece anotação e correção visual de máscaras em ambiente web, enquanto o OHIF constitui um visualizador web de imagens médicas e pode servir como interface para fluxos de segmentação [CVAT.ai 2026, OHIF 2026]. Tais sistemas são referências funcionais importantes, porém sua disponibilidade não significa que tragam, como fluxo padrão, as regras anatômicas e as medidas de ecogenicidade específicas deste estudo. O MedSAM [Ma et al. 2024] demonstra a relevância de modelos de segmentação médica de propósito amplo e pode auxiliar a produção de propostas de máscara, mas não deve ser confundido com uma solução completa de governança da curadoria.

A Curadoria Web deste trabalho é posicionada como *artefato especializado*, e não como substituto genérico dessas plataformas. O seu recorte é a revisão separada de rim, córtex, medula e CEC em ultrassonografias renais, a preservação da proposta automática e da máscara modificada, e a vinculação dessas decisões a descritores de ecogenicidade. Uma contribuição verificável decorre da integração e rastreabilidade de tais etapas; uma possível superioridade sobre ferramentas existentes ou um ganho no treinamento são hipóteses a testar, não resultados já demonstrados.

2.18. Fundamentos técnicos das medidas de ecogenicidade

Em ultrassonografia B-mode, a intensidade registrada depende da interação acústica com o tecido e também da aquisição: ganho, compensação temporal de ganho, profundidade,

compressão e processamento do equipamento. Consequentemente, brilho em tons de cinza não é uma medida absoluta de fibrose. Comparações quantitativas requerem identificar as regiões anatômicas e declarar precisamente qual transformação foi aplicada à imagem [Manley and O'Neill 2001, Moghazi et al. 2005].

Se C e E representam conjuntos de pixels válidos de córtex e CEC, respectivamente, as médias de intensidade na imagem original I podem ser expressas por

$$\mu_C = \frac{1}{|C|} \sum_{(x,y)\in C} I(x,y), \qquad \mu_{CEC} = \frac{1}{|E|} \sum_{(x,y)\in E} I(x,y). \tag{8}$$

Dessas médias derivam uma razão orientada $R_{C/CEC} = \mu_C/\mu_{CEC}$ e um contraste normalizado $(\mu_{CEC} - \mu_C)/(\mu_{CEC} + \mu_C)$, quando seus denominadores são positivos. A inversão da razão altera sua interpretação; por isso, a ordem córtex/CEC deve permanecer consistente entre interface, equações e tabelas. Valores percentuais correspondem à multiplicação dessas razões por 100, não a outra grandeza física.

O uso de regiões de interesse (ROIs) internas e pareadas procura diminuir a influência de bordas, sombras e posições muito distintas na imagem, sem eliminar a dependência dos parâmetros de aquisição. Estatísticas robustas, como mediana e intervalo interquartil, complementam médias sujeitas a regiões heterogêneas. Se uma máscara é revisada, as ROIs e suas estatísticas podem mudar mesmo sem alterar a imagem original: este é um mecanismo testável para avaliar como a curadoria afeta a estabilidade das medidas. Realces como CLAHE podem auxiliar a visualização ou a inferência, mas sua utilização para quantificação precisa ser explicitamente separada da análise em B-mode original, conforme o protocolo efetivamente implementado.

2.19. Lacuna e posicionamento da proposta

Os trabalhos anteriores sustentam três frentes complementares: segmentar estruturas, aproveitar dados pouco anotados e investigar descritores de ecogenicidade. A questão abordada aqui é a ligação rastreável entre elas. Uma máscara com bom desempenho médio pode falhar em uma imagem específica; uma pseudomáscara pode ser plausível sem estar correta; e uma medida de brilho pode variar por razões não patológicas. O pipeline proposto reúne essas dependências em um mesmo protocolo, tornando explícito quais resultados já foram medidos e quais precisam de avaliação futura.

A originalidade reivindicada é, assim, de integração metodológica e avaliação operacional, e não de invenção de uma arquitetura ou da destilação de conhecimento. O sistema combina professores heterogêneos, estudantes específicas para a cápsula e para as estruturas intrarrenais, consenso para auditoria, Curadoria Web para revisão humana e descritores de ecogenicidade para análise exploratória. Essa formulação também posiciona o trabalho diante de arquiteturas recentes específicas do `KidneyUS`, como o MK-Net, evitando uma alegação de pioneirismo incompatível com o estado da arte.

3. Metodologia

3.1. Contexto e evolução do protocolo

A metodologia é apresentada na Figura 5 como uma evolução em três fases interligadas, cuja descrição geral orienta o detalhamento das subseções seguintes. A Fase 1, iniciada no artigo SBBD, abrange engenharia de dados, comparação de segmentadores, delimitação da cápsula e geração de pseudomáscaras candidatas. A Fase 2 acrescenta

consenso para auditoria, destilação de conhecimento entre professores heterogêneos e segmentação hierárquica da cápsula e das estruturas intrarrenais por estudantes compactas. A Fase 3 integra os modelos à Curadoria Web, à mensuração exploratória de ecogenicidade e ao assistente multimodal de IA para análise fundamentada nas evidências produzidas. Rastreabilidade, proveniência, reprodutibilidade e revisão humana são requisitos transversais às três fases; a saída do assistente não constitui diagnóstico clínico. A sequência é uma organização da evolução da pesquisa, não três conjuntos experimentais mutuamente exclusivos. A pesquisa iniciou-se com a comparação de arquiteturas para segmentação binária do rim. Nessa configuração, o principal resultado era uma máscara externa e sua concordância com anotações manuais. A limitação de imagens supervisionadas levou à busca por fontes adicionais e à construção de procedimentos de download, conversão, deduplicação e organização de dados externos. Essa evolução ampliou a diversidade potencial de imagens, mas introduziu um problema de procedência: dados externos sem anotações não poderiam ser tratados como equivalentes ao conjunto manual.

Na primeira etapa (SBBD), o conjunto exploratório kidneyUS reuniu 513 pares de imagens e máscaras; a expansão com 1.002 imagens locais e 4.479 imagens renais curadas do MONAI levou a 5.994 imagens no acervo histórico. As pseudomáscaras de cápsula foram triadas por confiança operacional mínima de 90% e critérios geométricos, totalizando, naquele relato, 2.961 máscaras automáticas aceitas e 1.001 máscaras preexistentes. O DeepLabV3-ResNet50 treinado com o conjunto expandido atingiu Dice de $0{,}9235$ e IoU de $0{,}8741$ no teste fixo daquele protocolo; esses valores não são diretamente comparáveis aos testes deduplicados desenvolvidos posteriormente [Singla et al. 2023, MONAI Development Team 2026].

Na evolução posterior, uma fase exploratória utilizou filtros de confiança, tamanho e geometria para priorizar pseudomáscaras. A observação de predições aparentemente confiantes, porém anatomicamente questionáveis, motivou uma mudança metodológica: os filtros deixaram de significar aceitação automática e passaram a funcionar como critérios de triagem. Foi então acrescentado o consenso U-Net–DeepLabV3, calibrado por predições *out-of-fold*, para estimar a estabilidade entre modelos independentes.

Na segunda etapa, as anotações de córtex, medula e complexo ecogênico central (CEC) do kidneyUS foram utilizadas para preparar os conjuntos supervisionados de segmentação intrarrenal [Singla et al. 2023]. Nessa fase, a máscara da cápsula delimita a região de interesse dentro da qual modelos multiclasse, como U-Net e DeepLabV3, identificam as estruturas internas. Essas anotações de especialistas não devem ser confundidas com as pseudomáscaras de cápsula geradas para as imagens externas do MONAI.

As máscaras originais fornecidas pelo `kidneyUS` são atribuídas aos anotadores desse conjunto [Singla et al. 2023]. Todas as outras máscaras do acervo foram produzidas no âmbito desta pesquisa: algumas são propostas geradas automaticamente pelos segmentadores, outras são pseudomáscaras selecionadas segundo critérios operacionais e outras podem apresentar correções e decisões registradas pela Curadoria Web. Portanto, a autoria das máscaras deve ser distinguida de seu nível de validação: a produção pelo projeto não caracteriza, por si só, anotação manual ou aprovação especializada. As imagens externas, inclusive as oriundas do repositório MONAI/NVIDIA [MONAI Development Team 2026], constituem fontes de imagens,

não fontes das máscaras produzidas aqui. A investigação avançou da cápsula para a medula e, posteriormente, para segmentação multiclasse de córtex, medula e CEC. O experimento de pseudo-expansão da medula forneceu uma observação decisiva: o aumento do treino não produziu melhora no teste manual. Isso justificou incorporar, na segunda etapa da pesquisa, a Curadoria Web como componente explícito de revisão *human-in-the-loop*, com edição, aprovação, histórico e persistência de versões.

A etapa mais recente encadeia cápsula, estruturas intrarrenais e mensuração de ecogenicidade. Nesse momento, tornou-se necessário separar ainda mais claramente o pré-processamento usado na inferência do dado usado na análise quantitativa. A mensuração passou a ser realizada na imagem original, por ROIs anatomicamente delimitadas, com resultados exploratórios. Esta seção descreve a origem das escolhas experimentais; as seções seguintes apresentam os protocolos que podem ser reproduzidos e os limites das evidências já obtidas.

A Figura 5 apresenta a visão geral da metodologia e orienta a leitura das subseções seguintes. A representação distingue três fases: (i) engenharia de dados e segmentação da cápsula renal, desenvolvidas a partir do SBBD; (ii) consenso entre modelos, destilação de conhecimento e segmentação hierárquica com estudantes distintas para cápsula e estruturas intrarrenais; e (iii) aplicação dos modelos na Curadoria Web, mensuração de ecogenicidade e análise exploratória assistida por IA multimodal. Em todas as fases, a proveniência das máscaras, a revisão humana e a reprodutibilidade permanecem explícitas.

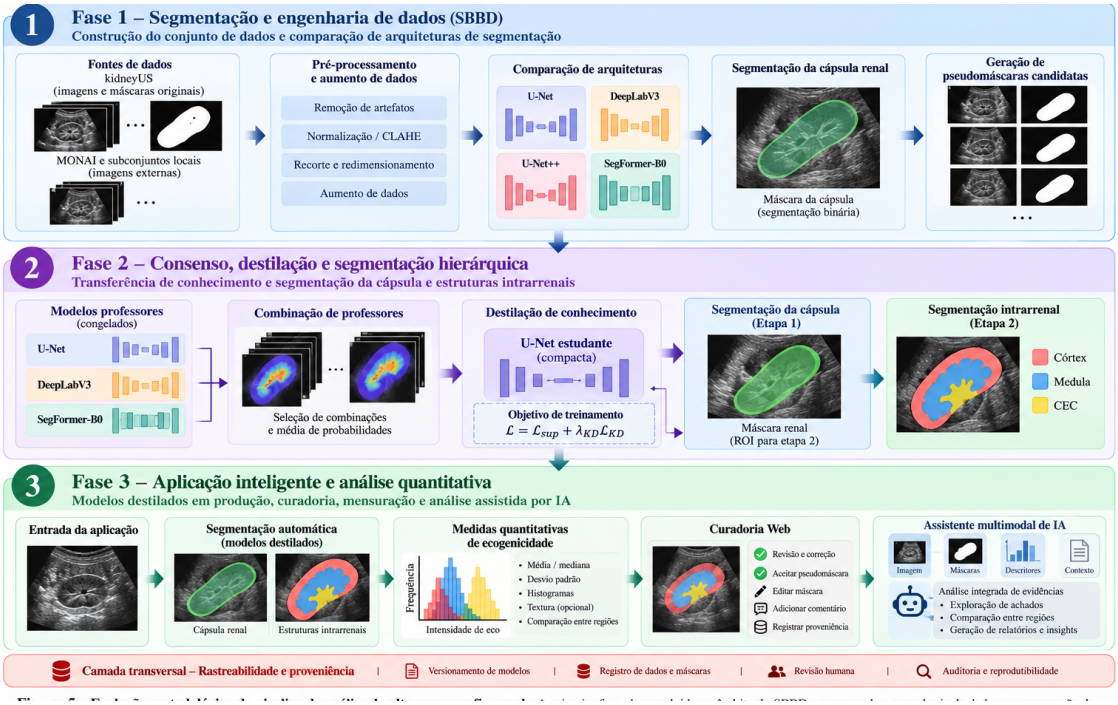


Figura 5. Visão geral da evolução metodológica da pesquisa: engenharia de dados e segmentação renal (Fase 1), consenso e destilação hierárquica com estudantes distintas para cápsula e estruturas intrarrenais (Fase 2), e integração à Curadoria Web, mensuração exploratória e assistente multimodal (Fase 3). Proveniência e revisão humana são transversais às fases. Fonte: elaboração própria.

A Figura 5 evidencia a evolução do trabalho de um protocolo de segmentação

externa para uma cascata de processamento e análise. Na primeira fase, as imagens anotadas do `kidneyUS` sustentam a comparação dos segmentadores, enquanto as fontes externas fornecem candidatas a pseudomáscaras, sem serem confundidas com referências manuais. Na segunda fase, o consenso orienta a auditoria das predições e a destilação ocorre em dois treinamentos distintos: uma U-Net estudante delimita a cápsula e define a ROI renal; outra U-Net estudante, treinada para a tarefa multiclasse, segmenta córtex, medula e CEC dentro dessa região. Na terceira fase, a aplicação reúne as máscaras, as medidas de ecogenicidade extraídas da imagem original e as evidências apresentadas ao assistente multimodal para interpretação exploratória e revisão na Curadoria Web. As setas expressam dependências de processamento, não validação clínica automática. As subseções seguintes detalham, na mesma lógica, dados, arquiteturas, experimentos, critérios de avaliação e limites de cada componente.

3.2. Desenho experimental e unidades de avaliação

A organização histórica da pesquisa compreende a etapa inicial documentada no SBBD e uma segunda etapa de segmentação intrarrenal e Curadoria Web. Para avaliar os experimentos atuais, o estudo compreende três eixos: (i) segmentação supervisionada da cápsula; (ii) segmentação e estabilidade de estruturas intrarrenais; e (iii) engenharia de dados, curadoria e quantificação exploratória. Esses eixos não compartilham necessariamente as mesmas amostras nem os mesmos protocolos. Por isso, cada resultado é apresentado juntamente com sua tarefa, a origem do dado e o tipo de referência. Resultados de conjuntos expandidos com pseudorrótulos não são comparados diretamente com testes manuais deduplicados.

A referência supervisionada original para os experimentos anatômicos é o `kidneyUS` [Singla et al. 2023]; as demais máscaras presentes no conjunto expandido são produtos dos fluxos de segmentação e curadoria desta pesquisa, com proveniência própria. Os polígonos fornecidos nas anotações são rasterizados para produzir máscaras.

A Tabela 1 resume os conjuntos supervisionados e torna explícito que os tamanhos de amostra não são intercambiáveis entre tarefas.

Tabela 1. Conjuntos supervisionados do estudo. Os testes de tarefas diferentes não representam uma mesma amostra.

Tarefa	Total	Treino	Val.	Teste
Cápsula deduplicada	468	328	70	70
Intrarrenal multiclasse	335	235	50	50
Medula binária	336	236	50	50

A análise da cápsula parte de 486 registros do primeiro anotador que correspondem a 468 imagens únicas; após deduplicação e agrupamento por exame, foram destinadas 328 imagens a treino, 70 a validação e 70 a teste. A tarefa intrarrenal multiclasse utiliza 335 imagens (235/50/50) e a tarefa binária de medula utiliza 336 imagens (236/50/50), conforme os respectivos critérios de elegibilidade. Na divisão intrarrenal, o agrupamento por paciente evita que imagens de um mesmo indivíduo sejam distribuídas entre conjuntos de desenvolvimento e teste.

A deduplicação por hash identifica conteúdos idênticos; o agrupamento por exame ou paciente busca reduzir vazamento de informação por imagens correlacionadas. Quando existem múltiplas representações de anotação para o mesmo conteúdo, o

procedimento de preparação define a amostra de referência usada no experimento. A estratégia de divisão, os manifestos e as configurações dos modelos devem acompanhar os resultados para permitir auditoria. A separação reduz, mas não exclui, o risco de semelhanças residuais e de mudança de distribuição entre fontes.

3.3. Pré-processamento e benchmark da cápsula

Os segmentadores são treinados com imagens normalizadas e redimensionadas; na configuração deduplicada de referência da U-Net, a entrada possui 256 por 256 pixels, CLAHE é aplicado ao ramo de segmentação e o aumento de dados é restrito ao treinamento. O treinamento registrado utiliza AdamW, taxa inicial de aprendizado de 10^{-4} e perda combinada de entropia cruzada binária e Dice. A seleção do checkpoint e do limiar de decisão ocorre com base na validação; para a U-Net de cápsula consolidada de referência, o limiar documentado é $0{,}35$, enquanto a estudante destilada operacional utiliza $0{,}60$. A inferência de pseudomáscaras externas utiliza também a imagem espelhada horizontalmente, agregando as previsões antes da binarização.

U-Net, UNet++, DeepLabV3-ResNet50 e SegFormer-B0 são comparados no mesmo teste deduplicado. A qualidade de sobreposição é reportada por Dice e IoU [Taha and Hanbury 2015]; precisão e *recall* identificam tendências de supersegmentação ou omissão, enquanto quadros por segundo (FPS) informam o custo de inferência nas condições do benchmark. A U-Net foi a referência inicial da cascata; após a matriz de destilação, a aplicação passou a utilizar, como decisão operacional exploratória, a U-Net estudante da combinação U-Net + DeepLabV3 para inferência e geração de pseudomáscaras. A escolha da combinação foi feita após a observação da matriz completa, incluindo o teste, e não deve ser apresentada como seleção independente desse conjunto.

3.4. Fonte externa, pseudomáscaras e consenso

Para estudar expansão de dados, metadados do repositório clínico MONAI/NVIDIA [MONAI Development Team 2026] foram filtrados por exames renais ou retroperitoneais. DICOMs candidatos foram processados em lotes; foram mantidos quadros adequados ao estudo em escala de cinza, reduzidas sequências temporais e descartados, por padrão, quadros RGB ou coloridos. O conjunto externo consolidado contém 4.479 imagens. Essas imagens não são parte do teste supervisionado da cápsula e não dispõem, nesse fluxo, de referência manual suficiente para estimar Dice externo.

A U-Net gera propostas de máscara renal. Para uma máscara candidata não vazia M, a confiança operacional média é definida por

$$C(M) = \frac{1}{|M|} \sum_{i \in M} p_i, \tag{9}$$

em que p_i é a probabilidade atribuída ao primeiro plano no pixel i. Essa estatística resume a confiança dos pixels selecionados, mas não estima diretamente a probabilidade de toda a máscara estar correta. Componentes conectados, plausibilidade geométrica e características da predição são usados para preparação e priorização, sem converter automaticamente a proposta em *ground truth*.

A mesma imagem é processada por uma DeepLabV3 independente. A concordância espacial entre as duas predições é

$$S(M_U, M_D) = \frac{2|M_U \cap M_D|}{|M_U| + |M_D|}, \tag{10}$$

calculada para máscaras não vazias com denominador válido. O indicador foi calibrado por validação cruzada *out-of-fold* em cinco folds agrupados por exame, para que cada amostra manual fosse avaliada por modelos que não a haviam utilizado naquele fold. Limiares operacionais de $0{,}89$ e $0{,}94$, derivados da distribuição de calibração documentada, organizam a fila de revisão; eles não certificam a qualidade anatômica. O manifesto preserva fonte, modelo, checkpoint, estado e indicadores associados a cada predição.

3.5. Destilação multi-professor e comparação controlada

O consenso U-Net–DeepLabV3 foi introduzido inicialmente como medida de concordância para organizar a revisão de pseudomáscaras. Entretanto, manter duas redes ativas para cada inferência aumenta o consumo operacional. A destilação foi incorporada como uma estratégia adicional: o consenso permanece como mecanismo de auditoria e triagem, enquanto uma U-Net estudante pode concentrar, em seus parâmetros, parte do comportamento dos professores.

A implementação considera as combinações de professores U-Net–DeepLabV3, U-Net–SegFormer-B0, DeepLabV3–SegFormer-B0 e U-Net–DeepLabV3–SegFormer-B0. Também foi preparado um controle com a mesma U-Net estudante treinada apenas pelas máscaras manuais, sem termo de destilação. Para cada combinação, as probabilidades são produzidas por professores congelados e agregadas conforme a Equação 5. As previsões são armazenadas em cache e cada professor é carregado individualmente, evitando mantê-los simultaneamente na GPU durante a preparação dos alvos.

A estudante possui três canais de entrada, uma saída binária e 32 canais de base. A perda supervisionada é a soma de entropia cruzada binária e perda Dice:

$$\mathcal{L}_{sup} = \mathcal{L}_{BCE} + \mathcal{L}_{Dice}. \tag{11}$$

Para probabilidade média p_T dos professores, limitada numericamente ao intervalo $[10^{-4}, 1 - 10^{-4}]$, e logits z_S da estudante, o termo de destilação implementado é

$$\mathcal{L}_{KD} = T^2 \ \mathrm{BCEWithLogits}\left(\frac{z_S}{T}, \sigma\left[\frac{\mathrm{logit}(p_T)}{T}\right]\right), \tag{12}$$

com $T = 2$, $\lambda_{sup} = 1$ e $\lambda_{KD} = 0{,}5$. No controle sem professores, o termo $\mathcal{L}_{KD}$ é removido. A configuração piloto emprega imagens de 256×256 pixels, CLAHE, aumento de dados apenas no treinamento, AdamW, taxa inicial de 10^{-4}, lote 16, semente 42, até 12 épocas e parada antecipada com paciência de quatro épocas.

Os experimentos utilizam os mesmos conjuntos manuais deduplicados de 328 imagens para treino, 70 para validação e 70 para teste. O limiar e o checkpoint de cada estudante devem ser escolhidos na validação e mantidos fixos durante a avaliação independente. Para comparações entre configurações, registram-se Dice, IoU,

parâmetros, tamanho dos pesos e tempo de inferência em um protocolo comum. Precisão, *recall*, análise por exame e intervalos de confiança constituem extensões importantes da avaliação. O filtro opcional de concordância mínima entre professores é tratado como uma ablação separada, pois altera a composição do conjunto de treinamento. A escolha da combinação de professores para a implantação foi feita após a matriz completa, incluindo os resultados do teste; portanto, o teste não permaneceu completamente isolado da seleção da configuração operacional, e essa escolha deve ser interpretada como exploratória.

O piloto U-Net–DeepLabV3 e as demais combinações de professores já foram executados e são reportados na Seção de Resultados. A escolha operacional de uma estudante é uma decisão de implantação que deverá ser reavaliada à luz da qualidade anatômica e não apenas da velocidade, especialmente porque a seleção da combinação operacional observou o desempenho no teste.

A Figura 6 resume o desenho metodológico da destilação. Os professores permanecem congelados durante a formação dos alvos; as combinações são avaliadas separadamente, e a estudante recebe tanto a máscara manual quanto a média das probabilidades dos professores. A figura representa o fluxo de treinamento, não uma execução simultânea dos professores na inferência da aplicação.

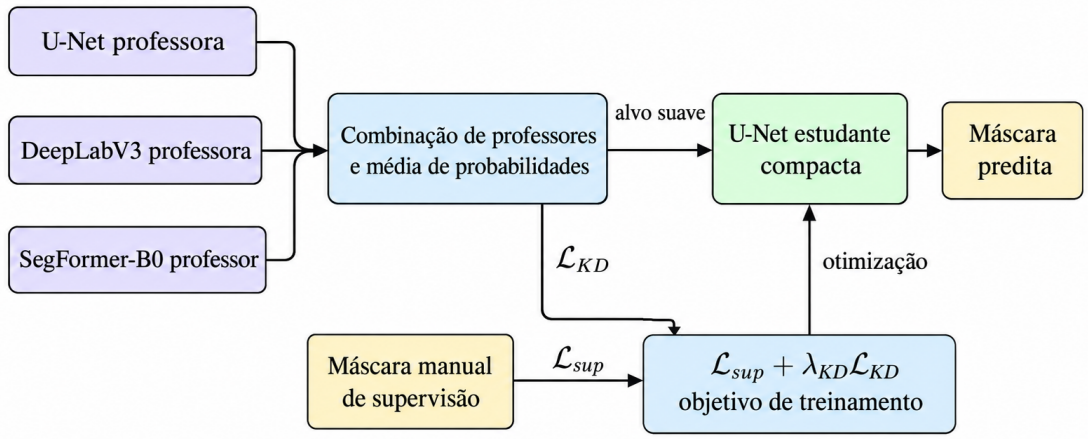


Figura 6. Fluxo metodológico da destilação multi-professor. As combinações de U-Net, DeepLabV3 e SegFormer-B0 geram alvos suaves; a estudante é treinada combinando essa informação com a máscara manual.

A Figura 6 distingue os professores, empregados exclusivamente na preparação dos alvos suaves, da U-Net estudante, utilizada na inferência. As combinações representam experimentos alternativos de treinamento, e não a execução obrigatória dos três professores ao mesmo tempo. A supervisão manual permanece presente em todas as configurações destiladas; a destilação da cápsula e a destilação intrarrenal são realizadas em treinamentos distintos, com máscaras e saídas anatômicas específicas.

3.6. Segmentação intrarrenal e propagação de erro

A análise interna prediz quatro classes: fundo, córtex, medula e CEC. A U-Net multiclasse e a DeepLabV3 multiclasse recebem, no fluxo consolidado, três canais correspondentes à ROI em tons de cinza, à ROI com o exterior do rim mascarado e à máscara de cápsula. O treinamento da U-Net documentado utiliza imagens de 256 por 256

pixels, AdamW, taxa inicial de 10^{-4} e perda de entropia cruzada multiclasse combinada com Dice. A avaliação reporta Dice e IoU por estrutura, além das médias sobre as classes de primeiro plano.

Para a implantação, foi treinada uma segunda estudante destilada, agora multiclasse e específica da etapa intrarrenal, com 235 imagens para treino, 50 para validação e 50 para teste independente. Ela utiliza 32 canais de base e combina a supervisão manual com a média das probabilidades produzidas pela U-Net e pela DeepLabV3 intrarrenais, com temperatura $T = 2$ e peso de destilação $0{,}5$. Os professores são necessários apenas para formar os alvos suaves durante o treinamento; na inferência da cascata, somente a estudante é carregada.

Duas séries independentes de anotações do `kidneyUS` permitem calcular concordância interobservador por estrutura. Esse resultado serve para contextualizar ambiguidades da referência, sem estabelecer que a rede superou um humano: as comparações humano–humano e modelo–anotador possuem pares e desenhos distintos.

A dependência entre estágios é investigada em um experimento de estabilidade: o segmentador especializado de medula é aplicado inicialmente com ROI definida pela cápsula manual e depois com ROI produzida pelo modelo renal. A mudança na máscara e em medidas de intensidade permite observar a sensibilidade da etapa interna a erros da primeira. Trata-se de um experimento específico de medula e não substitui a avaliação completa da cascata multiclasse em novos dados.

3.7. Pseudo-expansão controlada da medula

DeepLabV3 e MedullaROIUNet produzem candidatos independentes de máscara de medula. A seleção automática combina concordância e restrições geométricas; um experimento acrescentou 342 pseudomáscaras às 236 imagens de treino manual, totalizando 578 exemplos. As 50 imagens de validação e as 50 de teste permaneceram manuais. A comparação resultante examina o efeito desse conjunto específico de pseudorrótulos; não mede o efeito de uma curadoria humana completa nem garante equivalência entre conjuntos de tamanhos diferentes.

3.8. Curadoria Web: implementação e fluxo de revisão humana

Como artefato computacional desta pesquisa, foi desenvolvida a plataforma *Curadoria Web*, implementada no diretório `curadoria_web/` do repositório. Seu objetivo é integrar a inspeção de imagens ultrassonográficas, a conferência das predições anatômicas e a revisão humana em um mesmo ambiente. A arquitetura separa o servidor de aplicação em Python, responsável pelas operações sobre casos, máscaras e persistência, da interface desenvolvida com HTML, CSS e JavaScript. O sistema utiliza um manifesto de casos para carregar as imagens e suas versões de máscaras e mantém em banco SQLite os registros da curadoria.

O fluxo de trabalho começa com a identificação do revisor e a seleção de um caso na fila. A tela permite filtrar a origem das anotações e o estado da revisão, consultar as informações do modelo e sobrepor ou ocultar individualmente as camadas de rim, córtex, medula e complexo ecogênico central. O revisor pode classificar cada estrutura como aceita, a corrigir, rejeitada ou indisponível. Quando necessária, a correção pode ser realizada por polígono, pincel ou borracha; as operações permitem substituir, adicionar ou remover áreas da máscara. As edições são registradas sem sobrescrever a predição original, de modo que a máscara revisada possa ser distinguida da máscara proposta pelo modelo.

A Figura 7 apresenta a organização do ambiente. As Figuras 8 e 9 apresentam, respectivamente, a inspeção ampliada de um exame e a ferramenta utilizada para preparar uma correção manual.

A Figura 7 documenta a disposição da fila de curadoria, a identificação do revisor e os controles disponíveis na interface.

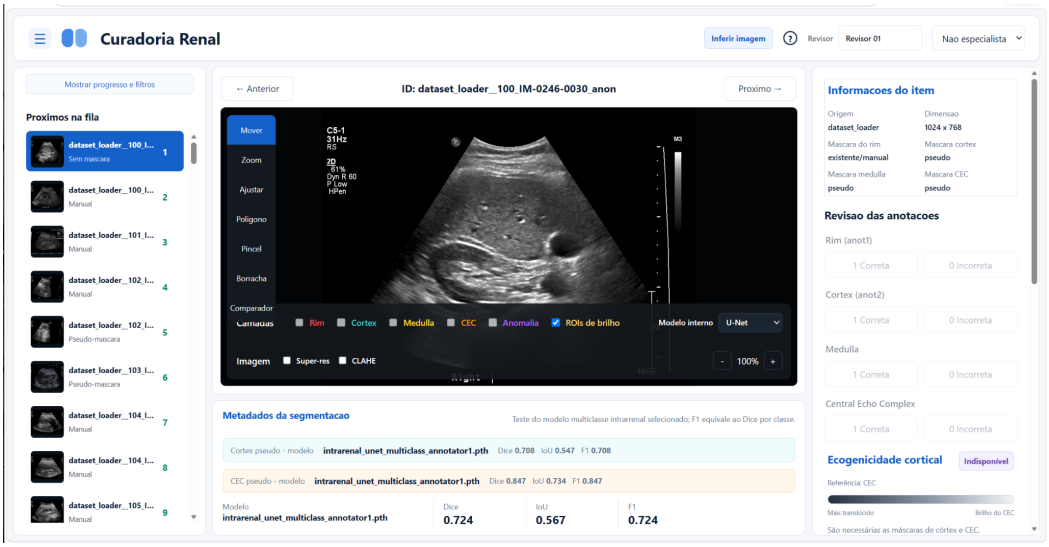


Figura 7. Visão geral da interface de Curadoria Web: fila de imagens à esquerda, visualizador de ultrassonografia renal ao centro e, à direita, metadados dos modelos e controles de revisão das anotações. O painel de progresso e filtros está recolhido.
Fonte: elaboração própria (captura de tela do sistema desenvolvido).

A visão geral reúne a fila de casos, o visualizador e os controles de revisão em uma única tela. Os metadados do modelo e o estado da curadoria ficam associados ao caso selecionado, enquanto o painel de progresso e os filtros podem permanecer recolhidos durante a inspeção.

A Figura 8 apresenta a visualização ampliada do mesmo caso, destinada ao exame da imagem renal sem distrações dos painéis laterais.

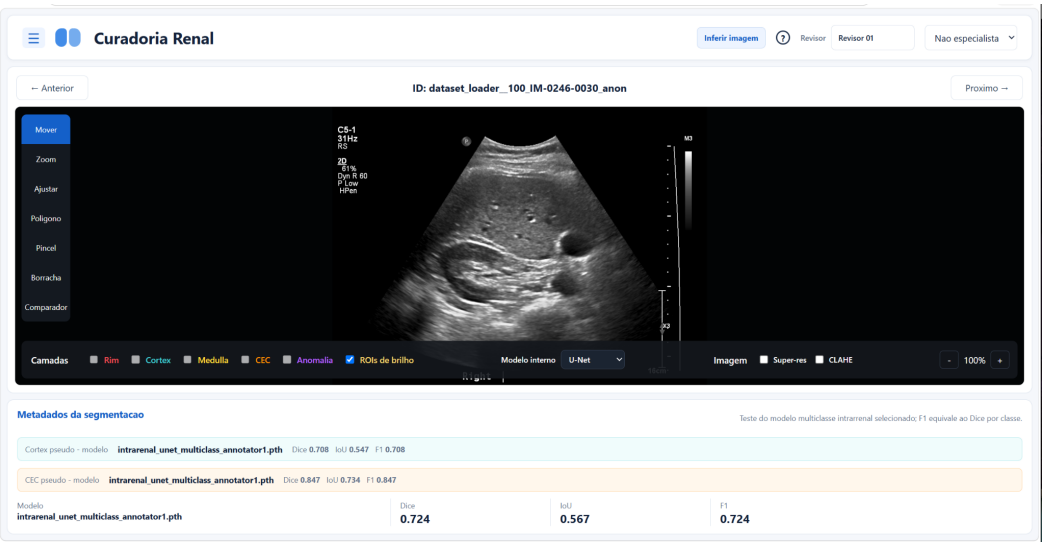


Figura 8. Visualização ampliada de uma ultrassonografia renal na Curadoria Web: área de inspeção do exame, ferramentas de navegação e controles das camadas anatômicas. As sobreposições das máscaras estão desativadas nesta captura.
Fonte: elaboração própria (captura de tela do sistema desenvolvido).

Na captura ampliada, as máscaras estão desativadas; na aplicação, elas podem ser habilitadas individualmente para comparar rim, córtex, medula e CEC com a imagem original.

A Figura 9 apresenta a tela de configuração de uma edição manual com a ferramenta de pincel.

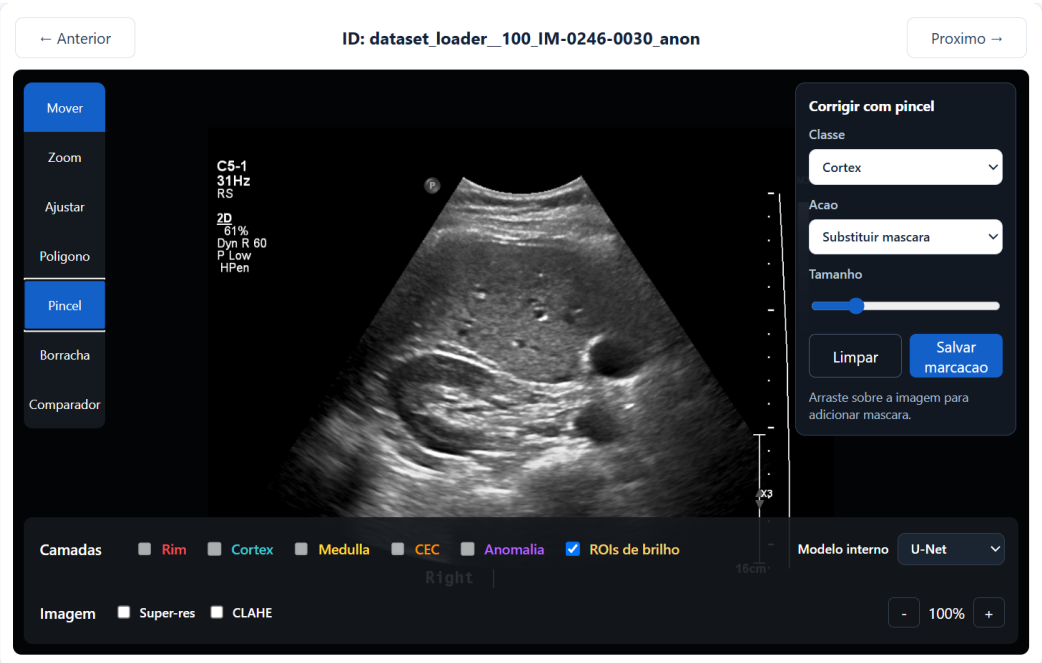


Figura 9. Tela de correção manual de máscaras na Curadoria Web: ferramenta pincel selecionada para substituir a máscara da classe córtex. A imagem documenta a configuração da edição, não uma correção concluída.
Fonte: elaboração própria (captura de tela do sistema desenvolvido).

A tela mostra a seleção da classe e da operação, mas não demonstra, isoladamente, uma máscara já alterada ou uma operação de salvamento concluída. A persistência e o histórico são propriedades verificáveis na implementação.

O módulo de inferência recebe uma nova imagem, executa a U-Net estudante de cápsula selecionada operacionalmente (`kidneyus_capsule_student_unet_deeplab.pth`), recorta a ROI renal, aplica a U-Net estudante intrarrenal destilada (`intrarenal_student_unet_deeplab.pth`) e reconstrói máscaras no espaço da imagem. O mesmo checkpoint de cápsula é utilizado pelo construtor de pseudomáscaras do MONAI. Em seguida, calcula descritores de ecogenicidade quando as regiões necessárias estão disponíveis. As saídas são armazenadas separadamente e não ingressam automaticamente na base de treino, prevenindo incorporação silenciosa de previsões não revisadas.

3.9. Mensuração quantitativa de ecogenicidade

As previsões podem utilizar CLAHE, mas as estatísticas de brilho são calculadas na imagem B-mode original preservada pelo fluxo, antes desse realce. Seja μ_C a intensidade média cortical e μ_{CEC} a intensidade média do CEC. Para denominadores estritamente positivos, definem-se a razão e o contraste normalizado:

$$R_{C/CEC} = 100\frac{\mu_C}{\mu_{CEC}}, \qquad CN_{CEC-C} = 100\frac{\mu_{CEC} - \mu_C}{\mu_{CEC} + \mu_C}. \tag{13}$$

A diferença absoluta de intensidade é $D_{CEC-C} = \mu_{CEC} - \mu_C$. Também são registrados mediana, intervalo interquartil (IQR), tamanho das regiões e indicadores de saturação. Quando uma máscara é inexistente ou uma medida é matematicamente indefinida, o sistema deve registrar indisponibilidade, em vez de criar uma estimativa.

Como médias de regiões extensas podem ser sensíveis a bordas, heterogeneidade e profundidade, emprega-se adicionalmente um protocolo de ROIs pareadas. As máscaras de córtex e CEC são erodidas por um elemento estruturante de 5×5 pixels; a área é organizada em três estratos verticais e o algoritmo procura até um par de discos válidos por estrato. Os discos têm áreas iguais e profundidades verticais aproximadas. Para cada par i, calculam-se

$$R_i = 100\frac{\mu_{C,i}}{\mu_{CEC,i}}, \qquad D_i = \mu_{CEC,i} - \mu_{C,i}. \tag{14}$$

A mediana dos R_i é a medida exploratória principal e o IQR descreve sua dispersão. O revisor pode ajustar as posições e conservar a versão revisada. A coordenada vertical funciona apenas como aproximação operacional de profundidade; não corrige completamente ganho temporal, atenuação, compressão ou diferenças entre equipamentos. O protocolo ainda requer análise de sensibilidade e repetibilidade, não sendo interpretado como biomarcador clínico validado.

A Figura 10 apresenta o comparador interativo de duas ROIs circulares posicionadas manualmente sobre as máscaras anatômicas.

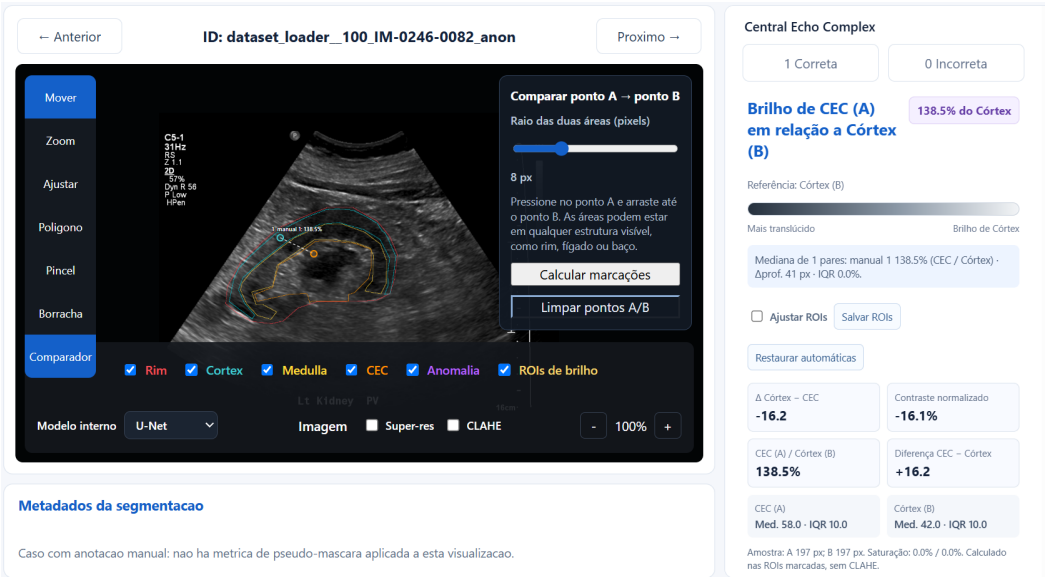


Figura 10. Comparador de ecogenicidade da Curadoria Web: seleção manual de ROIs sobre máscaras anatômicas e cálculo da razão de brilho CEC (A)/córtex (B) para o par selecionado, usando a imagem original sem CLAHE. Essa razão local não corresponde ao indicador global córtex/CEC nem constitui diagnóstico. ***Fonte: elaboração própria (captura de tela do sistema desenvolvido).***

No exemplo, o CEC é selecionado como região A e o córtex como região B; por isso, a razão exibida é $100\,\mu_{CEC}/\mu_C$, inversa à razão global $R_{C/CEC}$ definida na Equação 13. Os indicadores não devem ser comparados sem considerar a ordem das regiões, e o exemplo interativo de um par não substitui a mediana do protocolo automático de até três pares.

4. Resultados

4.1. Delimitação da cápsula renal

A Tabela 2 apresenta os resultados da segmentação da cápsula no teste manual deduplicado, comum às quatro arquiteturas comparadas.

As taxas de FPS dessa tabela pertencem ao benchmark original, que inclui carregamento dos lotes, transferência para a GPU, pós-processamento e cálculo das métricas. Para separar o custo da rede desses componentes, a subseção posterior apresenta um benchmark controlado de *forward* com protocolo comum à estudante e ao SegFormer.

Tabela 2. Segmentação da cápsula em 70 imagens de teste manual deduplicado do `kidneyUS`.

Modelo	Dice	IoU	Precisão	Recall	FPS
U-Net	**0,9290**	**0,8722**	**0,9236**	**0,9440**	18,11
SegFormer-B0	0,9223	0,8598	0,9117	0,9426	**31,34**
DeepLabV3 R50	0,9203	0,8606	0,9219	0,9338	22,26
UNet++	0,9099	0,8419	0,8910	0,9419	16,57

A U-Net obteve o maior Dice (0,9290), IoU (0,8722), precisão (0,9236) e *recall* (0,9440) entre as configurações comparadas. O SegFormer-B0 alcançou a maior taxa de inferência (31,34 FPS), em contraste com 18,11 FPS da U-Net. O ganho de sobreposição da U-Net em relação ao SegFormer foi de 0,0067 em Dice nesse teste; sem intervalo de

confiança por exame ou comparação pareada de diferenças, não se deve converter essa distância numérica em alegação de superioridade estatística.

A escolha inicial da U-Net para localizar a ROI renal baseou-se no desempenho observado e no papel crítico da máscara externa. Após a destilação, a aplicação utiliza a U-Net estudante descrita na subseção seguinte; essa mudança não implica que o modelo apresente a mesma qualidade em imagens externas. A diversidade de qualidade visual exige análise de erros e validação específica para novas fontes.

A Figura 11 apresenta um exemplo qualitativo em que as condições de aquisição favorecem a delimitação; a imagem não substitui a avaliação agregada da Tabela 2.

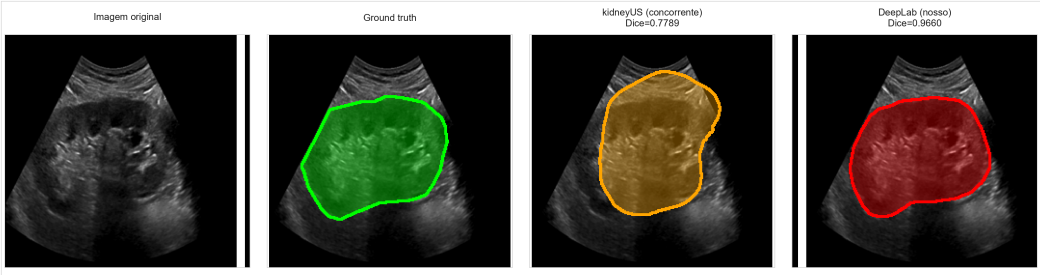


Figura 11. Exemplo qualitativo de segmentação em imagem com condições favoráveis de delimitação renal. A inspeção visual complementa, mas não substitui, as métricas agregadas.

Na imagem apresentada, o contorno previsto acompanha visualmente a região renal em condições de contraste favoráveis. Esse exemplo não permite inferir o comportamento do modelo em imagens com sombras, baixo contraste ou limites ambíguos.

4.2. Consenso *out-of-fold* e imagens externas

Na calibração com referência manual, o consenso U-Net–DeepLabV3 apresentou média de $0{,}9416$, mediana de $0{,}9627$ e correlação documentada de $0{,}840$ com o menor Dice frente à anotação manual. A direção dessa associação sugere utilidade para triagem, mas concordância entre modelos não pode ser tomada como probabilidade de correção. Para avaliar a implantação da estudante, a Tabela 3 compara a cobertura operacional no mesmo lote de 4.479 imagens externas do MONAI. Como não há máscaras manuais externas consolidadas para esse lote, esses números expressam a capacidade de produzir uma proposta não vazia, e não a acurácia anatômica.

Tabela 3. Cobertura operacional de pseudomáscaras no lote externo do MONAI.

Situação	Pseudomáscaras MONAI não vazias	Imagens sem máscara
Antes	3.534 de 4.479	945
Modelo destilado	3.707 de 4.479	772
Diferença	**+173 imagens**	**-173 imagens**

O modelo destilado aumentou a cobertura de propostas não vazias de 78,9% para 82,8%, correspondendo a 173 imagens adicionais processadas com uma máscara candidata. Esse resultado demonstra o funcionamento operacional da estudante no fluxo de geração de pseudomáscaras e sua integração ao pipeline. Entretanto, não demonstra, isoladamente, melhora da qualidade anatômica: essa questão exige comparação com referências manuais, análise por imagem e revisão especializada.

A Figura 12 ilustra um caso em que a discordância entre modelos justifica a inspeção humana.

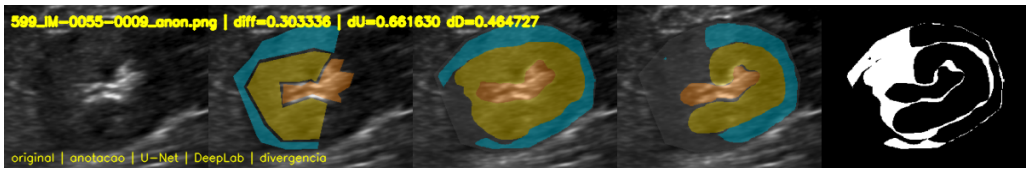


Figura 12. Exemplo de divergência entre predições de U-Net e DeepLabV3. Discordância orienta inspeção humana, mas concordância também não certifica o contorno renal.

O caso ilustra a função do consenso como mecanismo de triagem: a diferença entre as máscaras indica a necessidade de inspeção, mas a concordância entre modelos também não constitui prova de correção anatômica.

4.3. Destilação das estruturas intrarrenais: córtex, medula e CEC

A Tabela 4 apresenta o desempenho dos modelos no teste manual de 50 imagens, discriminado por estrutura intrarrenal.

Tabela 4. Desempenho intrarrenal no teste manual de 50 imagens; Dice por estrutura e médias sobre classes de primeiro plano.

Modelo	Córtex	Medula	CEC	Dice médio	IoU médio
U-Net	**0,7075**	**0,7237**	0,8469	**0,7594**	**0,6163**
DeepLabV3 R50	0,6822	0,7156	**0,8497**	0,7492	0,6045
U-Net estudante destilada	0,6959	0,7076	0,8467	0,7501	0,6051

A U-Net multiclasse obteve Dice médio $0{,}7594$ e os maiores Dice de córtex ($0{,}7075$) e medula ($0{,}7237$); a DeepLabV3 foi ligeiramente superior no CEC ($0{,}8497$ contra $0{,}8469$). A estudante destilada alcançou Dice médio $0{,}7501$ e IoU médio $0{,}6051$, com desempenho próximo aos professores neste teste. Em todos os modelos, o CEC apresentou sobreposição mais alta do que córtex e medula. O resultado reforça que a tarefa interna deve ser analisada por estrutura e não apenas por uma média geral.

4.4. Destilação da cápsula renal

Como experimento piloto inicial do caminho de destilação, foi treinada uma U-Net estudante com 32 canais de base, usando 328 imagens manuais para treino, 70 para validação e 70 para teste independente. A estudante combinou a perda supervisionada da máscara manual com a perda de destilação das probabilidades médias da U-Net e da DeepLabV3, com temperatura $T = 2$ e peso de destilação $0{,}5$. A seleção do checkpoint ocorreu na validação; o teste foi consultado somente ao final.

Tabela 5. Piloto inicial da destilação de conhecimento no teste manual independente; a seleção operacional posterior é apresentada na matriz de combinações de professores.

Modelo	Dice	IoU
U-Net professora	0,9302	0,8738
DeepLabV3 professora	0,9182	0,8587
U-Net estudante destilada	0,8847	0,7932

Os valores de $0{,}8847$ e $0{,}9078$ não correspondem à mesma execução. O primeiro pertence ao piloto inicial, executado pelo script `train_distilled_unet.py`, com limiar selecionado de $0{,}45$ e tempo registrado de 175,1 s. O segundo pertence à matriz posterior de combinações, executada pelo script `train_distillation_combinations.py`, com limiar $0{,}60$ e tempo de 168,2 s. Embora os dois experimentos usem a divisão nominal de 328/70/70 imagens, são execuções distintas e não devem ser tratados como replicações diretas.

O resultado confirma a execução do protocolo, mas não demonstra superioridade da estudante: nesta primeira configuração, seu desempenho ficou abaixo dos dois professores. Esse checkpoint do piloto não foi adotado como modelo operacional final; o piloto foi sucedido pela matriz posterior de combinações, que orientou a seleção operacional exploratória da estudante U-Net–DeepLabV3. A motivação de implantação foi concentrar o conhecimento dos professores em uma única rede e reduzir o custo de memória em relação a mantê-los simultaneamente na inferência. Essa é uma decisão operacional, não uma alegação de superioridade estatística; a qualidade da estudante deve continuar sendo monitorada e comparada com os professores em avaliações futuras.

4.4.1. Modelo operacional destilado: arquitetura, pesos e custo de inferência

A estudante é uma U-Net convolucional binária com três canais de entrada e um canal de saída. Sua arquitetura utiliza quatro blocos de codificação com 32, 64, 128 e 256 canais, um *bottleneck* com 512 canais e quatro blocos de decodificação com convoluções transpostas e conexões de salto. Cada bloco `DoubleConv` contém duas convoluções 3×3, normalização em lote e ReLU; a saída é produzida por uma convolução 1×1. Em comparação, a U-Net professora utiliza a mesma topologia com 64 canais de base, enquanto a DeepLabV3 professora utiliza backbone ResNet-50 e ASPP com convoluções atrous. Assim, a destilação não combina as arquiteturas em uma rede híbrida: transfere para a U-Net menor as probabilidades médias produzidas pelos dois professores.

O treinamento foi realizado com imagens de 256×256 pixels, lote 16, AdamW, taxa de aprendizagem 10^{-4}, decaimento 10^{-5}, aumento de dados e CLAHE no treino. A função objetivo combinou BCE+Dice supervisionada pela máscara manual, com peso 1,0, e a perda de destilação, com peso 0,5 e temperatura $T = 2$. Foram executadas 12 épocas, com seleção pela validação e semente 42; o treinamento levou 168,2 s na RTX 3050 de 8 GB. O limiar salvo para a aplicação é 0,60. A estudante possui 7.765.985 parâmetros e seu checkpoint ocupa 29,69 MiB; os checkpoints da U-Net e da DeepLabV3 professoras ocupam, respectivamente, 118,51 MiB e 160,56 MiB.

A Tabela 6 compara o custo de uma passagem direta pela rede. O protocolo utilizou a mesma RTX 3050, imagens de 256×256, lote 8, sincronização CUDA e medição somente do *forward*, sem incluir carregamento do modelo, leitura do disco ou cálculo das métricas. Foram processadas 73 imagens porque o benchmark de velocidade utilizou o diretório de teste legado ‘capsule_annotator_1‘, não deduplicado; a avaliação de acurácia da Tabela 2 utiliza o diretório deduplicado com 70 imagens. Assim, as 73 imagens caracterizam apenas o protocolo de latência e não devem ser confundidas com o conjunto independente usado para Dice e IoU. O SegFormer-B0 foi mantido como referência porque havia apresentado a maior velocidade entre os comparadores.

Tabela 6. Custo controlado de inferência na RTX 3050; uma única passagem direta, sem pré-processamento e sem métricas.

Modelo	Parâmetros	Pesos (MiB)	ms/imagem	FPS
U-Net professora	31.043.521	118,51	18,19	54,97
DeepLabV3 professora	41.998.934	160,56	15,23	65,65
U-Net estudante	7.765.985	29,69	6,51	153,51
SegFormer-B0	3.714.401	14,25	2,74	365,61

O resultado mostra que a estudante reduz substancialmente o custo em relação aos professores: seu tempo por imagem é aproximadamente 64% menor que o da U-Net professora e 57% menor que o da DeepLabV3. O SegFormer-B0 continua sendo o mais rápido no protocolo controlado, com 2,74 ms por imagem; portanto, a adoção da estudante não é justificada por velocidade máxima, mas pelo compromisso entre uma única arquitetura convolucional, menor custo que os professores e a transferência do consenso usado no treinamento. O modelo escolhido permanece dependente de revisão humana e não produz diagnóstico clínico.

As cinco configurações da matriz produzem a mesma arquitetura de estudante, com 32 canais de base; portanto, o número de professores utilizados durante o treino não aumenta o custo de inferência da aplicação. A diferença entre elas está no alvo suave usado durante a destilação. A Tabela 7 apresenta a comparação realizada com o mesmo particionamento manual. Os *checkpoints* e limiares de cada execução foram selecionados pela validação. O conjunto de teste independente foi apresentado para comparação final e não foi usado para ajustar os pesos ou hiperparâmetros de cada execução; entretanto, foi observado posteriormente na escolha exploratória da combinação operacional.

Tabela 7. Comparação das combinações de professores na destilação da U-Net estudante.

Professores	Dice val.	IoU val.	Dice teste	IoU teste
Nenhum (baseline)	0,9108	0,8363	0,8978	0,8145
U-Net + DeepLabV3	0,9093	0,8337	**0,9078**	**0,8312**
U-Net + SegFormer-B0	0,9027	0,8226	0,8965	0,8125
DeepLabV3 + SegFormer-B0	**0,9109**	**0,8363**	0,8847	0,7933
U-Net + DeepLabV3 + SegFormer-B0	0,9101	0,8351	0,9078	0,8311

Na validação, a combinação DeepLabV3–SegFormer-B0 apresentou o maior Dice ($0{,}9109$), enquanto U-Net–DeepLabV3 obteve $0{,}9093$. A combinação U-Net–DeepLabV3 foi escolhida operacionalmente porque apresentou o maior Dice ($0{,}9078$) e IoU ($0{,}8312$) no teste observado na matriz. Essa decisão utiliza o teste para selecionar a combinação e, portanto, não permite tratar esse teste como uma estimativa completamente independente de desempenho da configuração escolhida. Em relação ao baseline sem destilação, a estudante U-Net–DeepLabV3 aumentou o Dice de $0{,}8978$ para $0{,}9078$ e o IoU de $0{,}8145$ para $0{,}8312$ nesse protocolo, diferenças descritivas que ainda precisam de repetição e intervalos de confiança. O trio de professores ficou praticamente empatado ($0{,}9078$ de Dice), mostrando que adicionar um terceiro professor não produziu ganho mensurável. A média de probabilidades pode diluir informação complementar ou introduzir alvos suaves conflitantes; assim, mais professores não implicam necessariamente melhor transferência. O SegFormer-B0 continua sendo o modelo mais rápido, com 2,74 ms por imagem; entre as estudantes, o tempo permanece aproximadamente igual porque todas executam a mesma U-Net e os professores não são carregados durante a inferência.

4.5. Estudo piloto do comportamento do assistente multimodal

Para avaliar o comportamento do assistente como apoio à interpretação da imagem, e verificar sua integração com a Curadoria Web e as máscaras anatômicas, foi executado um estudo piloto com a imagem `kidneyus_capsule_test__122_IM-0144-0001_anon.png`. A inferência da cascata foi executada na RTX 3050 de 8 GB, com dispositivo CUDA, imagem de 1024×768 pixels e máscaras de rim, córtex, medula e CEC. O mesmo conjunto de evidências e a mesma sobreposição visual foram enviados ao Qwen2.5-VL-3B-Instruct-AWQ local e ao GPT-6 Luna. O recorte da cápsula foi delimitado por $\texttt{capsule_bbox} = (120, 159, 805, 742)$.

O piloto não foi desenhado para estabelecer um diagnóstico, mas para observar se os modelos conseguem utilizar as evidências fornecidas, localizar regiões anatômicas relevantes, relacionar métricas de ecogenicidade e expressar limitações. Esses comportamentos são tratados como apoio à triagem e à revisão especializada, não como decisão clínica autônoma.

A Figura 13 documenta visualmente o conjunto de evidências utilizado no piloto: a imagem B-mode original, cada máscara anatômica individual e a sobreposição conjunta das regiões segmentadas.

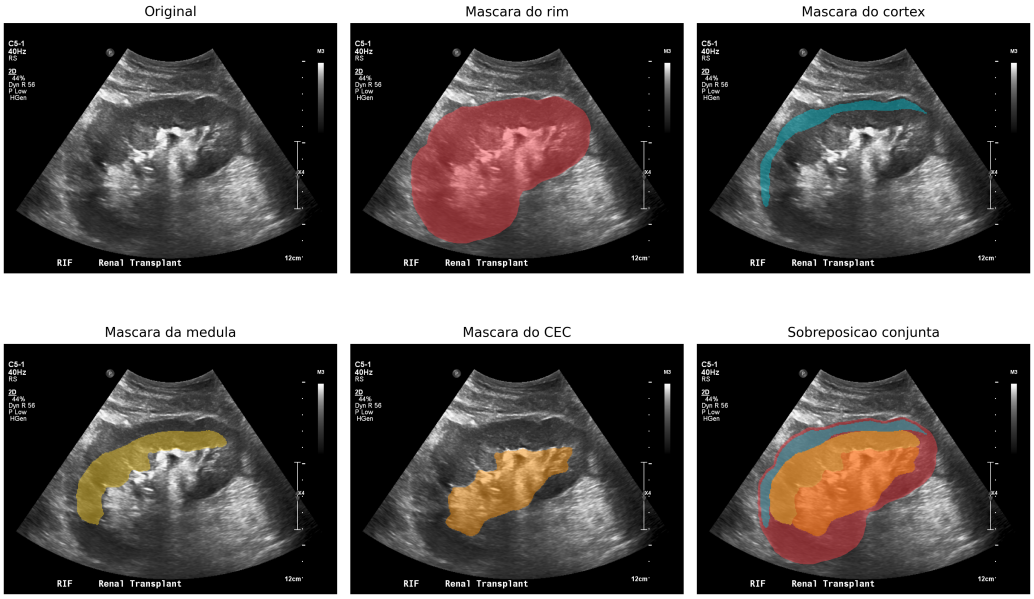


Figura 13. Evidências visuais do estudo piloto multimodal: imagem B-mode original, máscaras individuais de rim, córtex, medula e CEC e sobreposição conjunta. As máscaras individuais são apresentadas sobre a imagem para facilitar a localização de cada estrutura; as cores representam rim em vermelho, córtex em ciano, medula em amarelo e CEC em laranja. As máscaras foram geradas automaticamente pela cascata da Curadoria Web, com U-Net da cápsula (`models/kidneyus_capsule_unet.pth`) e U-Net multiclasse intrarrenal (`models/intrarenal_unet_multiclass_annotator1.pth`). Fonte: elaboração própria a partir da inferência registrada em `inferencias/infer_0141d6c60b3a`.

A composição mostra que as quatro máscaras estão no mesmo espaço da imagem original e correspondem às evidências disponibilizadas ao assistente. A máscara externa do rim foi produzida pela U-Net de cápsula; córtex, medula e CEC foram produzidos pela

U-Net multiclasse intrarrenal. Portanto, as quatro camadas são predições automáticas do pipeline, e não anotações humanas independentes ou máscaras corrigidas pela Curadoria Web. A visualização facilita a inspeção da localização anatômica, mas não constitui anotação clínica independente nem confirma, por si só, a presença de artefatos ecogênicos.

A Tabela 8 resume a comparação descritiva. Como o estudo possui um único caso e não utiliza um gabarito independente para os achados multimodais, os critérios de resposta devem ser lidos como observações qualitativas dos pesquisadores, e não como métricas de desempenho.

Tabela 8. Comparação qualitativa do estudo piloto multimodal ($N = 1$).

Critério	Qwen local	GPT-6 Luna
Evidências recebidas	Imagem, quatro máscaras e métricas	Mesma entrada
Região prioritária	Não delimitada claramente	Região central/CEC, faixa média
Separação CEC–foco	Parcial e genérica	Explicitamente cautelosa
Uso da ecogenicidade	Parcial; saída limitada pelo contexto	CEC 130,4; córtex 71,6; diferença 58,7
Resultado qualitativo	Localização menos explícita; rastreabilidade parcial	Localização mais explícita; rastreabilidade maior
Acurácia estatística	Não estimável ($N = 1$)	Não estimável ($N = 1$)

Desfecho do piloto. Considerando os comportamentos observados, o desfecho operacional foi favorável à utilização do assistente como apoio à triagem baseada em evidências: os dois modelos receberam a mesma imagem, as quatro máscaras e as métricas, mas o GPT-6 Luna produziu, neste caso, uma resposta mais explicitamente vinculada às regiões e aos valores fornecidos, enquanto a resposta do Qwen local exigiu maior mediação interpretativa. Essa diferença é uma observação qualitativa de um único caso, e não uma demonstração de superioridade geral.

O resultado não deve ser interpretado como acurácia clínica, pois o piloto possui apenas um caso e não dispõe de uma referência humana independente para presença, localização e natureza de um foco ecogênico. Portanto, a conclusão adequada é que a integração é tecnicamente viável e pode apoiar a organização da análise pelo especialista, mas ainda não demonstra detecção confiável de artefatos ecogênicos nem diagnóstico. A avaliação quantitativa requer uma amostra anotada por especialistas, com sensibilidade, especificidade, precisão, F1, concordância por região e taxa de afirmações não sustentadas.

4.5.1. Exemplo de uso assistencial na Curadoria Web

Como exemplo ilustrativo do uso assistencial, foi selecionada a imagem `dataset_loader__10_IM-0415-0078_anon`, pertencente ao conjunto com referência manual de rim, córtex, medula e CEC. A apresentação inicial do caso é feita pela imagem B-mode e pela sobreposição das regiões anatômicas, conforme a Figura 14. Essa etapa delimita o objeto da revisão antes da formulação da pergunta ao assistente.

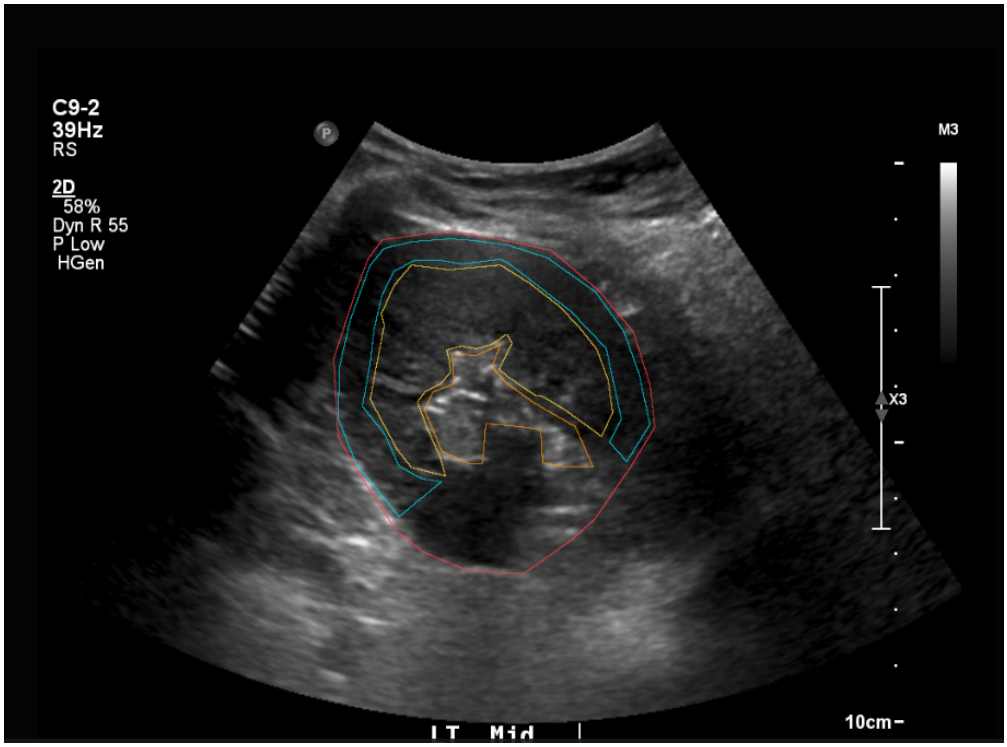


Figura 14. Exemplo de imagem renal apresentada para apoio assistencial, com a sobreposição visual das máscaras de rim, córtex, medula e CEC. A imagem e as máscaras foram recuperadas do manifesto de curadoria; a visualização não constitui, isoladamente, uma conclusão diagnóstica.

Após a apresentação do objeto, a pergunta foi normalizada para: “comparando as máscaras do córtex com o CEC, há indícios de fibrose?”. O contexto visual selecionado foi o recorte da cápsula renal, acompanhado das máscaras, do medidor de brilho e das métricas disponíveis. A Figura 15 mostra a interface assistencial no momento da consulta, incluindo a pergunta, o consentimento explícito para o provedor externo e os comandos de análise local ou comparação.

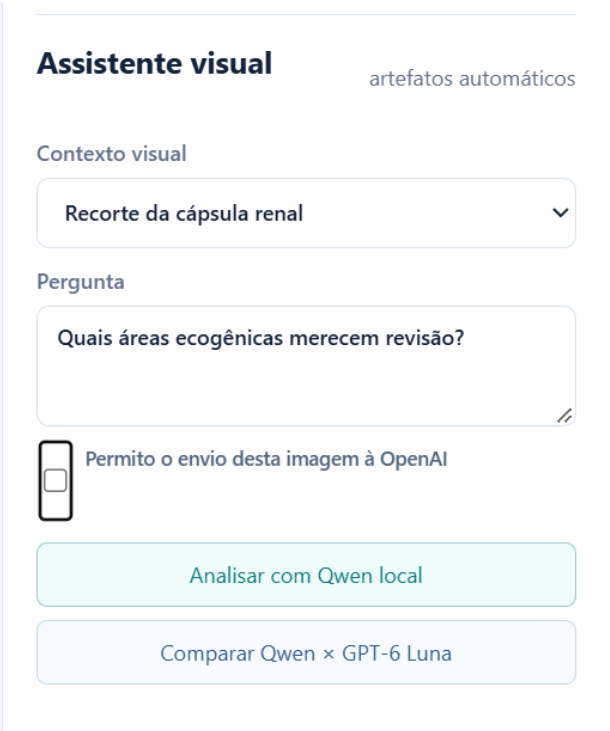


Figura 15. Interface do assistente visual durante o exemplo de uso assistencial. A Curadoria Web apresenta o contexto visual, a pergunta, as opções de execução e as evidências recuperadas da imagem selecionada.

A Tabela 9 organiza o resultado em uma sequência assistencial, sem transformar a saída do modelo em diagnóstico. O modelo local Qwen2.5-VL-3B-Instruct-AWQ produziu uma resposta mais genérica e incluiu uma afirmação sobre fibrose que exige mediação. O GPT-6 Luna descreveu ecos brilhantes dispersos, relacionou os valores de córtex (32,7) e CEC (79,2) à diferença de 46,5 e ressaltou que esses dados não permitem afirmar nem excluir fibrose. Essa diferença é útil para a revisão humana, mas não representa acurácia comparativa, pois se trata de um único caso sem referência independente para o achado assistencial.

Tabela 9. Exemplo de uso assistencial do assistente multimodal.

Etapa	Resultado apresentado	Uso e limite
Entrada	Imagem B-mode, recorte da cápsula, máscaras anatômicas e métricas de ecogenicidade.	Define o objeto e as evidências da revisão.
Resposta local	Saída genérica sobre a relação CEC–córtex, com afirmação não sustentada sobre fibrose.	Serve como proposta inicial; requer checagem especializada.
Resposta externa	Ecos brilhantes dispersos, sem foco cortical delimitado; córtex 32,7, CEC 79,2 e diferença 46,5.	Prioriza a revisão do contraste, sem caracterizar lesão.
Desfecho assistencial	Encaminhar a imagem e as regiões indicadas para revisão humana.	Não confirma nem exclui fibrose e não substitui laudo.

Esse exemplo mostra a função assistencial pretendida: organizar evidências, indicar regiões que merecem atenção e explicitar limitações para apoiar o especialista. A decisão final permanece humana, e a saída conversacional não é incorporada automaticamente como anotação clínica.

4.6. Comparação descritiva com resultados publicados

Para situar o desempenho obtido, a Tabela 10 apresenta, lado a lado, os coeficientes Dice desta pesquisa e os relatados por Zuo et al. [Zuo et al. 2025] para a MAT-UNet. A escolha dessa referência decorre da utilização do `Open Kidney Ultrasound Data Set` e do interesse nas mesmas quatro estruturas anatômicas. Os números são reproduzidos nas escalas de Dice entre zero e um; a tabela é uma comparação *descritiva entre publicações*, e não uma reavaliação dos modelos sobre as mesmas imagens.

Tabela 10. Comparação descritiva do Dice com a MAT-UNet de Zuo et al. [Zuo et al. 2025]. Os resultados provêm de protocolos independentes e não constituem um ranking experimental.

Estrutura	MAT-UNet (2025)	U-Net deste trabalho
Cápsula	0,9383	0,9290
Córtex	0,5893	0,7075
Medula	0,6634	0,7237
CEC	0,8434	0,8469

Embora a MAT-UNet apresente valor numérico maior para cápsula e os resultados deste trabalho sejam numericamente maiores para córtex, medula e CEC, tais diferenças não demonstram superioridade de uma arquitetura: os conjuntos de teste, procedimentos de divisão, critérios de elegibilidade, referência de anotação e forma de agregação podem divergir. Neste estudo, por exemplo, a cápsula foi avaliada em 70 imagens deduplicadas e a segmentação intrarrenal em 50 imagens, sem que essas avaliações correspondam necessariamente ao mesmo protocolo da MAT-UNet. A comparação controlada exigiria reproduzir as abordagens sob um conjunto de teste comum, com as mesmas anotações e métricas.

Outros trabalhos relacionados possuem objetivos complementares, mas seus desfechos não permitem preencher essa tabela de Dice. Athavale et al. [Athavale et al. 2021] investigaram classificação de fibrose intersticial e atrofia tubular com referência histopatológica, enquanto Zhao et al. [Zhao et al. 2025] avaliaram diferenças de ecogenicidade e sua associação com doença renal crônica. Essas publicações orientam a escolha de desfechos clínicos e de medidas quantitativas para validação futura; os resultados exploratórios aqui apresentados não são equivalentes a seus diagnósticos ou indicadores de desempenho clínico. No eixo de curadoria, o MONAI Label [Diaz-Pinto et al. 2024] fornece referência funcional para anotação interativa, mas sua comparação com a Curadoria Web deve priorizar rastreabilidade, operações de revisão e, em estudo futuro, tempo e concordância dos revisores, em vez de métricas de segmentação não pareadas.

4.7. Variabilidade da referência humana

A Tabela 11 apresenta a concordância Dice entre os dois anotadores, organizada por estrutura e pelo número de imagens comuns disponíveis.

Tabela 11. Concordância Dice entre os dois anotadores do `kidneyUS`, nos conjuntos disponíveis por estrutura.

Estrutura	Imagens comuns	Dice
Cápsula	486	0,9461
Córtex	323	0,5961
Medula	325	0,6936
CEC	468	0,8688

A cápsula apresentou concordância mais elevada ($0{,}9461$), ao passo que córtex ($0{,}5961$) e medula ($0{,}6936$) concentraram divergências maiores. As quantidades de imagens comuns também diferem por classe; por isso, a tabela não representa uma avaliação pareada única de quatro estruturas em exatamente os mesmos casos. A menor concordância humana ajuda a interpretar a dificuldade de obter referências internas estáveis, sem constituir prova de que os modelos alcançaram desempenho equivalente ao de especialistas.

4.8. Medula: heurística, estabilidade e expansão

Uma heurística inicial para localizar regiões escuras apresentou Dice médio $0{,}3291$ frente à referência do primeiro anotador. No experimento supervisionado específico de medula, a DeepLabV3 atingiu Dice de teste $0{,}7528$ e a MedullaROIUNet, $0{,}7326$. Em avaliação específica da estabilidade da cascata, a troca da ROI de cápsula manual pela cápsula prevista alterou o Dice global da DeepLabV3 de $0{,}7626$ para $0{,}7610$, uma diferença absoluta de $0{,}0016$. Nesse protocolo, a intensidade média estimada na medula teve correlação de $0{,}9508$ entre os dois cenários. Essa correlação descreve o conjunto avaliado; não descarta erros individuais nem certifica estabilidade de outras medidas.

A Tabela 12 apresenta a comparação da pseudo-expansão com validação e teste manuais preservados.

Tabela 12. Experimento de pseudo-expansão do treino da medula, com validação e teste manuais preservados.

Configuração	Treino	Val. Dice	Teste Dice	IoU teste
Manual	236	0,7235	**0,7528**	**0,6035**
Manual + 342 pseudo	578	**0,7424**	0,7523	0,6030

A expansão elevou numericamente o Dice de validação de $0{,}7235$ para $0{,}7424$, enquanto o Dice de teste passou de $0{,}7528$ para $0{,}7523$. Essa diferença de $-0{,}0005$ no teste não demonstra benefício de generalização; tampouco permite afirmar equivalência estatística ou inutilidade da pseudo-expansão. O achado sinaliza a necessidade de estudar qualidade do rótulo, composição dos casos e variabilidade entre execuções antes de incorporar automaticamente novas máscaras ao treino.

4.9. Resultados históricos e componentes ainda exploratórios

Um experimento anterior no `dataset_geral` expandido registrou Dice médio de teste $0{,}9366$ para DeepLabV3-ResNet50. O valor é documentado como histórico porque a base, o tipo de referência e o protocolo diferem do teste manual deduplicado; não é utilizado para alegar progresso de $0{,}9290$ para $0{,}9366$. A Curadoria Web e a inferência integrada estão implementadas, mas ainda não há estudo de revisão humana com efeito quantitativo demonstrado no retreinamento. Da mesma forma, o cálculo das ROIs

córtex–CEC constitui um procedimento operacional disponível, e não uma avaliação concluída de repetibilidade ou associação clínica.

4.10. Artefato computacional: plataforma Web de Curadoria

Além dos experimentos de segmentação, a pesquisa produziu uma aplicação Web funcional para inspeção, edição e documentação de máscaras de ultrassonografia renal. As Figuras 7–9 apresentam a interface de triagem de casos, a visualização ampliada e os controles de correção de estruturas anatômicas. A Figura 10 registra a integração entre máscaras intrarrenais e a comparação visual de duas regiões de interesse de ecogenicidade. A aplicação também disponibiliza um fluxo de inferência para novas imagens, separado da inclusão automática de dados na base de treinamento.

O produto implementado demonstra a viabilidade técnica de reunir predição automática, conferência individual por estrutura, edição das máscaras e registro de decisões em uma infraestrutura local auditável. O histórico de alterações e a separação entre máscaras originais e corrigidas são propriedades da implementação; não constituem, isoladamente, evidência de melhora na acurácia, de concordância interobservador ou de utilidade clínica. A mensuração desses aspectos integra o planejamento experimental subsequente.

5. Discussão

Os resultados mostram uma assimetria entre as tarefas anatômicas. A delimitação da cápsula apresentou Dice de $0{,}9290$ no teste manual deduplicado, enquanto o Dice médio intrarrenal foi $0{,}7594$. A diferença, entretanto, não pode ser interpretada como redução mensurada da qualidade do mesmo modelo em uma única população, porque os conjuntos e as tarefas não coincidem. O que os dois experimentos evidenciam, em seus respectivos protocolos, é que o projeto dispõe de um segmentador externo competitivo e que o detalhamento de córtex e medula ainda constitui um gargalo.

A variabilidade entre anotadores reforça essa leitura. Enquanto a cápsula tem concordância humana relativamente elevada, córtex e medula apresentam menor sobreposição entre referências. Isso expõe duas fontes de erro que devem ser distinguidas: a imprecisão da predição computacional e a ambiguidade da própria anotação. A comparação descritiva com a MAT-UNet (Tabela 10) ajuda a situar a dificuldade relativa das classes, mas diferenças de divisão, anotadores, treinamento e execução impedem um ranking direto entre estudos [Zuo et al. 2025]. O contraste indica valores publicados próximos para a cápsula e o CEC e maior dispersão para córtex e medula; não constitui teste de significância nem comprovação de superioridade de nossa U-Net. Um experimento futuro mais informativo deverá apresentar medidas por exame, distribuição de casos difíceis e, quando viável, múltiplas referências humanas.

O experimento de estabilidade oferece evidência inicial de viabilidade do encadeamento anatômico. Na avaliação específica de medula, substituir a cápsula manual pela prevista teve pequeno efeito na métrica global e preservou elevada correlação de intensidade média. Ainda assim, médias agregadas podem ocultar falhas importantes em exames difíceis. Particularmente em uma cadeia de mensuração, uma região deslocada pode modificar a ROI cortical ou do CEC mesmo quando a sobreposição global é satisfatória. Portanto, a análise de propagação deve ser aprofundada para os três compartimentos intrarrenais e para as medidas pareadas, não apenas para um único descritor de medula.

A pseudo-expansão é um resultado negativo informativo. O aumento de 236 para 578 imagens não elevou o Dice no teste manual da medula, embora a validação tenha melhorado. Existem interpretações plausíveis — seleção de casos redundantes, erros residuais dos pseudorrótulos, mudança de distribuição ou variância de treinamento —, mas os dados aqui apresentados não permitem determinar qual mecanismo predominou. A literatura sobre aprendizado com rótulos imperfeitos e correção de pseudorrótulos sustenta a relevância desse problema [Tajbakhsh et al. 2020, Su et al. 2024, Huang et al. 2025]. O próximo experimento deve separar explicitamente o efeito do volume de treinamento do efeito da qualidade de anotação.

Nesse contexto, o consenso U-Net–DeepLabV3 tem função operacional bem definida: apoiar a triagem. A correlação documentada entre acordo dos modelos e qualidade frente à referência é promissora para ordenar o trabalho de revisão, mas não prova que candidatos de consenso alto sejam anatomicamente corretos. Um estudo *human-in-the-loop* deve medir, por estratos de consenso, taxas de aceitação, correção e rejeição, concordância de revisores, tempo despendido e ganho no desempenho final. Somente essa comparação permitirá estimar o benefício científico e operacional da curadoria implementada.

O piloto inicial de destilação U-Net–DeepLabV3 indicou viabilidade operacional, mas não ganho de acurácia: a estudante obteve Dice $0{,}8847$, inferior aos dois professores, apesar da redução no número de parâmetros e no tempo de passagem direta. A matriz posterior produziu $0{,}9078$ de Dice para a mesma combinação nominal de professores, mas esse valor pertence a uma execução distinta, com outro script e limiar selecionado. A diferença não deve ser interpretada como melhora longitudinal do mesmo checkpoint; ela evidencia a necessidade de congelar o protocolo antes de comparar execuções.

A matriz também permite comparar a estudante destilada com o baseline sem professores. O ganho descritivo de $0{,}8978$ para $0{,}9078$ no Dice e de $0{,}8145$ para $0{,}8312$ no IoU sugere utilidade potencial da transferência, mas a seleção da configuração ocorreu após a observação do teste. Além disso, o maior resultado de validação pertenceu à combinação DeepLabV3–SegFormer-B0, que não foi a melhor no teste. A inclusão de mais professores também não melhorou o resultado: o trio empatou aproximadamente com U-Net–DeepLabV3. Esse comportamento pode decorrer da média de alvos suaves heterogêneos, conflitos entre erros dos professores ou variância de treinamento; os dados atuais não distinguem esses mecanismos. Portanto, a matriz sustenta uma decisão operacional exploratória, não uma demonstração de superioridade da destilação. Mesmo um eventual aumento de Dice no teste interno não substituirá validação em imagens externas e revisão anatômica especializada [Qin et al. 2021, Zhao et al. 2023, Qi et al. 2024].

A análise de ecogenicidade representa a motivação aplicada da segmentação. O uso da imagem original, em lugar de valores após CLAHE, evita introduzir na medida quantitativa o realce produzido especificamente para melhorar a entrada da rede. O pareamento córtex–CEC e a exclusão de bordas tornam explícitas as escolhas de amostragem e podem reduzir certas fontes de heterogeneidade. Entretanto, tais decisões também introduzem hiperparâmetros — raio, posição, número de pares, erosão e aproximação de profundidade — cuja sensibilidade ainda não foi medida. A literatura sobre ecogenicidade relativa fornece motivação, não validação direta desse protocolo particular [Manley and O'Neill 2001, Beutler et al. 2024, Zhao et al. 2025].

Finalmente, a caracterização quantitativa não deve ser confundida com inferência histopatológica. Uma razão córtex–CEC próxima da unidade informa semelhança relativa de intensidades na imagem disponível; ela não identifica, isoladamente, fibrose, IFTA ou doença renal crônica. A avaliação de associações com eGFR ou biópsia exigirá desenho de estudo, variáveis clínicas e análise de fatores de confusão apropriados [Moghazi et al. 2005, Athavale et al. 2021, Qin et al. 2024]. O valor atual do projeto reside, portanto, na integração rastreável entre dado, anatomia, revisão e medida, com fronteiras explícitas entre o demonstrado e o ainda hipotético.

6. Limitações e Ameaças à Validade

Validade interna. Embora a deduplicação e o agrupamento por exame ou paciente reduzam vazamento, diferenças na formação dos subconjuntos e na seleção dos checkpoints precisam continuar documentadas. Na matriz de destilação, a escolha da combinação operacional ocorreu após a observação do teste; por isso, o resultado da configuração escolhida é exploratório e não equivale a uma estimativa final não enviesada. Os resultados agregados não incluem, nesta versão, intervalos de confiança pareados por paciente, múltiplas sementes sistemáticas ou análise uniforme de significância. Resultados históricos em conjuntos expandidos com pseudomáscaras não podem ser interpretados como replicações independentes do benchmark manual.

Validade de construção. Dice e IoU medem concordância espacial, não adequação clínica. Confiança média e acordo entre modelos são indicadores operacionais, não probabilidades calibradas de correção. A discordância interobservador, sobretudo em córtex e medula, mostra que a escolha da anotação de referência afeta a avaliação. Para ecogenicidade, intensidades derivadas de imagens B-mode processadas pelo equipamento não representam propriedades acústicas absolutas do tecido.

Validade externa. Os testes supervisionados documentados utilizam majoritariamente o `kidneyUS`. Imagens externas do MONAI foram processadas sem um conjunto manual de teste consolidado, o que impede estimar a acurácia anatômica nesse domínio. Equipamentos, operadores, população, ganho, TGC, profundidade, compressão e qualidade visual podem modificar tanto a segmentação quanto as razões de brilho.

Validade clínica e operacional. Não existe, nesta etapa, base clínica ou histopatológica pareada suficiente para afirmar detecção de fibrose, IFTA ou DRC. A ferramenta de curadoria preserva versões e decisões, mas sua concordância inter-revisores, custo de uso e benefício no retreinamento ainda precisam de medição prospectiva. A disponibilidade de infraestrutura funcional não equivale a validação do seu impacto.

7. Continuidade da Dissertação

A primeira prioridade é congelar manifestos, checkpoints, protocolos e conjuntos de avaliação, corrigindo divergências de contagens em relatórios históricos e vinculando cada número ao experimento responsável. A segunda é realizar uma rodada piloto de curadoria estratificada por consenso, qualidade visual e fonte, com participação de revisores independentes e medição de concordância, tempo e operações de correção. Após essa etapa, um teste final revisado e independente deverá ser preservado para comparação controlada dos três regimes de treinamento: manual, manual acrescido de pseudorrótulos automáticos e manual acrescido de pseudorrótulos revisados.

O próximo eixo será verificar como as diferenças de segmentação se propagam para a análise intrarrenal e para as medidas de ecogenicidade. O protocolo de ROIs pareadas deverá ser examinado por análise de sensibilidade do tamanho e número de discos, da erosão, da profundidade aproximada e da intervenção do revisor. Repetibilidade intra e interobservador, cobertura de pares válidos e distribuição de erros são desfechos prioritários. Somente após consolidar esses estudos computacionais fará sentido investigar, em uma coorte institucional com governança apropriada, associações com creatinina, eGFR, laudos e eventualmente histopatologia.

8. Conclusão

Este trabalho apresentou a organização de um pipeline rastreável para análise quantitativa de ultrassonografia renal, articulando segmentação da cápsula, consenso entre modelos, curadoria humana, segmentação intrarrenal e mensuração exploratória de ecogenicidade. O teste manual deduplicado documentou Dice de $0{,}9290$ para a cápsula com U-Net; a mesma arquitetura obteve Dice médio $0{,}7594$ na segmentação multiclasse de córtex, medula e CEC em outro conjunto de teste. A estudante destilada aumentou de 3.534 para 3.707 o número de pseudomáscaras externas não vazias no lote MONAI, demonstrando funcionamento operacional, mas não acurácia clínica.

A contribuição científica deve ser interpretada como integração metodológica e avaliação operacional, e não como uma nova arquitetura ou como a primeira aplicação de destilação ao `KidneyUS`. Em relação a trabalhos próximos, como o MK-Net [Chen et al. 2026a], este estudo investiga a combinação de professores heterogêneos, a compactação separada das etapas da cascata, a auditoria por consenso e a revisão humana vinculada à mensuração de ecogenicidade. Os resultados sustentam a viabilidade desse arranjo, mas ainda não demonstram superioridade estatística, confiabilidade anatômica das pseudomáscaras externas ou benefício clínico.

A expansão preliminar de treino de medula não melhorou o Dice do teste manual, evidenciando a necessidade de avaliar qualidade de anotação e efeito da curadoria antes de interpretar quantidade de dados como benefício. A contribuição atual está na estrutura metodológica que preserva proveniência e separa predição automática, revisão humana e medida quantitativa. O protocolo córtex–CEC constitui uma etapa promissora para estudos de estabilidade de imagem, ainda sem validação clínica. A continuidade da pesquisa deverá testar o efeito da revisão humana e a repetibilidade das medidas, mantendo a interpretação de fibrose e de doença renal crônica fora do escopo dos resultados atualmente demonstrados.

Referências

Aljabri, M., AlAmir, M., AlGhamdi, M., Abdel-Mottaleb, M., and Collado-Mesa, F. (2022). Towards a better understanding of annotation tools for medical imaging: A survey. *Multimedia Tools and Applications*, 81(18):25877–25911.

Araújo, N. C., da Silveira Rioja, L., and Suassuna, J. H. R. (2026). Correlation between computer-assisted ultrasonographic parameters and histological findings in glomerular diseases: A multivariate ordinal analysis. *Journal of Clinical Ultrasound*, 54(8):1885–1893.

Artsi, Y., Klang, E., Collins, J. D., Glicksberg, B. S., Nadkarni, G. N., Korfiatis, P., and Sorin, V. (2025). Large language models in radiology reporting - a systematic review

of performance, limitations, and clinical implications. *Intelligence-Based Medicine*, 12:100287.

Athavale, A. M., Hart, P. D., Itteera, M., Cimbaluk, D., Patel, T., Alabkaa, A., Arruda, J., Singh, A., Rosenberg, A., and Kulkarni, H. (2021). Development and validation of a deep learning model to quantify interstitial fibrosis and tubular atrophy from kidney ultrasonography images. *JAMA Network Open*, 4(5):e2111176.

Bai, S., Chen, K., Liu, X., Wang, J., Ge, W., Song, S., Dang, K., Wang, P., et al. (2025). Qwen2.5-vl technical report.

Beutler, B. D., El-Sabawi, B., Walker, D. K., Cen, S., and Tchelepi, H. (2024). An objective computer-assisted measurement of sonographic renal cortical echogenicity: The splenorenal index. *Ultrasound Quarterly*, 40(1).

Bluethgen, C., Van Veen, D., Zakka, C., Link, K. E., Fanous, A. H., Daneshjou, R., Frauenfelder, T., Langlotz, C. P., Gatidis, S., and Chaudhari, A. (2025). Best practices for large language models in radiology. *Radiology*, 315(1).

Budd, S., Robinson, E. C., and Kainz, B. (2021). A survey on active learning and human-in-the-loop deep learning for medical image analysis. *Medical Image Analysis*, 71:102062.

Busch, F., Hoffmann, L., Pinto dos Santos, D., Makowski, M. R., Saba, L., Prucker, P., Hadamitzky, M., Navab, N., Kather, J. N., Truhn, D., Cuocolo, R., Adams, L. C., and Bressem, K. K. (2025). Large language models for structured reporting in radiology: past, present, and future. *European Radiology*, 35(5):2589–2602.

Chen, B., Liu, C., Qi, W., and Chan, S.-C. (2026a). MK-Net: A multi-scale semantic propagation and base-channel distillation network for multi-class kidney ultrasound segmentation. In *2026 IEEE International Symposium on Circuits and Systems*, pages 155–159. IEEE.

Chen, L.-C., Papandreou, G., Schroff, F., and Adam, H. (2017). Rethinking atrous convolution for semantic image segmentation.

Chen, L.-C., Zhu, Y., Papandreou, G., Schroff, F., and Adam, H. (2018). Encoder-decoder with atrous separable convolution for semantic image segmentation. In *Proceedings of the European Conference on Computer Vision (ECCV)*, pages 801–818.

Chen, Z., Wang, Y., and Chen, F. (2026b). Comparative performance of multimodal large language models in grayscale ultrasound-based classification of thyroid nodules. *Seminars in Ultrasound, CT and MRI*.

Cheng, Y., Wang, R., Hong, X., Wang, C., Yin, Y., Wang, J., Liu, X., Yang, L., Yi, L., Zhao, X., and Wang, Z. (2026). Benchmarking open-source large language models for breast ultrasound report processing: A multicenter study. *Diagnostics*, 16(21):3502.

Cui, H., Mao, L., Liang, X., Zhang, J., Ren, H., Li, Q., Li, X., and Yang, C. (2024). Biomedical visual instruction tuning with clinician preference alignment.

CVAT.ai (2026). CVAT: Computer vision annotation tool documentation. `https://docs.cvat.ai/`. Documentacao tecnica consultada em outubro de 2026.

Diaz-Pinto, A., Alle, S., Nath, V., Tang, Y., Ihsani, A., et al. (2024). MONAI Label: A framework for AI-assisted interactive labeling of 3D medical images. *Medical Image Analysis*, 95:103207.

Elhaie, M., Koozari, A., Nasab, A. S., and Dehaghi, F. T. (2026). Diagnostic accuracy of ai-augmented renal ultrasound for degenerative kidney disorders: a systematic review and meta-analysis. *Future Science OA*, 12(1).

Hao, P., Zhang, J., Zhang, S., Wu, F., and Tian, S. (2026). Ultrareporter for transforming spoken diagnostic cues into structured ultrasound reports with large language models. *Scientific Reports*, 16(1).

Hinton, G., Vinyals, O., and Dean, J. (2015). Distilling the knowledge in a neural network.

Huang, S., Wang, S., Qiao, S., Liu, Y., and Liu, T. (2025). Semi-plc: A framework for semi-supervised medical images segmentation with pseudo label correction. *Computer Methods and Programs in Biomedicine*, 271:109027.

Jiao, R., Zhang, Y., Ding, L., Xue, B., Zhang, J., Cai, R., and Jin, C. (2024). Learning with limited annotations: A survey on deep semi-supervised learning for medical image segmentation. *Computers in Biology and Medicine*, 169:107840.

Khan, R., Xiao, C., Liu, Y., Tian, J., Chen, Z., Su, L., Li, D., Hassan, H., Li, H., Xie, W., Zhong, W., and Huang, B. (2024). Transformative deep neural network approaches in kidney ultrasound segmentation: Empirical validation with an annotated dataset. *Interdisciplinary Sciences: Computational Life Sciences*, 16(2):439–454.

Lee, D.-H. (2013). Pseudo-label: The simple and efficient semi-supervised learning method for deep neural networks. In *Workshop on Challenges in Representation Learning, ICML*, volume 3.

Li, C., Wong, C., Zhang, S., Usuyama, N., Liu, H., Yang, J., Naumann, T., Poon, H., and Gao, J. (2023). Llava-med: Training a large language-and-vision assistant for biomedicine in one day.

Ma, J., He, Y., Li, F., Han, L., You, C., and Wang, B. (2024). Segment anything in medical images. *Nature Communications*, 15:654.

Manley, J. A. and O'Neill, W. C. (2001). How echogenic is echogenic? quantitative acoustics of the renal cortex. *American Journal of Kidney Diseases*, 37(4):706–711.

Moghazi, S., Jones, E., Schroepple, J., et al. (2005). Correlation of renal histopathology with sonographic findings. *Kidney International*, 67(4):1515–1520.

MONAI Development Team (2026). Clinical ultrasound image repository. AWS Open Data Registry. Accessed May 2026.

OHIF (2026). OHIF medical imaging viewer documentation. `https://docs.ohif.org/`. Documentacao tecnica consultada em outubro de 2026.

Qi, X., Wu, Z., Zou, W., Ren, M., Gao, Y., Sun, M., Zhang, S., Shan, C., and Sun, Z. (2024). Exploring generalizable distillation for efficient medical image segmentation. *IEEE Journal of Biomedical and Health Informatics*, 28(7):4170–4183.

Qin, D., Bu, J.-J., Liu, Z., Shen, X., Zhou, S., Gu, J.-J., Wang, Z.-H., Wu, L., and Dai, H.-F. (2021). Efficient medical image segmentation based on knowledge distillation. *IEEE Transactions on Medical Imaging*, 40(12):3820–3831.

Qin, X., Liu, X., Xia, L., Luo, Q., and Zhang, C. (2024). Multimodal ultrasound deep learning to detect fibrosis in early chronic kidney disease. *Renal Failure*, 46(2):2417740.

Reichenpfader, D., Müller, H., and Denecke, K. (2024). A scoping review of large language model based approaches for information extraction from radiology reports. *npj Digital Medicine*, 7(1).

Ronneberger, O., Fischer, P., and Brox, T. (2015). U-net: Convolutional networks for biomedical image segmentation. In *Medical Image Computing and Computer-Assisted Intervention (MICCAI)*, pages 234–241.

Sellergren, A., Kazemzadeh, S., Mahvar, F., et al. (2026). An open vision-language model for diverse medical applications. *Nature Medicine*, 32(10):3695–3704.

Shu, C., Liu, Y., Gao, J., Yan, Z., and Shen, C. (2021). Channel-wise knowledge distillation for dense prediction. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 5311–5320.

Singla, R., Ringstrom, C., Hu, G., Lessoway, V., Reid, J., Nguan, C., and Rohling, R. (2023). The open kidney ultrasound data set. In *Simplifying Medical Ultrasound*, volume 14337 of *Lecture Notes in Computer Science*, pages 155–164. Springer Nature Switzerland.

Su, J., Luo, Z., Lian, S., Lin, D., and Li, S. (2024). Mutual learning with reliable pseudo label for semi-supervised medical image segmentation. *Medical Image Analysis*, 94:103111.

Taha, A. A. and Hanbury, A. (2015). Metrics for evaluating 3d medical image segmentation: Analysis, selection, and tool. *BMC Medical Imaging*, 15(29).

Tajbakhsh, N., Jeyaseelan, L., Li, Q., Chiang, J. N., Wu, Z., and Ding, X. (2020). Embracing imperfect datasets: A review of deep learning solutions for medical image segmentation. *Medical Image Analysis*, 63:101693.

Wang, C., Banerjee, R., Kuperstein, H., Malick, H., Bano, R., Cunningham, R. L., Tahir, H., Sakhuja, P., Hajagos, J., and Koraishy, F. M. (2025). Natural language processing for kidney ultrasound analysis: correlating imaging reports with chronic kidney disease diagnosis. *Renal Failure*, 47(1).

Xie, E., Wang, W., Yu, Z., Anandkumar, A., Alvarez, J. M., and Luo, P. (2021). Segformer: Simple and efficient design for semantic segmentation with transformers. *Advances in Neural Information Processing Systems*, 34:12077–12090.

Zhang, L., Li, X., Qi, R., Wang, S., Shi, X., Song, Y., Li, L., Zhang, N., and Ge, H. (2026a). A comparative study of large language models (chatgpt/deepseek) in generating structured thyroid ultrasound reports. *Scientific Reports*, 16(1).

Zhang, Y., Hou, Y., Qiu, T., Zhuang, Y., Chen, K., Ling, W., Luo, Y., and Lin, J. (2026b). Deep learning in renal ultrasound: applications, challenges, and future outlook. *Frontiers in Oncology*, 15:1730628.

Zhao, L., Qian, X., Guo, Y., Song, J., Hou, J., and Gong, J. (2023). MSKD: Structured knowledge distillation for efficient medical image segmentation. *Computers in Biology and Medicine*, 164:107284.

Zhao, L., Shang, J., Shi, Y., Yan, Y., Li, P., Niu, W., Zhang, G., Ding, Z., Chu, X., Wang, T., and Zheng, S. (2025). Quantifying ultrasound echogenicity difference for accurate chronic kidney disease diagnosis. *Journal of Nephrology*, 38(8):2353–2362.

Zhou, Z., Siddiquee, M. M. R., Tajbakhsh, N., and Liang, J. (2018). Unet++: A nested u-net architecture for medical image segmentation. In *Deep Learning in Medical Image Analysis and Multimodal Learning for Clinical Decision Support*, volume 11045 of *Lecture Notes in Computer Science*, pages 3–11. Springer.

Zuo, Y., Li, J., and Tian, J. (2025). A segmentation network with two distinct attention modules for the segmentation of multiple renal structures in ultrasound images. *Diagnostics*, 15(15):1978.