Segmentação Renal, Curadoria *Human-in-the-Loop* e Quantificação da Ecogenicidade em Ultrassonografia: um Pipeline Rastreável para Caracterização Intrarrenal

Jefferson S. dos Anjos[1]

[1 1] CEFET/RJ – Rio de Janeiro – RJ – Brasil
[2] HUPE – UERJ – Rio de Janeiro – RJ – Brasil

jefferson.anjos.1@aluno.cefet-rj.br,

{amaro.lima,gabriel.araujo,felipe.henriques}@cefet-rj.br,

{jorge.henriques,norderval.norderval}@uerj.br

Abstract. *Renal ultrasound is widely available, but anatomical segmentation and image quantification remain sensitive to acquisition variability, ambiguous tissue boundaries and scarce expert annotations. This study develops a traceable pipeline linking renal capsule segmentation, model-agreement analysis, human-in-the-loop curation, multiclass intrarenal segmentation and quantitative echogenicity measurements. The kidneyUS dataset provides the manually annotated reference. In a deduplicated 70-image test set, U-Net achieved Dice 0.9290 and IoU 0.8722 for capsule segmentation. Applied to 4,479 external MONAI images, the selected model produced 3,534 candidate pseudomasks, which were not treated as manually validated ground truth. For cortex, medulla and central echo complex, multiclass U-Net achieved mean Dice 0.7594 in 50 manually annotated test images. A preliminary medulla training-set expansion from 236 to 578 images did not improve test Dice (0.7528 versus 0.7523). These findings motivate a controlled comparison between automatic pseudolabeling and expert-reviewed data. Echogenicity measures are computed from the original B-mode image using anatomically constrained regions of interest; their repeatability and clinical associations remain to be established. The contribution is an auditable methodological framework, not an automatic diagnosis of fibrosis or chronic kidney disease.*

Resumo. *A ultrassonografia renal é amplamente disponível, mas sua análise computacional depende da delimitação de estruturas com fronteiras pouco definidas, de condições variáveis de aquisição e de anotações especializadas escassas. Este trabalho desenvolve um pipeline rastreável que integra segmentação da cápsula, concordância entre modelos, curadoria human-in-the-loop, segmentação intrarrenal multiclasse e medidas quantitativas de ecogenicidade. O* `kidneyUS` *constitui a referência manual. No teste deduplicado de 70 imagens, a U-Net alcançou Dice de 0,9290 e IoU de 0,8722 para a cápsula. Em 4.479 imagens externas do MONAI, o modelo produziu 3.534 pseudomáscaras candidatas, mantidas separadas da referência manual. Para córtex, medula e complexo ecogênico central, a U-Net multiclasse obteve Dice médio de 0,7594 em 50 imagens de teste. A expansão preliminar de 236 para 578 imagens no treinamento da medula não aumentou o Dice de teste (0,7528 contra 0,7523), reforçando a necessidade de avaliar a qualidade dos pseudorrótulos. As medidas de ecogenicidade são obtidas*

da imagem original por regiões de interesse anatomicamente restritas; sua repetibilidade e suas associações clínicas ainda precisam ser demonstradas. A contribuição atual é metodológica e auditável, sem alegação de diagnóstico automático de fibrose ou doença renal crônica.

1. Introdução

A ultrassonografia é utilizada na avaliação morfológica renal por oferecer aquisição não invasiva, disponibilidade clínica e visualização em tempo real. Entretanto, a interpretação de suas imagens permanece dependente do operador e das condições de aquisição. Ruído *speckle*, sombras acústicas, variações de ganho, profundidade, enquadramento e pós-processamento alteram a aparência dos tecidos, dificultando tanto a delimitação do órgão quanto a comparação de intensidades. Esse problema torna-se especialmente relevante quando se pretende quantificar regiões internas: uma estimativa de brilho pode incorporar pixels de tecido adjacente, fundo ou artefatos se a região anatômica não estiver corretamente identificada.

A tarefa computacional pode ser decomposta em dois níveis relacionados. O primeiro consiste em localizar a cápsula renal e produzir uma máscara externa confiável. O segundo consiste em identificar estruturas de interesse no interior dessa máscara, particularmente córtex, medula e complexo ecogênico central (CEC). A segmentação externa reduz a área de busca, mas também introduz dependência entre etapas: um contorno incompleto pode eliminar tecido relevante, enquanto uma máscara excessiva pode contaminar a caracterização intrarrenal. Portanto, o desempenho de cada segmentador, considerado isoladamente, não descreve toda a confiabilidade de uma cadeia de análise.

Outro obstáculo é a disponibilidade de anotações. A marcação pixel a pixel requer conhecimento anatômico e pode variar entre observadores, principalmente nas interfaces córtico-medulares. O uso de pseudorrótulos para imagens não anotadas é uma alternativa estudada em aprendizado semi-supervisionado, mas previsões de elevada confiança podem permanecer anatomicamente incorretas [Lee 2013, Jiao et al. 2024, Su et al. 2024]. Isso exige distinguir três objetos diferentes: a proposta automática, a anotação humana e a máscara corrigida após revisão. O consenso entre arquiteturas pode ajudar a ordenar casos para inspeção, mas não deve ser confundido com acurácia individual nem convertido diretamente em referência clínica.

No domínio da imagem renal, a ecogenicidade cortical e a relação entre regiões anatômicas têm sido investigadas como descritores quantitativos associados a características funcionais ou histológicas [Manley and O'Neill 2001, Moghazi et al. 2005, Beutler et al. 2024, Zhao et al. 2025]. Entretanto, a ecogenicidade não é específica para fibrose; além disso, seus valores são afetados por parâmetros de aquisição. Dessa maneira, a passagem de uma máscara segmentada para uma medida de intensidade exige um protocolo explícito de seleção de regiões de interesse (ROIs), controle de artefatos e análise de repetibilidade, antes de qualquer inferência clínica.

Diante desse cenário, a questão que orienta esta pesquisa é: *como integrar segmentação anatômica, estimativas de estabilidade e revisão humana em um fluxo rastreável capaz de produzir descritores quantitativos de ultrassonografia renal cuja confiabilidade possa ser avaliada?* A hipótese metodológica a ser examinada é que a qualidade e a procedência das máscaras influenciam a estabilidade das medidas

intrarrenais, de modo que a curadoria humana pode ser mais relevante do que a simples inclusão de um maior número de pseudorrótulos. Essa hipótese ainda não corresponde a um efeito comprovado pelos experimentos atuais.

O objetivo geral é desenvolver e avaliar um pipeline de visão computacional para delimitação anatômica e caracterização quantitativa de ultrassonografias renais, preservando a proveniência de imagens, máscaras, modelos e revisões. Os objetivos específicos são estabelecer um benchmark supervisionado e deduplicado da cápsula; avaliar a concordância entre segmentadores na triagem de imagens externas; comparar segmentadores intrarrenais e sua relação com a variabilidade entre anotadores; investigar o efeito preliminar da pseudo-expansão; implementar curadoria auditável; e especificar medidas de ecogenicidade calculadas na imagem original. A validação da influência da revisão humana e a associação com desfechos clínicos constituem etapas posteriores.

A contribuição apresentada não consiste em propor uma nova arquitetura neural, mas em articular problemas normalmente avaliados separadamente. O `kidneyUS`, com anotações independentes, sustenta os testes supervisionados [Singla et al. 2023]; imagens externas são destinadas à geração de candidatos para revisão; e o mesmo encadeamento anatômico alimenta um protocolo quantitativo exploratório. O texto distingue resultados efetivamente medidos, componentes implementados e estudos planejados, prevenindo que uma boa métrica de segmentação seja interpretada como evidência de identificação de doença renal.

2. Fundamentação e Trabalhos Relacionados

2.1. Dados anotados e desafios da segmentação renal

A segmentação de ultrassonografias renais é dificultada pela variabilidade do formato do órgão, pelo contraste heterogêneo e pela presença de artefatos que compartilham intensidade com o parênquima. O `Open Kidney Ultrasound Data Set` (`kidneyUS`) foi disponibilizado com imagens e anotações de estruturas renais, incluindo marcações independentes que possibilitam estudar tanto o desempenho computacional quanto a variabilidade de referência [Singla et al. 2023]. A existência de dois observadores é particularmente importante: uma métrica obtida contra um único anotador não representa, por si só, um limite universal de precisão anatômica.

A arquitetura U-Net associa codificação e decodificação a conexões de salto e tornou-se um baseline recorrente em segmentação biomédica [Ronneberger et al. 2015]. UNet++ propõe conexões de salto densas; DeepLabV3 explora contexto multiescala por convoluções atrous; e SegFormer combina representação hierárquica e mecanismos baseados em transformadores [Zhou et al. 2018, Chen et al. 2018, Xie et al. 2021]. A comparação dessas famílias não deve se restringir ao maior Dice: características de borda, custo de inferência, estabilidade em casos difíceis e sensibilidade aos dados de treinamento também influenciam a escolha do modelo para a cascata. Estudos específicos de ultrassom renal reforçam a relevância de qualidade de imagem, preparação da entrada e contexto anatômico [Khan et al. 2024, Zuo et al. 2025].

A segmentação intrarrenal apresenta um grau adicional de dificuldade. Córtex, medula e CEC não têm necessariamente fronteiras visualmente inequívocas em todo exame; pequenas variações de anotação podem produzir diferenças substanciais de sobreposição, especialmente em estruturas menores. Por isso, este trabalho utiliza resultados por classe e concordância entre anotadores, evitando que uma média agregada esconda falhas localizadas.

2.2. Pseudorrótulos, consenso e confiabilidade das máscaras

Pseudorrotulação é a utilização de saídas de modelos como supervisão candidata para exemplos não rotulados [Lee 2013]. Sua vantagem operacional reside na possibilidade de ampliar a cobertura do conjunto sem repetir integralmente o esforço de anotação. O risco é incorporar erros sistemáticos e reforçar padrões inadequados em sucessivos treinamentos. Revisões e propostas recentes discutem aprendizado semi-supervisionado, consistência, estimativas de incerteza e correção de pseudorrótulos em imagens médicas [Jiao et al. 2024, Tajbakhsh et al. 2020, Su et al. 2024, Huang et al. 2025].

Neste projeto, duas redes de famílias diferentes segmentam a mesma imagem. O Dice entre suas máscaras é utilizado como medida de concordância *entre modelos*, não como Dice frente à anatomia verdadeira. Mesmo duas redes concordantes podem compartilhar um erro; por outro lado, baixa concordância ajuda a identificar casos que merecem inspeção. A calibração *out-of-fold* procura estudar a associação desse indicador com o erro observado em dados manuais não usados pelo modelo avaliado. A passagem desse indicador para regras de seleção de dados requer validação adicional.

2.3. Curadoria *human-in-the-loop*

Em sistemas *human-in-the-loop*, modelos e revisores desempenham funções complementares: a automação fornece propostas e prioriza casos, enquanto humanos inspecionam, corrigem ou rejeitam saídas [Budd et al. 2021]. A distinção não é apenas operacional. Uma máscara revisada deve conservar seus metadados de origem, o modelo que a produziu, a identidade ou código do revisor, a decisão tomada e a versão da correção. Sem essa trilha de auditoria, não é possível atribuir eventuais ganhos de treinamento à quantidade de dados ou à intervenção especializada.

O sistema desenvolvido mantém a predição original e a máscara corrigida como objetos distintos e registra revisões por estrutura anatômica. A hipótese de que essa estratégia produzirá melhores modelos ou medidas mais estáveis exige comparação controlada entre treinamento manual, pseudo-expansão automática e pseudo-expansão revisada, e não pode ser presumida da existência da interface.

2.4. Ecogenicidade quantitativa e limites da interpretação clínica

A ecogenicidade cortical tem sido quantificada por comparação com órgãos ou estruturas de referência. Manley e O'Neill discutem a quantificação cortical; estudos posteriores exploram medidas relativas envolvendo baço ou seio renal e suas associações com indicadores funcionais [Manley and O'Neill 2001, Beutler et al. 2024, Zhao et al. 2025]. Esses trabalhos motivam o uso de razões, diferenças e contrastes normalizados, mas seus protocolos e órgãos de referência não são automaticamente intercambiáveis. A comparação córtex–CEC desta pesquisa é um protocolo intrarrenal específico, cuja equivalência a medidas da literatura não foi demonstrada.

A interpretação de aumento de ecogenicidade também requer cautela. Moghazi et al. investigaram relações entre características ultrassonográficas e biópsia, evidenciando associações que não tornam uma medida isolada específica para fibrose [Moghazi et al. 2005]. Pesquisas voltadas a IFTA ou fibrose utilizam desfechos histopatológicos e, em alguns casos, combinações de modalidades de imagem [Athavale et al. 2021, Qin et al. 2024]. Como o presente projeto não dispõe de uma coorte histopatológica pareada suficiente, sua contribuição limita-se à caracterização quantitativa de padrões de imagem, não à classificação validada de fibrose.

2.5. Lacuna e posicionamento da proposta

Os trabalhos anteriores sustentam três frentes complementares: segmentar estruturas, aproveitar dados pouco anotados e investigar descritores de ecogenicidade. A questão abordada aqui é a ligação rastreável entre elas. Uma máscara com bom desempenho médio pode falhar em uma imagem específica; uma pseudomáscara pode ser plausível sem estar correta; e uma medida de brilho pode variar por razões não patológicas. O pipeline proposto reúne essas dependências em um mesmo protocolo, tornando explícito quais resultados já foram medidos e quais precisam de avaliação futura.

3. Evolução Metodológica da Pesquisa

A pesquisa iniciou-se com a comparação de arquiteturas para segmentação binária do rim. Nessa configuração, o principal resultado era uma máscara externa e sua concordância com anotações manuais. A limitação de imagens supervisionadas levou à busca por fontes adicionais e à construção de procedimentos de download, conversão, deduplicação e organização de dados externos. Essa evolução ampliou a diversidade potencial de imagens, mas introduziu um problema de procedência: dados externos sem anotações não poderiam ser tratados como equivalentes ao conjunto manual.

Uma fase exploratória posterior utilizou filtros de confiança, tamanho e geometria para escolher pseudomáscaras. A observação de predições aparentemente confiantes, porém anatomicamente questionáveis, motivou uma mudança metodológica: os filtros deixaram de significar aceitação automática e passaram a funcionar como critérios de triagem. Foi então acrescentado o consenso U-Net–DeepLabV3, calibrado por predições *out-of-fold*, para estimar a estabilidade entre modelos independentes.

A investigação avançou da cápsula para a medula e, posteriormente, para segmentação multiclasse de córtex, medula e CEC. O experimento de pseudo-expansão da medula forneceu uma observação decisiva: o aumento do treino não produziu melhora no teste manual. Isso justificou tornar a curadoria *human-in-the-loop* um componente explícito, com edição, aprovação, histórico e persistência de versões.

A etapa mais recente encadeia cápsula, estruturas intrarrenais e mensuração de ecogenicidade. Nesse momento, tornou-se necessário separar ainda mais claramente o pré-processamento usado na inferência do dado usado na análise quantitativa. A mensuração passou a ser realizada na imagem original, por ROIs anatomicamente delimitadas, com resultados exploratórios. Esta seção descreve a origem das escolhas experimentais; as seções seguintes apresentam os protocolos que podem ser reproduzidos e os limites das evidências já obtidas.

4. Materiais e Métodos

4.1. Desenho experimental e unidades de avaliação

O estudo compreende três eixos: (i) segmentação supervisionada da cápsula; (ii) segmentação e estabilidade de estruturas intrarrenais; e (iii) engenharia de dados, curadoria e quantificação exploratória. Esses eixos não compartilham necessariamente as mesmas amostras nem os mesmos protocolos. Por isso, cada resultado é apresentado juntamente com sua tarefa, a origem do dado e o tipo de referência. Resultados de conjuntos expandidos com pseudorrótulos não são comparados diretamente com testes manuais deduplicados.

A referência supervisionada principal é o `kidneyUS` [Singla et al. 2023]. Os polígonos fornecidos nas anotações são rasterizados para produzir máscaras. A análise

da cápsula parte de 486 registros do primeiro anotador que correspondem a 468 imagens únicas; após deduplicação e agrupamento por exame, foram destinadas 328 imagens a treino, 70 a validação e 70 a teste. A tarefa intrarrenal multiclasse utiliza 335 imagens (235/50/50) e a tarefa binária de medula utiliza 336 imagens (236/50/50), conforme os respectivos critérios de elegibilidade. Na divisão intrarrenal, o agrupamento por paciente evita que imagens de um mesmo indivíduo sejam distribuídas entre conjuntos de desenvolvimento e teste.

Tabela 1. Conjuntos supervisionados do estudo. Os testes de tarefas diferentes não representam uma mesma amostra.

Tarefa	Total	Treino	Val.	Teste
Cápsula deduplicada	468	328	70	70
Intrarrenal multiclasse	335	235	50	50
Medula binária	336	236	50	50

A deduplicação por hash identifica conteúdos idênticos; o agrupamento por exame ou paciente busca reduzir vazamento de informação por imagens correlacionadas. Quando existem múltiplas representações de anotação para o mesmo conteúdo, o procedimento de preparação define a amostra de referência usada no experimento. A estratégia de divisão, os manifestos e as configurações dos modelos devem acompanhar os resultados para permitir auditoria. A separação reduz, mas não exclui, o risco de semelhanças residuais e de mudança de distribuição entre fontes.

4.2. Pré-processamento e benchmark da cápsula

Os segmentadores são treinados com imagens normalizadas e redimensionadas; na configuração deduplicada de referência da U-Net, a entrada possui 256 por 256 pixels, CLAHE é aplicado ao ramo de segmentação e o aumento de dados é restrito ao treinamento. O treinamento registrado utiliza AdamW, taxa inicial de aprendizado de 10^{-4} e perda combinada de entropia cruzada binária e Dice. A seleção do checkpoint e do limiar de decisão ocorre com base na validação; para a U-Net de cápsula consolidada, o limiar documentado é $0{,}35$. A inferência de pseudomáscaras externas utiliza também a imagem espelhada horizontalmente, agregando as previsões antes da binarização.

U-Net, UNet++, DeepLabV3-ResNet50 e SegFormer-B0 são comparados no mesmo teste deduplicado. A qualidade de sobreposição é reportada por Dice e IoU; precisão e *recall* identificam tendências de supersegmentação ou omissão, enquanto quadros por segundo (FPS) informam o custo de inferência nas condições do benchmark. A arquitetura selecionada para a cascata é a U-Net, por seu desempenho de segmentação observado nesse protocolo, e não por superioridade universal sobre as demais.

4.3. Fonte externa, pseudomáscaras e consenso

Para estudar expansão de dados, metadados do repositório clínico MONAI/NVIDIA foram filtrados por exames renais ou retroperitoneais. DICOMs candidatos foram processados em lotes; foram mantidos quadros adequados ao estudo em escala de cinza, reduzidas sequências temporais e descartados, por padrão, quadros RGB ou coloridos. O conjunto externo consolidado contém 4.479 imagens. Essas imagens não são parte do teste supervisionado da cápsula e não dispõem, nesse fluxo, de referência manual suficiente para estimar Dice externo.

A U-Net gera propostas de máscara renal. Para uma máscara candidata não vazia M, a confiança operacional média é definida por

$$C(M) = \frac{1}{|M|} \sum_{i \in M} p_i, \tag{1}$$

em que p_i é a probabilidade atribuída ao primeiro plano no pixel i. Essa estatística resume a confiança dos pixels selecionados, mas não estima diretamente a probabilidade de toda a máscara estar correta. Componentes conectados, plausibilidade geométrica e características da predição são usados para preparação e priorização, sem converter automaticamente a proposta em *ground truth*.

A mesma imagem é processada por uma DeepLabV3 independente. A concordância espacial entre as duas predições é

$$S(M_U, M_D) = \frac{2|M_U \cap M_D|}{|M_U| + |M_D|}, \tag{2}$$

calculada para máscaras não vazias com denominador válido. O indicador foi calibrado por validação cruzada *out-of-fold* em cinco folds agrupados por exame, para que cada amostra manual fosse avaliada por modelos que não a haviam utilizado naquele fold. Limiares operacionais de $0{,}89$ e $0{,}94$, derivados da distribuição de calibração documentada, organizam a fila de revisão; eles não certificam a qualidade anatômica. O manifesto preserva fonte, modelo, checkpoint, estado e indicadores associados a cada predição.

4.4. Segmentação intrarrenal e propagação de erro

A análise interna prediz quatro classes: fundo, córtex, medula e CEC. A U-Net multiclasse e a DeepLabV3 multiclasse recebem, no fluxo consolidado, três canais correspondentes à ROI em tons de cinza, à ROI com o exterior do rim mascarado e à máscara de cápsula. O treinamento da U-Net documentado utiliza imagens de 256 por 256 pixels, AdamW, taxa inicial de 10^{-4} e perda de entropia cruzada multiclasse combinada com Dice. A avaliação reporta Dice e IoU por estrutura, além das médias sobre as classes de primeiro plano.

Duas séries independentes de anotações do `kidneyUS` permitem calcular concordância interobservador por estrutura. Esse resultado serve para contextualizar ambiguidades da referência, sem estabelecer que a rede superou um humano: as comparações humano–humano e modelo–anotador possuem pares e desenhos distintos.

A dependência entre estágios é investigada em um experimento de estabilidade: o segmentador especializado de medula é aplicado inicialmente com ROI definida pela cápsula manual e depois com ROI produzida pelo modelo renal. A mudança na máscara e em medidas de intensidade permite observar a sensibilidade da etapa interna a erros da primeira. Trata-se de um experimento específico de medula e não substitui a avaliação completa da cascata multiclasse em novos dados.

4.5. Pseudo-expansão controlada da medula

DeepLabV3 e MedullaROIUNet produzem candidatos independentes de máscara de medula. A seleção automática combina concordância e restrições geométricas; um experimento acrescentou 342 pseudomáscaras às 236 imagens de treino manual,

totalizando 578 exemplos. As 50 imagens de validação e as 50 de teste permaneceram manuais. A comparação resultante examina o efeito desse conjunto específico de pseudorrótulos; não mede o efeito de uma curadoria humana completa nem garante equivalência entre conjuntos de tamanhos diferentes.

4.6. Curadoria Web: implementação e fluxo de revisão humana

Como artefato computacional desta pesquisa, foi desenvolvida a plataforma *Curadoria Web*, implementada no diretório `curadoria_web/` do repositório. Seu objetivo é integrar a inspeção de imagens ultrassonográficas, a conferência das predições anatômicas e a revisão humana em um mesmo ambiente. A arquitetura separa o servidor de aplicação em Python, responsável pelas operações sobre casos, máscaras e persistência, da interface desenvolvida com HTML, CSS e JavaScript. O sistema utiliza um manifesto de casos para carregar as imagens e suas versões de máscaras e mantém em banco SQLite os registros da curadoria.

O fluxo de trabalho começa com a identificação do revisor e a seleção de um caso na fila. A tela permite filtrar a origem das anotações e o estado da revisão, consultar as informações do modelo e sobrepor ou ocultar individualmente as camadas de rim, córtex, medula e complexo ecogênico central. O revisor pode classificar cada estrutura como aceita, a corrigir, rejeitada ou indisponível. Quando necessária, a correção pode ser realizada por polígono, pincel ou borracha; as operações permitem substituir, adicionar ou remover áreas da máscara. As edições são registradas sem sobrescrever a predição original, de modo que a máscara revisada possa ser distinguida da máscara proposta pelo modelo.

A Figura 1 apresenta a organização do ambiente, ao passo que as Figuras 2 e 3 documentam, respectivamente, a inspeção ampliada de um exame e a ferramenta utilizada para preparar uma correção manual. O sistema preserva informações como revisor, estrutura, estado, operação e data da atualização, além do histórico das máscaras corrigidas. Na recuperação de uma imagem, uma correção manual disponível tem precedência sobre a proposta automática para a visualização do próprio revisor. Esses mecanismos estabelecem rastreabilidade operacional; a medida do tempo gasto, a concordância entre revisores e o ganho decorrente de retreinamento com dados revisados permanecem questões experimentais em aberto.

A Figura 1 documenta a disposição da fila de curadoria, a identificação do revisor e os controles disponíveis na interface.

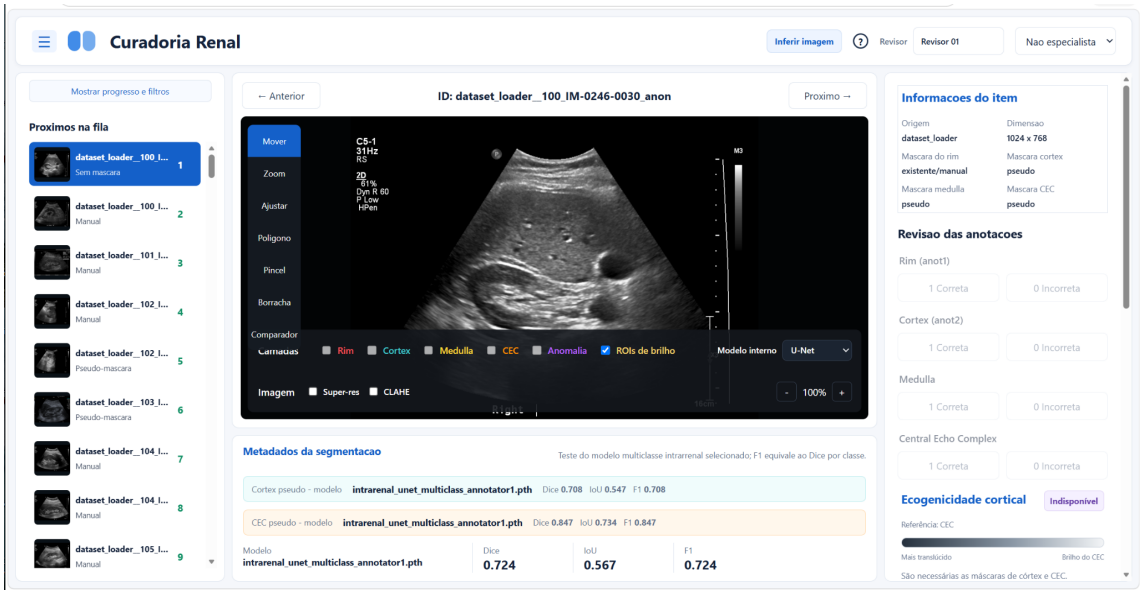


Figura 1. Tela da Curadoria Web desenvolvida na pesquisa: fila de imagens à esquerda, visualizador central, metadados dos segmentadores e formulário de revisão à direita. No registro apresentado, o painel de progresso e filtros encontra-se recolhido. Fonte: captura de tela da implementação.

A Figura 2 mostra a modalidade de visualização ampliada do mesmo caso, útil para examinar a imagem renal sem distrações dos painéis laterais. Nessa captura, as máscaras estão desativadas; elas podem ser habilitadas individualmente na aplicação.

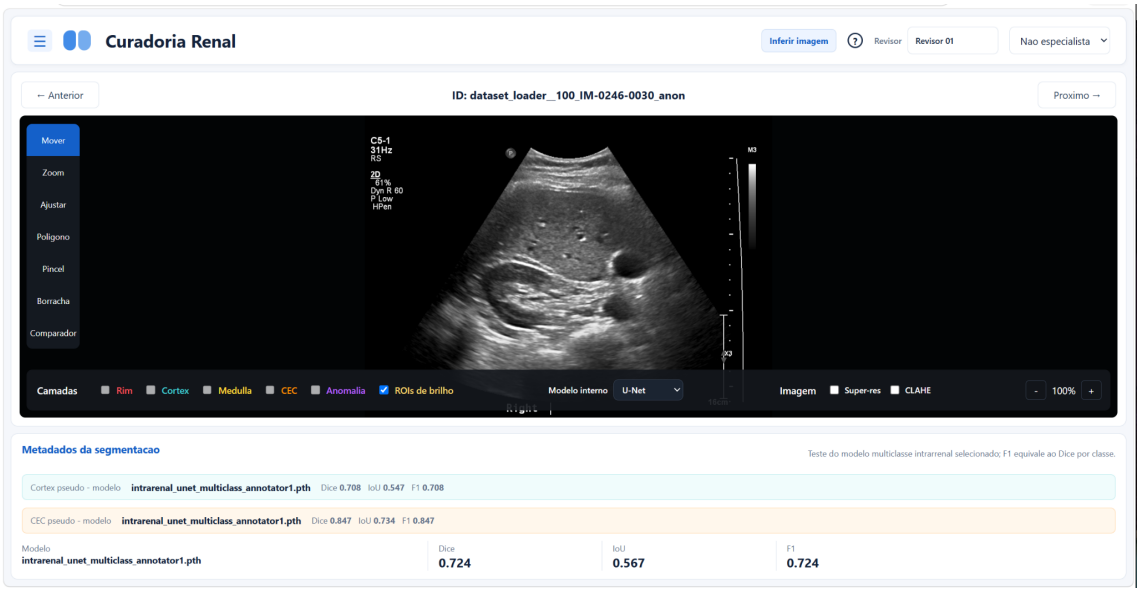


Figura 2. Visualização ampliada de um caso no módulo de curadoria, com ferramentas de navegação, controles de ativação das camadas e metadados do modelo intrarrenal. Nesta captura, as sobreposições anatômicas estão desmarcadas. Fonte: captura de tela da implementação.

A Figura 3 apresenta a configuração de uma edição manual com a ferramenta de pincel, incluindo a seleção da classe e da operação. A captura não demonstra, isoladamente, uma máscara já alterada ou uma operação de salvamento concluída; a persistência e o histórico são propriedades verificáveis na implementação.

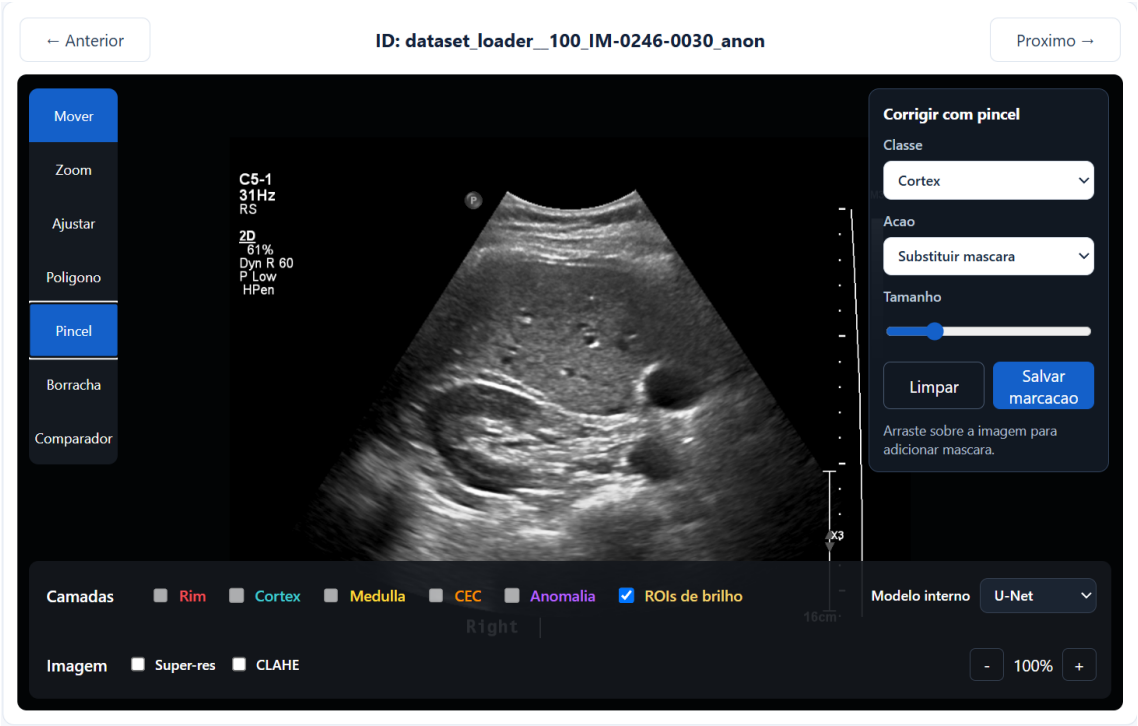


Figura 3. Ferramenta de edição manual configurada para a classe córtex e a operação de substituição de máscara por pincel. A captura documenta os controles de edição, sem apresentar o resultado de uma correção concluída. Fonte: captura de tela da implementação.

O módulo de inferência recebe uma nova imagem, executa a U-Net da cápsula, recorta a ROI renal, aplica a U-Net intrarrenal e reconstrói máscaras no espaço da imagem. Em seguida, calcula descritores de ecogenicidade quando as regiões necessárias estão disponíveis. As saídas são armazenadas separadamente e não ingressam automaticamente na base de treino, prevenindo incorporação silenciosa de previsões não revisadas.

4.7. Mensuração quantitativa de ecogenicidade

As previsões podem utilizar CLAHE, mas as estatísticas de brilho são calculadas na imagem B-mode original preservada pelo fluxo, antes desse realce. Seja μ_C a intensidade média cortical e μ_{CEC} a intensidade média do CEC. Para denominadores estritamente positivos, definem-se a razão e o contraste normalizado:

$$R_{C/CEC} = 100\frac{\mu_C}{\mu_{CEC}}, \qquad CN_{CEC-C} = 100\frac{\mu_{CEC} - \mu_C}{\mu_{CEC} + \mu_C}. \tag{3}$$

A diferença absoluta de intensidade é $D_{CEC-C} = \mu_{CEC} - \mu_C$. Também são registrados mediana, intervalo interquartil (IQR), tamanho das regiões e indicadores de saturação. Quando uma máscara é inexistente ou uma medida é matematicamente indefinida, o sistema deve registrar indisponibilidade, em vez de criar uma estimativa.

Como médias de regiões extensas podem ser sensíveis a bordas, heterogeneidade e profundidade, emprega-se adicionalmente um protocolo de ROIs pareadas. As máscaras de córtex e CEC são erodidas por um elemento estruturante de 5×5 pixels; a área é organizada em três estratos verticais e o algoritmo procura até um par de discos válidos por estrato. Os discos têm áreas iguais e profundidades verticais aproximadas. Para cada

par i, calculam-se

$$R_i = 100\frac{\mu_{C,i}}{\mu_{CEC,i}}, \qquad D_i = \mu_{CEC,i} - \mu_{C,i}. \tag{4}$$

A mediana dos R_i é a medida exploratória principal e o IQR descreve sua dispersão. O revisor pode ajustar as posições e conservar a versão revisada. A coordenada vertical funciona apenas como aproximação operacional de profundidade; não corrige completamente ganho temporal, atenuação, compressão ou diferenças entre equipamentos. O protocolo ainda requer análise de sensibilidade e repetibilidade, não sendo interpretado como biomarcador clínico validado.

A Figura 4 exemplifica o comparador interativo de duas ROIs circulares posicionadas manualmente. O exemplo seleciona CEC como região A e córtex como região B, de modo que a razão mostrada na interface é $100\,\mu_{CEC}/\mu_C$, inversa à razão global $R_{C/CEC}$ definida na Equação 3. Os dois indicadores não devem ser comparados sem considerar a ordem das regiões; além disso, o exemplo interativo de um par não substitui a mediana do protocolo automático de até três pares.



Figura 4. Comparador manual de ROIs na Curadoria Web, com sobreposição de máscaras anatômicas e razão de brilho CEC (A)/córtex (B) calculada sobre um par selecionado pelo revisor. A imagem original é utilizada sem CLAHE. Esse valor não representa o indicador global córtex/CEC nem um diagnóstico clínico. Fonte: captura de tela da implementação.

5. Resultados

5.1. Delimitação da cápsula renal

A Tabela 2 apresenta os resultados no teste manual deduplicado, comum às quatro arquiteturas. A U-Net obteve o maior Dice (0,9290), IoU (0,8722), precisão (0,9236) e *recall* (0,9440) entre as configurações comparadas. O SegFormer-B0 alcançou a maior taxa de inferência (31,34 FPS), em contraste com 18,11 FPS da U-Net. O ganho de sobreposição da U-Net em relação ao SegFormer foi de 0,0067 em Dice nesse teste; sem intervalo de confiança por exame ou comparação pareada de diferenças, não se deve converter essa distância numérica em alegação de superioridade estatística.

Tabela 2. Segmentação da cápsula em 70 imagens de teste manual deduplicado do `kidneyUS`.

Modelo	Dice	IoU	Precisão	Recall	FPS
U-Net	**0,9290**	**0,8722**	**0,9236**	**0,9440**	18,11
SegFormer-B0	0,9223	0,8598	0,9117	0,9426	**31,34**
DeepLabV3 R50	0,9203	0,8606	0,9219	0,9338	22,26
UNet++	0,9099	0,8419	0,8910	0,9419	16,57

A escolha da U-Net para localizar a ROI renal baseou-se no desempenho observado e no papel crítico da máscara externa. Essa escolha não implica que o modelo apresente a mesma qualidade em imagens externas. A diversidade de qualidade visual exige análise de erros e validação específica para novas fontes.

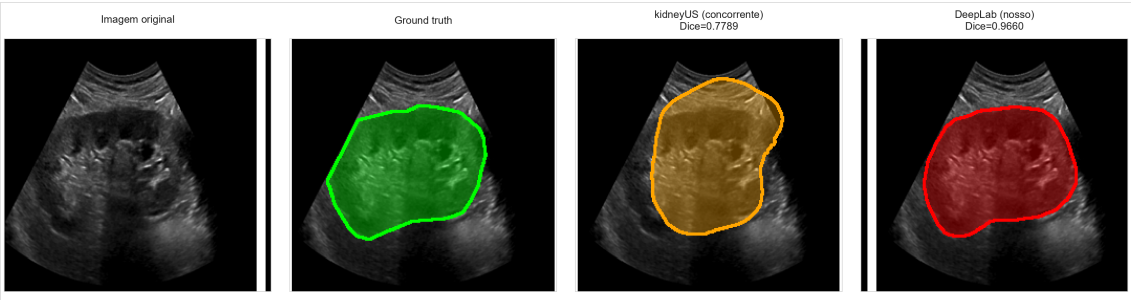


Figura 5. Exemplo qualitativo de segmentação em imagem com condições favoráveis de delimitação renal. A inspeção visual complementa, mas não substitui, as métricas agregadas.

5.2. Consenso *out-of-fold* e imagens externas

Na calibração com referência manual, o consenso U-Net–DeepLabV3 apresentou média de 0,9416, mediana de 0,9627 e correlação documentada de 0,840 com o menor Dice frente à anotação manual. A direção dessa associação sugere utilidade para triagem, mas concordância entre modelos não pode ser tomada como probabilidade de correção. Nas 4.479 imagens externas do MONAI, a U-Net produziu 3.534 pseudomáscaras candidatas; as outras 945 não receberam predição não vazia desse modelo no recorte analisado. Como não há máscaras manuais externas consolidadas para esse lote, esses números expressam cobertura e não acurácia anatômica.

5.3. Segmentação de córtex, medula e CEC

A Tabela 3 apresenta a avaliação no teste manual de 50 imagens. A U-Net multiclasse obteve Dice médio 0,7594 e maior Dice de córtex (0,7075) e medula (0,7237); a DeepLabV3 foi ligeiramente superior no CEC (0,8497 contra 0,8469). Em ambas, o CEC apresentou sobreposição mais alta do que córtex e medula. O resultado reforça que a tarefa interna deve ser analisada por estrutura e não apenas por uma média geral.

Tabela 3. Desempenho intrarrenal no teste manual de 50 imagens; Dice por estrutura e médias sobre classes de primeiro plano.

Modelo	Córtex	Medula	CEC	Dice médio	IoU médio
U-Net	**0,7075**	**0,7237**	0,8469	**0,7594**	**0,6163**
DeepLabV3 R50	0,6822	0,7156	**0,8497**	0,7492	0,6045

5.4. Variabilidade da referência humana

Na comparação das anotações disponíveis de ambos os observadores, o Dice médio variou por estrutura, como mostra a Tabela 4. A cápsula apresentou concordância mais elevada (0,9461), ao passo que córtex (0,5961) e medula (0,6936) concentraram divergências maiores. As quantidades de imagens comuns também diferem por classe; por isso, a tabela não representa uma avaliação pareada única de quatro estruturas em exatamente os mesmos casos. A menor concordância humana ajuda a interpretar a dificuldade de obter referências internas estáveis, sem constituir prova de que os modelos alcançaram desempenho equivalente ao de especialistas.

Tabela 4. Concordância Dice entre os dois anotadores do `kidneyUS`, nos conjuntos disponíveis por estrutura.

Estrutura	Imagens comuns	Dice
Cápsula	486	0,9461
Córtex	323	0,5961
Medula	325	0,6936
CEC	468	0,8688

5.5. Medula: heurística, estabilidade e expansão

Uma heurística inicial para localizar regiões escuras apresentou Dice médio $0{,}3291$ frente à referência do primeiro anotador. No experimento supervisionado específico de medula, a DeepLabV3 atingiu Dice de teste $0{,}7528$ e a MedullaROIUNet, $0{,}7326$. Em avaliação específica da estabilidade da cascata, a troca da ROI de cápsula manual pela cápsula prevista alterou o Dice global da DeepLabV3 de $0{,}7626$ para $0{,}7610$, uma diferença absoluta de $0{,}0016$. Nesse protocolo, a intensidade média estimada na medula teve correlação de $0{,}9508$ entre os dois cenários. Essa correlação descreve o conjunto avaliado; não descarta erros individuais nem certifica estabilidade de outras medidas.

Tabela 5. Experimento de pseudo-expansão do treino da medula, com validação e teste manuais preservados.

Configuração	Treino	Val. Dice	Teste Dice	IoU teste
Manual	236	0,7235	**0,7528**	**0,6035**
Manual + 342 pseudo	578	**0,7424**	0,7523	0,6030

A expansão elevou numericamente o Dice de validação de $0{,}7235$ para $0{,}7424$, enquanto o Dice de teste passou de $0{,}7528$ para $0{,}7523$. Essa diferença de $-0{,}0005$ no teste não demonstra benefício de generalização; tampouco permite afirmar equivalência estatística ou inutilidade da pseudo-expansão. O achado sinaliza a necessidade de estudar qualidade do rótulo, composição dos casos e variabilidade entre execuções antes de incorporar automaticamente novas máscaras ao treino.

5.6. Resultados históricos e componentes ainda exploratórios

Um experimento anterior no `dataset_geral` expandido registrou Dice médio de teste $0{,}9366$ para DeepLabV3-ResNet50. O valor é documentado como histórico porque a base, o tipo de referência e o protocolo diferem do teste manual deduplicado; não é utilizado para alegar progresso de $0{,}9290$ para $0{,}9366$. A Curadoria Web e a inferência integrada estão implementadas, mas ainda não há estudo de revisão humana com efeito

quantitativo demonstrado no retreinamento. Da mesma forma, o cálculo das ROIs córtex–CEC constitui um procedimento operacional disponível, e não uma avaliação concluída de repetibilidade ou associação clínica.

5.7. Artefato computacional: plataforma Web de Curadoria

Além dos experimentos de segmentação, a pesquisa produziu uma aplicação Web funcional para inspeção, edição e documentação de máscaras de ultrassonografia renal. As Figuras 1–3 apresentam a interface de triagem de casos, a visualização ampliada e os controles de correção de estruturas anatômicas. A Figura 4 registra a integração entre máscaras intrarrenais e a comparação visual de duas regiões de interesse de ecogenicidade. A aplicação também disponibiliza um fluxo de inferência para novas imagens, separado da inclusão automática de dados na base de treinamento.

O produto implementado demonstra a viabilidade técnica de reunir predição automática, conferência individual por estrutura, edição das máscaras e registro de decisões em uma infraestrutura local auditável. O histórico de alterações e a separação entre máscaras originais e corrigidas são propriedades da implementação; não constituem, isoladamente, evidência de melhora na acurácia, de concordância interobservador ou de utilidade clínica. A mensuração desses aspectos integra o planejamento experimental subsequente.

6. Discussão

Os resultados mostram uma assimetria entre as tarefas anatômicas. A delimitação da cápsula apresentou Dice de $0{,}9290$ no teste manual deduplicado, enquanto o Dice médio intrarrenal foi $0{,}7594$. A diferença, entretanto, não pode ser interpretada como redução mensurada da qualidade do mesmo modelo em uma única população, porque os conjuntos e as tarefas não coincidem. O que os dois experimentos evidenciam, em seus respectivos protocolos, é que o projeto dispõe de um segmentador externo competitivo e que o detalhamento de córtex e medula ainda constitui um gargalo.

A variabilidade entre anotadores reforça essa leitura. Enquanto a cápsula tem concordância humana relativamente elevada, córtex e medula apresentam menor sobreposição entre referências. Isso expõe duas fontes de erro que devem ser distinguidas: a imprecisão da predição computacional e a ambiguidade da própria anotação. Comparações externas, como os resultados de MAT-UNet no `kidneyUS`, ajudam a situar a dificuldade relativa das classes, mas diferenças de divisão, anotadores e execução impedem um ranking direto entre estudos [Zuo et al. 2025]. Um experimento futuro mais informativo deverá apresentar medidas por exame, distribuição de casos difíceis e, quando viável, múltiplas referências humanas.

O experimento de estabilidade oferece evidência inicial de viabilidade do encadeamento anatômico. Na avaliação específica de medula, substituir a cápsula manual pela prevista teve pequeno efeito na métrica global e preservou elevada correlação de intensidade média. Ainda assim, médias agregadas podem ocultar falhas importantes em exames difíceis. Particularmente em uma cadeia de mensuração, uma região deslocada pode modificar a ROI cortical ou do CEC mesmo quando a sobreposição global é satisfatória. Portanto, a análise de propagação deve ser aprofundada para os três compartimentos intrarrenais e para as medidas pareadas, não apenas para um único descritor de medula.

A pseudo-expansão é um resultado negativo informativo. O aumento de 236 para 578 imagens não elevou o Dice no teste manual da medula, embora a validação tenha melhorado. Existem interpretações plausíveis — seleção de casos redundantes, erros residuais dos pseudorrótulos, mudança de distribuição ou variância de treinamento —, mas os dados aqui apresentados não permitem determinar qual mecanismo predominou. A literatura sobre aprendizado com rótulos imperfeitos e correção de pseudorrótulos sustenta a relevância desse problema [Tajbakhsh et al. 2020, Su et al. 2024, Huang et al. 2025]. O próximo experimento deve separar explicitamente o efeito do volume de treinamento do efeito da qualidade de anotação.

Nesse contexto, o consenso U-Net–DeepLabV3 tem função operacional bem definida: apoiar a triagem. A correlação documentada entre acordo dos modelos e qualidade frente à referência é promissora para ordenar o trabalho de revisão, mas não prova que candidatos de consenso alto sejam anatomicamente corretos. Um estudo *human-in-the-loop* deve medir, por estratos de consenso, taxas de aceitação, correção e rejeição, concordância de revisores, tempo despendido e ganho no desempenho final. Somente essa comparação permitirá estimar o benefício científico e operacional da curadoria implementada.

A análise de ecogenicidade representa a motivação aplicada da segmentação. O uso da imagem original, em lugar de valores após CLAHE, evita introduzir na medida quantitativa o realce produzido especificamente para melhorar a entrada da rede. O pareamento córtex–CEC e a exclusão de bordas tornam explícitas as escolhas de amostragem e podem reduzir certas fontes de heterogeneidade. Entretanto, tais decisões também introduzem hiperparâmetros — raio, posição, número de pares, erosão e aproximação de profundidade — cuja sensibilidade ainda não foi medida. A literatura sobre ecogenicidade relativa fornece motivação, não validação direta desse protocolo particular [Manley and O'Neill 2001, Beutler et al. 2024, Zhao et al. 2025].

Finalmente, a caracterização quantitativa não deve ser confundida com inferência histopatológica. Uma razão córtex–CEC próxima da unidade informa semelhança relativa de intensidades na imagem disponível; ela não identifica, isoladamente, fibrose, IFTA ou doença renal crônica. A avaliação de associações com eGFR ou biópsia exigirá desenho de estudo, variáveis clínicas e análise de fatores de confusão apropriados [Moghazi et al. 2005, Athavale et al. 2021, Qin et al. 2024]. O valor atual do projeto reside, portanto, na integração rastreável entre dado, anatomia, revisão e medida, com fronteiras explícitas entre o demonstrado e o ainda hipotético.

7. Limitações e Ameaças à Validade

Validade interna. Embora a deduplicação e o agrupamento por exame ou paciente reduzam vazamento, diferenças na formação dos subconjuntos e na seleção dos checkpoints precisam continuar documentadas. Os resultados agregados não incluem, nesta versão, intervalos de confiança pareados por paciente, múltiplas sementes sistemáticas ou análise uniforme de significância. Resultados históricos em conjuntos expandidos com pseudomáscaras não podem ser interpretados como replicações independentes do benchmark manual.

Validade de construção. Dice e IoU medem concordância espacial, não adequação clínica. Confiança média e acordo entre modelos são indicadores operacionais, não probabilidades calibradas de correção. A discordância interobservador, sobretudo em córtex e medula, mostra que a escolha da anotação de referência afeta a avaliação. Para

ecogenicidade, intensidades derivadas de imagens B-mode processadas pelo equipamento não representam propriedades acústicas absolutas do tecido.

Validade externa. Os testes supervisionados documentados utilizam majoritariamente o `kidneyUS`. Imagens externas do MONAI foram processadas sem um conjunto manual de teste consolidado, o que impede estimar a acurácia anatômica nesse domínio. Equipamentos, operadores, população, ganho, TGC, profundidade, compressão e qualidade visual podem modificar tanto a segmentação quanto as razões de brilho.

Validade clínica e operacional. Não existe, nesta etapa, base clínica ou histopatológica pareada suficiente para afirmar detecção de fibrose, IFTA ou DRC. A ferramenta de curadoria preserva versões e decisões, mas sua concordância inter-revisores, custo de uso e benefício no retreinamento ainda precisam de medição prospectiva. A disponibilidade de infraestrutura funcional não equivale a validação do seu impacto.

8. Continuidade da Dissertação

A primeira prioridade é congelar manifestos, checkpoints, protocolos e conjuntos de avaliação, corrigindo divergências de contagens em relatórios históricos e vinculando cada número ao experimento responsável. A segunda é realizar uma rodada piloto de curadoria estratificada por consenso, qualidade visual e fonte, com participação de revisores independentes e medição de concordância, tempo e operações de correção. Após essa etapa, um teste final revisado e independente deverá ser preservado para comparação controlada dos três regimes de treinamento: manual, manual acrescido de pseudorrótulos automáticos e manual acrescido de pseudorrótulos revisados.

O próximo eixo será verificar como as diferenças de segmentação se propagam para a análise intrarrenal e para as medidas de ecogenicidade. O protocolo de ROIs pareadas deverá ser examinado por análise de sensibilidade do tamanho e número de discos, da erosão, da profundidade aproximada e da intervenção do revisor. Repetibilidade intra e interobservador, cobertura de pares válidos e distribuição de erros são desfechos prioritários. Somente após consolidar esses estudos computacionais fará sentido investigar, em uma coorte institucional com governança apropriada, associações com creatinina, eGFR, laudos e eventualmente histopatologia.

9. Conclusão

Este trabalho apresentou a organização de um pipeline rastreável para análise quantitativa de ultrassonografia renal, articulando segmentação da cápsula, consenso entre modelos, curadoria humana, segmentação intrarrenal e mensuração exploratória de ecogenicidade. O teste manual deduplicado documentou Dice de $0{,}9290$ para a cápsula com U-Net; a mesma arquitetura obteve Dice médio $0{,}7594$ na segmentação multiclasse de córtex, medula e CEC em outro conjunto de teste. A geração de 3.534 pseudomáscaras externas demonstrou cobertura operacional, não acurácia clínica.

A expansão preliminar de treino de medula não melhorou o Dice do teste manual, evidenciando a necessidade de avaliar qualidade de anotação e efeito da curadoria antes de interpretar quantidade de dados como benefício. A contribuição atual está na estrutura metodológica que preserva proveniência e separa predição automática, revisão humana e medida quantitativa. O protocolo córtex–CEC constitui uma etapa promissora para estudos de estabilidade de imagem, ainda sem validação clínica. A continuidade da pesquisa deverá testar o efeito da revisão humana e a repetibilidade das medidas,

mantendo a interpretação de fibrose e de doença renal crônica fora do escopo dos resultados atualmente demonstrados.

Referências

Athavale, A. M., Hart, P. D., Itteera, M., Cimbaluk, D., Patel, T., Alabkaa, A., Arruda, J., Singh, A., Rosenberg, A., and Kulkarni, H. (2021). Development and validation of a deep learning model to quantify interstitial fibrosis and tubular atrophy from kidney ultrasonography images. *JAMA Network Open*, 4(5):e2111176.

Beutler, B. D., El-Sabawi, B., Walker, D. K., Cen, S., and Tchelepi, H. (2024). An objective computer-assisted measurement of sonographic renal cortical echogenicity: The splenorenal index. *Ultrasound Quarterly*, 40(1).

Budd, S., Robinson, E. C., and Kainz, B. (2021). A survey on active learning and human-in-the-loop deep learning for medical image analysis. *Medical Image Analysis*, 71:102062.

Chen, L.-C., Zhu, Y., Papandreou, G., Schroff, F., and Adam, H. (2018). Encoder-decoder with atrous separable convolution for semantic image segmentation. *European Conference on Computer Vision (ECCV)*, pages 801–818.

Huang, S., Wang, S., Qiao, S., Liu, Y., and Liu, T. (2025). Semi-plc: A framework for semi-supervised medical images segmentation with pseudo label correction. *Computer Methods and Programs in Biomedicine*, 271:109027.

Jiao, R., Zhang, Y., Ding, L., Xue, B., Zhang, J., Cai, R., and Jin, C. (2024). Learning with limited annotations: A survey on deep semi-supervised learning for medical image segmentation. *Computers in Biology and Medicine*, 169:107840.

Khan, R., Xiao, C., Liu, Y., Tian, J., Chen, Z., Su, L., Li, D., Hassan, H., Li, H., Xie, W., Zhong, W., and Huang, B. (2024). Transformative deep neural network approaches in kidney ultrasound segmentation: Empirical validation with an annotated dataset. *Interdisciplinary Sciences: Computational Life Sciences*, 16(2):439–454.

Lee, D.-H. (2013). Pseudo-label: The simple and efficient semi-supervised learning method for deep neural networks. In *Workshop on Challenges in Representation Learning, ICML*, volume 3.

Manley, J. A. and O'Neill, W. C. (2001). How echogenic is echogenic? quantitative acoustics of the renal cortex. *American Journal of Kidney Diseases*, 37(4):706–711.

Moghazi, S., Jones, E., Schroepple, J., et al. (2005). Correlation of renal histopathology with sonographic findings. *Kidney International*, 67(4):1515–1520.

Qin, X., Liu, X., Xia, L., Luo, Q., and Zhang, C. (2024). Multimodal ultrasound deep learning to detect fibrosis in early chronic kidney disease. *Renal Failure*, 46(2):2417740.

Ronneberger, O., Fischer, P., and Brox, T. (2015). U-net: Convolutional networks for biomedical image segmentation. In *Medical Image Computing and Computer-Assisted Intervention (MICCAI)*, pages 234–241.

Singla, R., Ringstrom, C., Hu, G., Lessoway, V., Reid, J., Nguan, C., and Rohling, R. (2023). The open kidney ultrasound data set. In *Simplifying Medical Ultrasound*,

volume 14337 of *Lecture Notes in Computer Science*, pages 155–164. Springer Nature Switzerland.

Su, J., Luo, Z., Lian, S., Lin, D., and Li, S. (2024). Mutual learning with reliable pseudo label for semi-supervised medical image segmentation. *Medical Image Analysis*, 94:103111.

Tajbakhsh, N., Jeyaseelan, L., Li, Q., Chiang, J. N., Wu, Z., and Ding, X. (2020). Embracing imperfect datasets: A review of deep learning solutions for medical image segmentation. *Medical Image Analysis*, 63:101693.

Xie, E., Wang, W., Yu, Z., Anandkumar, A., Alvarez, J. M., and Luo, P. (2021). Segformer: Simple and efficient design for semantic segmentation with transformers. *Advances in Neural Information Processing Systems*, 34:12077–12090.

Zhao, L., Shang, J., Shi, Y., Yan, Y., Li, P., Niu, W., Zhang, G., Ding, Z., Chu, X., Wang, T., and Zheng, S. (2025). Quantifying ultrasound echogenicity difference for accurate chronic kidney disease diagnosis. *Journal of Nephrology*, 38(8):2353–2362.

Zhou, Z., Siddiquee, M. M. R., Tajbakhsh, N., and Liang, J. (2018). Unet++: A nested u-net architecture for medical image segmentation. *Deep Learning in Medical Image Analysis and Multimodal Learning for Clinical Decision Support*, pages 3–11.

Zuo, Y., Li, J., and Tian, J. (2025). A segmentation network with two distinct attention modules for the segmentation of multiple renal structures in ultrasound images. *Diagnostics*, 15(15):1978.