

Um Pipeline de Visão Computacional para Caracterização de Achados Intrarrenais em Ultrassonografia

Jefferson S. dos Anjos¹, Amaro A. de Lima¹, Gabriel M. Araújo¹,
Jorge Luiz de C. Henriques Junior², Norderval C. Araújo², José Hermógenes R. Suassuna²,
Felipe da R. Henriques¹

¹ CEFET/RJ – Rio de Janeiro – RJ – Brasil

² HUPE – UERJ – Rio de Janeiro – RJ – Brasil

jefferson.anjos.1@aluno.cefet-rj.br,
{amaro.lima,gabriel.araujo,felipe.henriques}@cefet-rj.br,
{jorge.henriques,norderval.norderval}@uerj.br

Abstract. Renal ultrasound interpretation depends on subjective visual inspection and anatomical delimitation of the kidney. This paper proposes a computer vision pipeline that first segments the kidney and then extracts exploratory intrarenal echogenicity and texture markers. An exploratory annotated set was used to train an initial model, which generated pseudo masks accepted only above a 90% operational confidence threshold. After data expansion, a second DeepLabV3 ResNet50 model was trained on the consolidated set and achieved Dice of 0.9235, IoU of 0.8741 and precision of 0.9301 on a fixed test set. Fibrosis, commonly assessed histologically as interstitial fibrosis and tubular atrophy (IFTA), is not a validated outcome in the current dataset.

Resumo. A interpretação de ultrassonografias renais depende de inspeção visual subjetiva e da delimitação anatômica do rim. Este artigo propõe um pipeline de visão computacional que primeiro segmenta o rim e depois extrai marcadores exploratórios de ecogenicidade e textura intrarrenal. Uma base exploratória anotada foi usada para treinar um modelo inicial, que gerou pseudomáscaras aceitas apenas acima de 90% de confiança operacional. Após a expansão dos dados, um segundo DeepLabV3 ResNet50 foi treinado no conjunto consolidado e atingiu Dice de 0,9235, IoU de 0,8741 e precisão de 0,9301 no teste fixo. Fibrose, usualmente avaliada histologicamente como fibrose intersticial e atrofia tubular (IFTA), não constitui um desfecho validado na base atual.

1. Introdução

A ultrassonografia renal é acessível, não invasiva e amplamente usada na avaliação de alterações estruturais do rim. Na prática clínica, ecogenicidade cortical, dimensões renais e diferenciação cortico-medular podem contribuir para avaliar alterações parenquimatosas, embora não determinem isoladamente fibrose.

Em estudos pareados com biópsia, o desfecho de fibrose é frequentemente operacionalizado como *interstitial fibrosis and tubular atrophy* (IFTA). Moghazi et al. [Moghazi et al. 2005] mostraram que a ecogenicidade cortical correlaciona-se com achados histopatológicos, mas possui especificidade limitada quando usada isoladamente. Athavale et al. [Athavale et al. 2021] demonstraram a viabilidade de prever classes

de IFTA a partir de ultrassonografia, utilizando rótulos histológicos como padrão de referência.

A ecogenicidade cortical, especialmente quando comparada ao fígado, também é observada em pacientes com doença renal crônica. A razão entre a intensidade cortical renal e a intensidade de um órgão de referência pode reduzir parte da subjetividade da inspeção visual [Manley and O'Neill 2001].

Em paralelo, a literatura explora segmentação renal e extração de medidas quantitativas de intensidade e textura para investigar padrões associados a alterações renais [Athavale et al. 2021]. Ainda assim, permanece a lacuna entre segmentar o rim e examinar, dentro dele, pontos hiperecogênicos candidatos a achados suspeitos.

Esse recorte é importante porque a ultrassonografia apresenta ruído, sombras acústicas, variações de ganho e diferenças de enquadramento. Sem uma máscara renal confiável, pontos muito claros podem ser confundidos com artefatos ou estruturas externas ao rim. Por isso, este trabalho parte da delimitação semântica do rim e só depois transforma achados hiperecogênicos em medidas computacionais.

Este artigo combina segmentação renal, expansão supervisionada por pseudomáscaras e extração de atributos intrarrenais. As contribuições são: consolidação de acervo expandido, geração de pseudomáscaras com limiar de 90%, treinamento de um segundo segmentador e avaliação exploratória de marcadores ultrassonográficos intrarrenais.

2. Contexto e Trabalhos Relacionados

A segmentação automática de rim em ultrassonografia é a primeira linha relacionada a este estudo. Arquiteturas como U-Net [Ronneberger et al. 2015], DeepLabV3 [Chen et al. 2018] e SegFormer [Xie et al. 2021] preservam bordas, capturam contexto multiescala e lidam com variações de textura.

A segunda linha é a quantificação da ecogenicidade renal relativa, em que medidas entre rim e fígado aproximam critérios usados por especialistas [Manley and O'Neill 2001]. A terceira é a extração de atributos quantitativos relacionados à textura e intensidade da imagem para investigação de alterações renais [Athavale et al. 2021].

Estruturas intrarrenais candidatas são mantidas apenas como referências espaciais exploratórias; elas não são tratadas, neste estudo, como marcador direto de IFTA.

Em segmentação, Dice e IoU medem a sobreposição entre máscara prevista e referência. Ambas variam de 0 a 1: valores próximos de 0 indicam baixa concordância, e valores próximos de 1 indicam maior proximidade entre predição e anotação esperada.

3. Metodologia

A metodologia foi organizada para transformar uma imagem de ultrassonografia renal em uma região anatômica delimitada e, em seguida, extrair marcadores exploratórios de intensidade e textura intrarrenal.

Para isso, o *pipeline* primeiro prepara a entrada, segmenta o rim, restringe a análise à máscara renal, procura regiões claras intrarrenais e, por fim, produz marcadores quantitativos. Uma eventual predição de IFTA exige dados associados a biópsia ou referência clínica validada e fica fora do escopo demonstrado. A Figura 1 apresenta essa organização geral.




Figura 1. Pipeline metodológico: a segmentação renal isola o rim para extração exploratória de marcadores intrarrenais.

Como indicado na Figura 1, a primeira etapa recebe a imagem de ultrassonografia, aplica normalização e redimensionamento e prepara a entrada para o segmentador. A segunda etapa segmenta o rim e usa a máscara resultante como janela anatômica, reduzindo falsos candidatos fora do órgão.

Na terceira etapa, a imagem em tons de cinza é examinada apenas dentro dessa região, buscando concentrações locais de pixels de alta intensidade próximas a regiões internas candidatas às pirâmides. Em seguida, são extraídos atributos de intensidade, dispersão, percentis, proporção de pixels brilhantes e textura por matrizes de coocorrência de níveis de cinza [Haralick et al. 1973].

Quando há ROI manual do fígado, também são calculadas razões entre rim e fígado. A etapa final usa um Random Forest [Breiman 2001] apenas como prova de conceito de separação de marcadores imagéticos; os rótulos disponíveis não representam IFTA confirmada.

O desenvolvimento foi organizado em duas fases. Na primeira, a base exploratória derivada do Open Kidney Ultrasound Data Set [Singla et al. 2023] reuniu 513 pares imagem e máscara, distribuídos em 360 imagens de treino, 51 de validação e 102 de teste. Esse conjunto treinou o modelo inicial, responsável por aprender o contorno renal.

Na segunda fase, o acervo foi ampliado com imagens locais e externas. O maior acréscimo veio do MONAI Clinical Ultrasound Image Repository: como o repositório completo é amplo e heterogêneo, foram filtrados nos metadados apenas estudos renais ou retroperitoneais. Os DICOMs selecionados foram convertidos para PNG, com descarte de quadros RGB ou coloridos para evitar Doppler e imagens fora do padrão B-mode. A curadoria gerou 4.487 PNGs; após deduplicação, 4.479 entraram no `dataset_geral`.

Para explicitar essa construção do acervo, a Tabela 1 resume os blocos que alimentaram o conjunto consolidado usado no segundo treinamento.

Tabela 1. Composição do acervo consolidado para segmentação renal.

Origem	Imagens	Papel no acervo
Open Kidney / kidneyUS	513	base inicial manual
Subconjuntos locais	1.002	complemento organizado
MONAI renal curado	4.479	expansão externa
Total	5.994	<code>dataset_geral</code>

Como mostrado na Tabela 1, o `dataset_geral` combina a base Open Kidney/kidneyUS, subconjuntos locais e o subconjunto MONAI curado. As imagens sem máscara manual foram pseudorrotuladas [Lee 2013], e as novas máscaras só foram aceitas quando a predição atingiu confiança operacional de pelo menos 90% e passou por filtros de área, componentes conectados e pixels de primeiro plano.

Na versão usada nos experimentos relatados, 3.962 imagens tinham máscaras aceitas: 1.001 originais e 2.961 pseudomáscaras geradas pelo modelo de segmentação 1. Essas pseudomáscaras foram mantidas apenas quando atingiram confiança mínima de 90% e passaram por filtros geométricos; as demais imagens permaneceram no manifesto

apenas para rastreabilidade.

No segundo treinamento, 30% das 3.962 imagens com máscara foram reservadas para teste fixo, e os 70% restantes foram usados em validação cruzada com 5 folds. Foram avaliadas as famílias U-Net, UNet++, DeepLabV3 e SegFormer.

A classificação exploratória de padrões intrarrenais usa apenas 50 imagens rotuladas, com 44 para treino e validação e 6 para teste. Esses rótulos não constituem referência histológica de IFTA e, portanto, não permitem avaliar detecção de fibrose.

Essa separação entre segmentação e decisão clínica foi adotada deliberadamente. O primeiro problema exige aprender o contorno renal com boa estabilidade; o segundo exige imagens vinculadas a IFTA por biópsia ou a referência clínica definida. Neste estágio, portanto, o artigo prioriza a etapa que já pode ser avaliada de forma consistente.

Para exemplificar a aplicação do *pipeline* em uma imagem concreta, a Figura 2 mostra, em sequência, o exame original, a máscara renal, a região intrarrenal analisada, as pirâmides candidatas e as ROIs de referência quando há comparação com fígado.




Figura 2. Exemplo de análise com órgão de referência: imagem original, máscara renal, região intrarrenal, pirâmides candidatas e ROIs de referência para comparação de ecogenicidade.

Na Figura 2, a máscara renal delimita a área em que os achados claros serão procurados. A região intrarrenal e as pirâmides candidatas organizam a busca espacial, enquanto as ROIs de referência permitem comparar a ecogenicidade do rim com o fígado quando essa informação está disponível. Esse exemplo ilustra que a análise não parte da imagem inteira, mas de uma região anatômica segmentada.

4. Resultados

Para avaliar o efeito da expansão do acervo no desempenho do segmentador, a Tabela 2 compara os resultados obtidos antes e depois da pseudorrotulação. Na etapa anterior, a escolha do DeepLabV3 R50 no `dataset_augmented` foi orientada pela maior precisão entre os modelos avaliados, com valor de **0,8426**.

Tabela 2. Resultados de segmentação antes e depois da expansão do acervo.

Etapa	Modelo	Dataset	Dice	IoU	Prec.	Recall	FPS
Antes	DeepLabV3 R50	dataset_augmented	0,8472	0,7732	0,8426	0,8718	28,98
	SegFormer B2		0,8372	0,7700	0,8294	0,8782	35,66
	U-Net		0,8119	0,7309	0,8039	0,8545	26,43
	UNet++		0,7924	0,6958	0,8189	0,7968	20,88
Depois	DeepLabV3 R50	dataset_geral	0,9235	0,8741	0,9301	0,9248	27,61

Como mostra a Tabela 2, depois da geração de pseudomáscaras, da filtragem por confiança de 90% e do treinamento no `dataset_geral`, o DeepLabV3 ResNet50 atingiu Dice médio de 0,9235, IoU de 0.8741, precisão de 0,9301 e recall de 0,9248 no teste fixo.

No *pipeline* completo, essa melhora reduz a inclusão de fundo, legenda e tecidos adjacentes, aumentando a confiabilidade das medidas intrarrenais. Esse ganho é relevante porque a busca por estruturas hiperecogênicas depende diretamente da qualidade da máscara renal.

Para complementar a avaliação quantitativa, a Figura 3 mostra um exemplo qualitativo em um caso com contorno renal mais definido.




Figura 3. Caso qualitativo favorável: imagem original, máscara de referência, predição do kidneyUS e predição do DeepLab local.

Na Figura 3, as colunas mostram a imagem original, a máscara de referência, a predição do modelo `kidneyUS` e a predição do DeepLab treinado localmente. Com contorno renal mais definido, o modelo local recupera a geometria do rim com alta aderência à referência. Essa estabilidade é importante porque a etapa seguinte depende de examinar apenas a região renal, evitando que pontos brilhantes fora do rim sejam tratados como suspeitos.

Para ilustrar o uso do modelo de segmentação 2 como entrada da prova de conceito, a Figura 4 apresenta um caso em que a máscara renal delimita a região interna examinada e organiza as pirâmides candidatas.




Figura 4. Prova de conceito com o modelo de segmentação 2: imagem original, máscara renal, região interna, pirâmides candidatas e referências usadas na análise.

Na Figura 4, a saída do segundo segmentador não é tratada como diagnóstico final. Ela define a janela anatômica para extrair atributos de intensidade, textura e relação espacial. Assim, a etapa posterior permanece uma caracterização exploratória de marcadores ultrassonográficos; avaliar IFTA exigiria imagens associadas a biópsia ou padrão clínico definido.

5. Discussão

Os resultados indicam que a principal contribuição do pipeline está na integração entre segmentação anatômica e extração de atributos intrarrenais. A máscara renal restringe a análise computacional ao órgão, reduzindo interferências externas e falsos achados fora da anatomia renal.

A melhora observada após a expansão do acervo sugere que a pseudorrotulação pode ser útil em cenários médicos com poucas anotações especializadas. Embora o limiar de 90% não substitua a validação clínica, ele funcionou como um mecanismo automático de controle de qualidade para a seleção das máscaras mais consistentes.

O pipeline também preserva a separação entre evidência computacional e interpretação clínica. Regiões hiperecogênicas não são tratadas como diagnóstico automático de fibrose, mas como achados candidatos para investigação quantitativa e validação posterior.

A comparação com resultados externos, como reproduções associadas ao kidneyUS, deve ser feita com cautela devido a diferenças de resolução, anotação e distribuição dos exames. Ainda assim, os resultados preliminares indicam que o ajuste aos dados locais foi importante para aumentar a estabilidade das máscaras renais.

As principais limitações envolvem a ausência de um conjunto clínico robusto de fibrose, o pequeno número de exemplos rotulados e a falta de anotações manuais das pirâmides renais. Apesar disso, os resultados obtidos mostram que o pipeline já fornece uma base consistente para futuras investigações em análise ultrassonográfica renal.

6. Conclusão

Este artigo propôs um *pipeline* para isolar o rim e extrair marcadores ultrassonográficos intrarrenais exploratórios. A segmentação foi construída em duas fases: modelo exploratório inicial, geração de pseudomáscaras com 90% de confiança e treinamento de um segundo modelo no `dataset_geral`. Esse modelo alcançou Dice médio de 0,9235 e sustenta a análise intrarrenal.

Os resultados mostram que a segmentação pode restringir a análise computacional à anatomia renal, reduzindo interferências externas e aumentando a confiabilidade das medidas extraídas. A expansão supervisionada por pseudomáscaras também demonstrou potencial para ampliar o acervo de treinamento mesmo em cenários com limitação de anotações manuais.

Além do desempenho quantitativo, o *pipeline* preserva a separação entre evidência computacional e interpretação clínica. Nesse contexto, as regiões hiperecogênicas são tratadas como achados candidatos para investigação, e não como diagnóstico automático. Uma etapa de predição de IFTA depende de casos vinculados a padrão histológico ou clínico validado.

Como trabalhos futuros, pretende-se ampliar o conjunto anotado, incluir marcações específicas das pirâmides renais e validar os atributos extraídos em cenários clínicos reais. Também se pretende investigar estratégias semi-supervisionadas e avaliar a integração de informações clínicas e medidas relativas de ecogenicidade para aumentar a robustez da análise.

Referências

- Athavale, A. M., Hart, P. D., Itteera, M., et al. (2021). Development and validation of a deep learning model to quantify interstitial fibrosis and tubular atrophy from kidney ultrasonography images. *JAMA Network Open*, 4(5):e2111176.
- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1):5–32.
- Chen, L.-C., Zhu, Y., Papandreou, G., Schroff, F., and Adam, H. (2018). Encoder-decoder with atrous separable convolution for semantic image segmentation. *European Conference on Computer Vision (ECCV)*, pages 801–818.
- Haralick, R. M., Shanmugam, K., and Dinstein, I. (1973). Textural features for image classification. *IEEE Transactions on Systems, Man, and Cybernetics*, SMC-3(6):610–621.
- Lee, D.-H. (2013). Pseudo-label: The simple and efficient semi-supervised learning method for deep neural networks. In *Workshop on Challenges in Representation Learning, ICML*, volume 3.
- Manley, J. A. and O'Neill, W. C. (2001). How echogenic is echogenic? quantitative acoustics of the renal cortex. *American Journal of Kidney Diseases*, 37(4):706–711.
- Moghazi, S., Jones, E., Schroepfle, J., et al. (2005). Correlation of renal histopathology with sonographic findings. *Kidney International*, 67(4):1515–1520.
- Ronneberger, O., Fischer, P., and Brox, T. (2015). U-net: Convolutional networks for biomedical image segmentation. In *Medical Image Computing and Computer-Assisted Intervention (MICCAI)*, pages 234–241.
- Singla, R., Ringstrom, C., Hu, G., Lessoway, V., Reid, J., Ngan, C., and Rohling, R. (2023). The open kidney ultrasound data set. In *Simplifying Medical Ultrasound*, volume 14337 of *Lecture Notes in Computer Science*, pages 155–164. Springer Nature Switzerland.
- Xie, E., Wang, W., Yu, Z., Anandkumar, A., Alvarez, J. M., and Luo, P. (2021). Segformer: Simple and efficient design for semantic segmentation with transformers. *Advances in Neural Information Processing Systems*, 34:12077–12090.