

Um Pipeline de Visão Computacional para Análise de Achados Hiperecogênicos em Ultrassonografia Renal

Jefferson S. dos Anjos¹, Amaro A. de Lima¹, Gabriel M. Araújo¹,
Jorge Luiz de C. Henriques Junior², Norderval², José Hermógenes R. Suassuna²,
Felipe da R. Henriques¹

¹ CEFET/RJ – Rio de Janeiro – RJ – Brasil

² HUPE – UERJ – Rio de Janeiro – RJ – Brasil

jefferson.anjos.1@aluno.cefet-rj.br,

{amaro.lima,gabriel.araujo,felipe.henriques}@cefet-rj.br,

{jorge.henriques,norderval.norderval}@uerj.br

Abstract. Renal ultrasound interpretation depends on subjective visual inspection and anatomical delimitation of the kidney. This paper proposes a computer vision pipeline that first segments the kidney and then analyzes suspicious hyperechoic regions near renal pyramids. An exploratory annotated set was used to train an initial model, which generated pseudo masks accepted only above a 90% operational confidence threshold. After data expansion, a second DeepLabV3 ResNet50 model was trained on the consolidated set and achieved Dice of 0.9366 and IoU of 0.8839 on a fixed 30% test set. The fibrosis suspicion classifier remains exploratory due to the lack of real labeled examples.

itálico
palavra
estrangeira

Resumo. A interpretação de ultrassonografias renais depende de inspeção visual subjetiva e da delimitação anatômica do rim. Este artigo propõe um **pipeline** de visão computacional que primeiro segmenta o rim e depois analisa regiões hiperecogênicas suspeitas próximas às pirâmides renais. Uma base exploratória anotada foi usada para treinar um modelo inicial, que gerou pseudomáscaras aceitas apenas acima de 90% de confiança operacional. Após a expansão dos dados, um segundo DeepLabV3 ResNet50 foi treinado no conjunto consolidado e atingiu Dice de 0.9366 e IoU de 0.8839 em teste fixo de 30%. O classificador de suspeita de fibrose permanece exploratório pela falta de exemplos reais rotulados.

de que?

em português se usa vírgula

1. Introdução

A ultrassonografia renal é um exame acessível, não invasivo e amplamente empregado na avaliação de alterações estruturais do rim. Na prática clínica, regiões muito claras no parênquima, em especial quando aparecem próximas às pirâmides renais, podem indicar achados suspeitos que merecem análise cuidadosa. A ecogenicidade cortical, especialmente quando comparada ao fígado, também é um sinal observado em pacientes com doença renal crônica. Estudos mostram que a razão entre a intensidade cortical renal e a intensidade de um órgão de referência pode reduzir parte da subjetividade da inspeção visual [Manley and O'Neill 2001, Araújo et al. 2020].

o que é isso?

Em paralelo, a literatura recente explora segmentação renal, **radiomics** e aprendizado de máquina para quantificar padrões associados a alterações fibróticas

ou funcionais [Athavale et al. 2021, Chen et al. 2023, Ge et al. 2023]. Apesar desses avanços, ainda há uma lacuna entre segmentar o rim e examinar, dentro da região segmentada, pontos hiperecogênicos candidatos a achados suspeitos. Assim, a segmentação não deve ser tratada como objetivo final, mas como etapa de isolamento anatômico para análise posterior.

Esse recorte é importante porque a ultrassonografia apresenta ruído, sombras acústicas, variações de ganho e diferenças de enquadramento entre exames. Pontos muito claros podem surgir por artefatos, por estruturas anatômicas normais ou por alterações que merecem atenção. Sem uma máscara renal confiável, esses pontos podem ser confundidos com estruturas externas ao rim. Por isso, este trabalho parte da delimitação semântica do rim e só depois transforma os achados hiperecogênicos em medidas computacionais.

Este artigo investiga a seguinte questão: ^{o que é isso?} em que medida a combinação entre segmentação renal, **expansão supervisionada por pseudomáscaras** e extração de atributos intrarrenais pode apoiar a análise de achados hiperecogênicos suspeitos? As contribuições são: (i) consolidação de um acervo expandido para segmentação renal; (ii) uso de um modelo inicial para gerar pseudomáscaras com limiar de confiança de 90%; (iii) treinamento de um segundo segmentador mais eficaz após a expansão da base; e (iv) avaliação exploratória da etapa de suspeita de fibrose, ainda limitada pela escassez de exemplos reais rotulados.

2. Contexto e Trabalhos Relacionados

A primeira linha relacionada a este trabalho é a segmentação automática de rim em ultrassonografia. Arquiteturas como U-Net [Ronneberger et al. 2015], DeepLabV3 [Chen et al. 2018] e SegFormer [Xie et al. 2021] oferecem estratégias complementares para preservar bordas, capturar contexto multiescala e lidar com variações de textura. A segunda linha é a quantificação da ecogenicidade renal relativa, em que medidas entre rim e fígado aproximam um critério usado por especialistas [Manley and O'Neill 2001, Araújo et al. 2020]. A terceira linha é a radiomics aplicada à doença renal, que busca relacionar textura, intensidade e heterogeneidade da imagem com fibrose ou disfunção [Athavale et al. 2021, Chen et al. 2023, Ge et al. 2023]. Além disso, alterações de ecogenicidade nas pirâmides renais foram associadas a pior função renal em cenários clínicos específicos [Chavhan et al. 2008], o que motiva a busca por estruturas claras nessa região.

Diferentemente de abordagens centradas apenas no contorno renal, este trabalho organiza essas linhas em um **pipeline** de dados. A máscara segmentada delimita a região de análise e permite procurar, apenas dentro do rim, regiões muito claras próximas às pirâmides candidatas. A contribuição, portanto, está no encadeamento entre curadoria, pseudorrotulação, treinamento, inferência, extração de atributos e interpretação experimental.

3. Metodologia

A Figura 1 apresenta a visão geral da abordagem. O pipeline recebe imagens de ultrassonografia, aplica normalização e redimensionamento, segmenta o rim e usa a máscara resultante para definir a região de interesse. Dentro dessa região, o método procura áreas hiperecogênicas, isto é, estruturas muito claras que aparecem próximas

às pirâmides renais candidatas. Em seguida, são extraídos atributos de intensidade, dispersão, percentis, proporção de pixels brilhantes e textura por matrizes de coocorrência de níveis de cinza [Haralick et al. 1973]. Quando há ROI manual do fígado, o sistema também calcula razões entre rim e fígado. Por fim, um classificador Random Forest [Breiman 2001] é usado apenas como prova de conceito, pois a etapa de decisão sobre suspeita de fibrose ainda não possui exemplos reais suficientes.

Na prática, a segmentação define uma janela anatômica para reduzir falsos candidatos fora do rim. A partir dela, a imagem é analisada em tons de cinza, buscando concentrações locais de pixels de alta intensidade e sua relação espacial com regiões internas candidatas às pirâmides. Essa etapa não assume que todo ponto claro represente fibrose; ela apenas transforma esses achados visuais em medidas que podem ser avaliadas posteriormente com rótulos clínicos.




Figura 1. Pipeline metodológico: a segmentação renal isola o rim para análise de regiões hiperecogênicas próximas às pirâmides renais.

O desenvolvimento foi organizado em duas fases. Na primeira, uma base exploratória derivada do Open Kidney Ultrasound Data Set [Singla et al. 2023], com 513 pares imagem e máscara, foi usada para treinar segmentadores iniciais. Esse modelo inicial teve a função de aprender o contorno renal e permitir a geração automática de máscaras em imagens adicionais. Na segunda fase, foi aplicada uma estratégia de pseudo labeling [Lee 2013]: as novas máscaras só foram aceitas quando a predição atingiu confiança operacional de pelo menos 90% e passou por filtros de área, componentes conectados e pixels de primeiro plano.

A montagem consolidada, chamada `dataset_geral`, contém 5.994 imagens únicas; destas, 3.962 possuem máscaras aceitas, sendo 1.001 máscaras originais e 2.961 pseudomáscaras filtradas. As demais 2.032 imagens foram preservadas no manifesto, mas não foram usadas no treinamento supervisionado. Após essa expansão, um segundo modelo foi treinado sobre a base ampliada, com maior diversidade de imagens e de contornos renais. A Tabela 1 resume o antes e depois dessa etapa.

A aceitação das pseudomáscaras não foi tratada como simples aumento de volume. A confiança mínima de 90% foi usada como critério operacional para reduzir a entrada de máscaras fracas no segundo treinamento. Os filtros geométricos também buscaram remover predições incompatíveis com uma região renal plausível, como objetos muito pequenos, regiões desconectadas ou respostas quase vazias. Com isso, a expansão da base procurou equilibrar quantidade e qualidade das anotações.

as 513 estão dentro da base consolidada também?

Tabela 1. Evolução do acervo e do modelo de segmentação.			
Etapa	Imagens	Máscaras aceitas	Uso principal
Base exploratória	513	513	Modelo inicial
Base consolidada	5.994	3.962	Segundo modelo


O protocolo principal do segundo modelo reserva 30% das 3.962 imagens com máscara como teste fixo e usa os 70% restantes para treino e seleção de modelo por

explicar melhor de onde vieram estas imagens, qual a origem do dataset

validação cruzada em 5 folds. Foram avaliadas as famílias U-Net, UNet++, DeepLabV3 e SegFormer. A etapa de classificação usa apenas o subconjunto atualmente rotulado para suspeita de alteração, com 50 imagens, das quais 44 compõem treino e validação e 6 compõem o teste. Por isso, essa etapa tem caráter exploratório e ainda não fecha o diagnóstico de fibrose em sim ou não.

deixar mais claro, por exemplo, já falar que é classificador de suspeita de fibrose

Essa separação entre segmentação e decisão clínica foi adotada deliberadamente. O primeiro problema exige aprender o contorno renal com boa estabilidade; o segundo exige exemplos reais de fibrose, preferencialmente balanceados e associados a informações clínicas. Neste estágio, portanto, o artigo prioriza a etapa que já pode ser avaliada de forma consistente.



explicar a figura no texto para guiar o leitor, não deixá-lo interpretar. Precisa ser explicado o que cada imagem representa e para que serve.

Figura 2. Exemplo de análise com órgão de referência: imagem original, máscara renal, região intrarrenal, pirâmides candidatas e ROIs de referência para comparação de ecogenicidade.

4. Resultados

está confuso quem é o dataset _augmented e o _geral?
Na tabela 1 isso já poderia estar definido

A Tabela 2 resume o desempenho antes e depois da expansão da base. Antes da montagem consolidada, o melhor resultado local era o DeepLabV3 R50 no dataset_augmented, com Dice de 0,8472. Depois da geração de pseudomáscaras, filtragem por confiança de 90% e treinamento do segundo modelo no dataset_geral, o DeepLabV3 ResNet50 atingiu Dice médio de 0,9366 e IoU de 0,8839 no teste fixo. Esse ganho indica que a expansão controlada do acervo foi decisiva para obter uma segmentação mais confiável antes da busca por achados intrarrenais.

Do ponto de vista do pipeline completo, a melhora da segmentação tem impacto direto sobre a etapa posterior. Uma máscara mais precisa reduz a inclusão de fundo, legenda, tecidos adjacentes e artefatos externos, que poderiam aumentar artificialmente a contagem de pixels brilhantes. Também preserva melhor a região interna do rim, onde se concentram as pirâmides candidatas. Assim, o ganho de Dice não representa apenas melhor contorno, mas maior confiabilidade para as medidas intrarrenais usadas depois.

seria interessante ter um human in the loop desta expansão do dataset, pois imagine que vc agregue ao treino 600% mais dados, todos com algum errinho de segmentação, então resultados com esses errinhos gerarão maior acurácia. Outra possibilidade é fazer um loop de aumento gradual, observando consistência em aumento de acurácia até que isso pare de ocorrer. Mas essas são ideias para pensarmos

não definido

o que é Dice?

Tabela 2. Resultados de segmentação antes e depois da expansão do acervo.

Protocolo / modelo	Dice	IoU	Prec.	Recall	FPS
Depois, DeepLabV3 R50, dataset_geral	0.9366	0.8839	—	—	—
Antes, DeepLabV3 R50, dataset_augmented	0.8472	0.7732	0.8426	0.8718	28.98
SegFormer B2, dataset_augmented	0.8372	0.7700	0.8294	0.8782	35.66
U-Net baseline, dataset_augmented	0.8119	0.7309	0.8039	0.8545	26.43
UNet++ baseline, dataset_augmented	0.7924	0.6958	0.8189	0.7968	20.88

As Figuras 3 e 4 complementam a avaliação quantitativa. Em imagens com contorno renal definido, o modelo local recupera a geometria do rim com alta aderência à máscara de referência. Em imagens ruidosas ou de baixo contraste, o erro aumenta, mas o segmentador treinado localmente ainda pode preservar parte da estrutura renal. Essa estabilidade é importante porque a etapa seguinte depende de examinar apenas a região renal, evitando que pontos brilhantes fora do rim sejam tratados como suspeitos.




Figura 3. Caso qualitativo favorável: imagem original, máscara de referência, predição do kidneyUS e predição do DeepLab local.




Figura 4. Caso qualitativo desafiador: imagem original, máscara de referência, predição do kidneyUS e predição do DeepLab local.

A etapa de suspeita de fibrose ainda não é apresentada como um classificador final. Até o momento, ela foi usada apenas como prova de conceito para verificar se os atributos extraídos da região renal conseguem separar alguns casos rotulados manualmente. Como esse subconjunto ainda é pequeno e desbalanceado, os resultados numéricos dessa etapa não são usados como evidência principal do artigo. A contribuição experimental consolidada, neste estágio, está na segmentação renal e na preparação da região intrarrenal para futura validação clínica.

Mesmo assim, essa etapa orienta a próxima fase do estudo. Os atributos extraídos permitem registrar, para cada imagem, informações sobre intensidade média, variabilidade, proporção de regiões muito claras e relação com a intensidade de referência quando disponível. Esse conjunto de medidas cria uma ponte entre o resultado visual do exame e uma base tabular que pode ser revisada por especialistas, ampliada com novos casos e usada posteriormente em modelos supervisionados mais robustos.

5. Discussão

Os resultados indicam que a principal contribuição do pipeline está na integração entre dados, máscara e descritores. Para o problema estudado, a segmentação organiza a evidência visual ao limitar a busca por achados muito claros à região anatômica do rim. Isso reduz interferências externas e permite examinar regiões próximas às pirâmides renais candidatas com maior controle. Além disso, o fluxo produz saídas intermediárias interpretáveis, o que facilita auditoria e inspeção qualitativa dos resultados.

Outro ponto relevante é que o pipeline preserva uma distinção entre evidência computacional e interpretação clínica. A presença de regiões hiperecogênicas pode orientar a análise, mas não deve ser convertida automaticamente em diagnóstico. Por isso, a proposta é melhor entendida como uma infraestrutura de análise que prepara medidas e exemplos para uma validação posterior, e não como um classificador clínico fechado.

A comparação com resultados externos, como artefatos associados ao kidneyUS, deve ser feita com cautela. Diferenças de resolução, anotação, split e distribuição dos dados impedem conclusões diretas quando os protocolos não são idênticos. Ainda assim, as reproduções preliminares indicam que o ajuste aos dados locais foi decisivo para o desempenho observado.

As principais limitações são a ausência de rótulos clínicos robustos de fibrose por imagem, o tamanho reduzido do conjunto rotulado para classificação, o desbalanceamento das classes e a falta de anotações manuais das pirâmides renais. Por isso, a etapa de decisão sobre fibrose em sim ou não ainda não deve ser apresentada como completa. O estudo deve ser entendido como consolidação metodológica da segmentação e da análise intrarrenal, preparando a futura validação clínica quando houver exemplos reais suficientes.

Também é importante destacar que o limiar de 90% usado na pseudorrotulação não substitui revisão especializada. Ele funciona como barreira automática para selecionar exemplos mais prováveis durante a expansão do acervo. Em um cenário clínico, a mesma lógica pode ser combinada com auditoria humana, permitindo que especialistas revisem prioritariamente os casos de maior incerteza ou aqueles em que a região hiperecogênica aparece próxima a estruturas anatômicas relevantes.

6. Conclusão

Este artigo propôs e avaliou um pipeline para isolar o rim e analisar regiões hiperecogênicas suspeitas próximas às pirâmides renais. A etapa de segmentação renal foi construída em duas fases: primeiro, um modelo exploratório treinado em base inicial; depois, a geração de pseudomáscaras com confiança mínima de 90% e o treinamento de um segundo modelo sobre o `dataset_geral`. Esse segundo modelo alcançou Dice médio de 0,9366, permitindo usar a máscara renal como base para a análise intrarrenal.

Como trabalhos futuros, pretende-se ampliar o subconjunto rotulado com casos reais, anotar pirâmides renais, refinar a detecção dos pontos muito claros e avaliar a consistência das medidas em diferentes aparelhos e condições de aquisição.

um sistema
que auxilia
a tomada
de decisão
do médico

Referências

- Araújo, N. C., Riella, C., Martins, L. S., et al. (2020). Sonographically determined kidney measurements are better able to predict histological changes and a low ckd-epi egfr when weighted towards cortical echogenicity. *BMC Nephrology*, 21(123).
- Athavale, A., Hartman, N., Sonavane, R., et al. (2021). Development and validation of a deep learning model to quantify interstitial fibrosis and tubular atrophy from kidney ultrasonography images. *JAMA Network Open*, 4(5):e2110856.
- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1):5–32.
- Chavhan, G. B., Parra, D. A., Oudjhane, K., et al. (2008). Renal pyramid echogenicity in ureteropelvic junction obstruction: correlation between altered echogenicity and differential renal function. *Pediatric Radiology*, 38(10):1063–1069.
- Chen, L.-C., Zhu, Y., Papandreou, G., Schroff, F., and Adam, H. (2018). Encoder-decoder with atrous separable convolution for semantic image segmentation. *European Conference on Computer Vision (ECCV)*, pages 801–818.
- Chen, Z., Guo, J., Chen, C., and Zheng, J. (2023). Ultrasound-based radiomics analysis in the assessment of renal fibrosis in patients with chronic kidney disease. *Journal of Ultrasound in Medicine*, 42(12):3025–3038.
- Ge, X.-Y., Miao, H., Wang, J., et al. (2023). Diagnostic accuracy of ultrasound-based multimodal radiomics modeling for fibrosis detection in chronic kidney disease. *Abdominal Radiology*, 48(3):977–987.
- Haralick, R. M., Shanmugam, K., and Dinstein, I. (1973). Textural features for image classification. *IEEE Transactions on Systems, Man, and Cybernetics*, SMC-3(6):610–621.
- Lee, D.-H. (2013). Pseudo-label: The simple and efficient semi-supervised learning method for deep neural networks. In *Workshop on Challenges in Representation Learning, ICML*, volume 3.
- Manley, J. A. and O'Neill, W. C. (2001). How echogenic is echogenic? quantitative acoustics of the renal cortex. *American Journal of Kidney Diseases*, 37(4):706–711.
- Ronneberger, O., Fischer, P., and Brox, T. (2015). U-net: Convolutional networks for biomedical image segmentation. In *Medical Image Computing and Computer-Assisted Intervention (MICCAI)*, pages 234–241.
- Singla, R., Ringstrom, C., Hu, G., Lessoway, V., Reid, J., Nguan, C., and Rohling, R. (2023). The open kidney ultrasound data set. In *Simplifying Medical Ultrasound*, volume 14337 of *Lecture Notes in Computer Science*, pages 155–164. Springer Nature Switzerland.
- Xie, E., Wang, W., Yu, Z., Anandkumar, A., Alvarez, J. M., and Luo, P. (2021). Segformer: Simple and efficient design for semantic segmentation with transformers. *Advances in Neural Information Processing Systems*, 34:12077–12090.